



Sesión 1. Modelos y probabilidad

Unidad 1 · Primera semana

«La probabilità non esiste.»
Bruno de Finetti

La frase no niega el cálculo que sigue: provoca una pregunta sobre qué significan sus números fuera del formalismo. Los axiomas producen consecuencias matemáticas; al aplicarlos debemos justificar por qué el espacio, los eventos y la probabilidad elegidos representan la situación.

Objetivos. Formular un modelo, justificar continuidad de probabilidades y usar el condicionamiento por eventos. La teoría de la medida se recuerda; sus aplicaciones probabilísticas se demuestran.

Regla de trabajo para los ejemplos. Antes de efectuar una cuenta seguiremos tres pasos: (i) describir el experimento y su espacio de resultados; (ii) fijar la probabilidad; (iii) definir como eventos los sucesos mencionados en la pregunta. Solo entonces calcularemos. No introduciremos una variable aleatoria cuando los eventos basten; ese concepto comienza en la sesión 2.

1. Del experimento al modelo

Un modelo especifica qué resultados distinguimos, qué sucesos podemos medir y con qué probabilidades. No hay equiprobabilidad por el solo hecho de que un conjunto sea finito.

Ejemplo: dos lanzamientos. El experimento consiste en lanzar dos veces una moneda y registrar, en orden, cruz (0) o cara (1). Un resultado es un par $\omega = (\omega_1, \omega_2)$. Adoptamos el modelo

$$\Omega = \{00, 01, 10, 11\}, \quad \mathcal{F} = 2^\Omega, \quad \mathbb{P}(\{\omega\}) = \frac{1}{4}.$$

Este modelo expresa dos lanzamientos equilibrados e independientes; la independencia se formalizará en la semana 2. Para responder preguntas sobre el número de caras no necesitamos definir todavía una variable aleatoria. Identificamos directamente los eventos

$$A_0 = \{\text{ninguna cara}\} = \{00\}, \quad A_1 = \{\text{exactamente una cara}\} = \{01, 10\},$$

$$A_2 = \{\text{exactamente dos caras}\} = \{11\}.$$

Por aditividad,

$$\mathbb{P}(A_0) = \frac{1}{4}, \quad \mathbb{P}(A_1) = \frac{2}{4}, \quad \mathbb{P}(A_2) = \frac{1}{4}.$$

Los tres eventos corresponden a los posibles conteos 0, 1, 2, pero no son equiprobables; no corresponde asignarles $1/3$. Si sabemos que apareció al menos una cara, la información es el evento

$$H = A_1 \cup A_2 = \{01, 10, 11\}.$$

El suceso preguntado “dos caras” es $A_2 \subset H$. Por ahora observamos que $\mathbb{P}(H) = 3/4$; en la sección 4, después de definir probabilidad condicional, obtendremos $\mathbb{P}(A_2 | H) = 1/3$.

Definición. Una σ -álgebra $\mathcal{F}$ sobre Ω contiene a Ω y es cerrada bajo complementos y uniones numerables. Un *espacio de probabilidad* es una terna $(\Omega, \mathcal{F}, \mathbb{P})$ donde $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$, $\mathbb{P}(\Omega) = 1$ y, para eventos disjuntos dos a dos,

$$\mathbb{P}\left(\bigcup_{n \geq 1} A_n\right) = \sum_{n \geq 1} \mathbb{P}(A_n).$$

Un resultado es $\omega \in \Omega$; un evento es $A \in \mathcal{F}$. Sin $\mathbb{P}$, el par $(\Omega, \mathcal{F})$ se llama *espacio medible*.

Recordatorio de medida. Se tiene $\emptyset \in \mathcal{F}$ y, por De Morgan, $\bigcap_n A_n = (\bigcup_n A_n^c)^c \in \mathcal{F}$. También $A \setminus B = A \cap B^c \in \mathcal{F}$. La σ -álgebra $\mathcal{B}(\mathbb{R})$ está generada por los abiertos. Usaremos la medida de Lebesgue λ sin reconstruirla.

Dos modelos de referencia.

- En un espacio finito o numerable, dadas masas $p_\omega \geq 0$ con $\sum_\omega p_\omega = 1$, se define $\mathbb{P}(A) = \sum_{\omega \in A} p_\omega$ sobre 2^Ω . La aditividad resulta de reagrupar series no negativas.
- En $\Omega = [0, 1]$, con la σ -álgebra boreliana relativa, $\mathbb{P}(A) = \lambda(A)$. Así $\mathbb{P}([a, b]) = b - a$ para $0 \leq a \leq b \leq 1$. No definimos esta medida sobre todos los subconjuntos de $[0, 1]$.

Lectura estadística. El modelo describe la distribución de una observación antes de observarla. Los datos son realizaciones. Una frecuencia observada no es, por definición, la probabilidad del modelo; las leyes de los grandes números estudiarán su relación.

Sesión 1 · 2. Propiedades y continuidad

Todos los conjuntos que aparecen a continuación son medibles.

Proposición 1. Se cumplen:

$$\mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(A^c) = 1 - \mathbb{P}(A), \quad A \subset B \implies \mathbb{P}(A) \leq \mathbb{P}(B),$$

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B), \quad \mathbb{P}\left(\bigcup_n A_n\right) \leq \sum_n \mathbb{P}(A_n).$$

Demostración. Aplicar la aditividad a $\Omega, \emptyset, \emptyset, \dots$ fuerza $\mathbb{P}(\emptyset) = 0$. Las descomposiciones disjuntas $\Omega = A \cup A^c$ y $B = A \cup (B \setminus A)$, si $A \subset B$, prueban complemento y monotonía. Como $A \cup B = A \cup (B \setminus A)$ y $B = (B \setminus A) \cup (A \cap B)$, se obtiene la fórmula de la unión. Para la última desigualdad, poner

$$D_1 = A_1, \quad D_n = A_n \setminus \bigcup_{j < n} A_j \quad (n \geq 2).$$

Los D_n son disjuntos, $D_n \subset A_n$ y $\bigcup D_n = \bigcup A_n$. La aditividad y la monotonía dan la desigualdad. $\square$

Teorema 2: continuidad de la probabilidad. Si $A_n \uparrow A$, es decir, $A_n \subset A_{n+1}$ y $A = \bigcup_n A_n$, entonces $\mathbb{P}(A_n) \uparrow \mathbb{P}(A)$. Si $A_n \downarrow A$, con $A = \bigcap_n A_n$, entonces $\mathbb{P}(A_n) \downarrow \mathbb{P}(A)$.

Demostración. En el caso creciente, tomar $A_0 = \emptyset$ y $D_n = A_n \setminus A_{n-1}$. Son disjuntos y $A_n = \bigcup_{k=1}^n D_k$, $A = \bigcup_{k \geq 1} D_k$. Por tanto,

$$\mathbb{P}(A) = \sum_{k \geq 1} \mathbb{P}(D_k) = \lim_{n \rightarrow \infty} \sum_{k=1}^n \mathbb{P}(D_k) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

En el caso decreciente, $A_n^c \uparrow A^c$. Lo probado y la fórmula del complemento dan $1 - \mathbb{P}(A_n) \rightarrow 1 - \mathbb{P}(A)$. $\square$

Hipótesis crucial. Para una medida general, la continuidad desde arriba requiere masa finita de algún término. En Lebesgue, $[n, \infty) \downarrow \emptyset$ pero todas sus medidas son infinitas. En probabilidad la finitud es automática.

3. Nulo no significa vacío

Un evento nulo tiene probabilidad cero; una propiedad vale *casi seguramente* si el evento donde falla es nulo. Precisemos primero el modelo: $\Omega = [0, 1]$, $\mathcal{F} = \mathcal{B}([0, 1])$ y $\mathbb{P} = \lambda$. El evento “el resultado es exactamente $1/2$ ” es

$$E = \{1/2\}.$$

Es no vacío, pero $\mathbb{P}(E) = \lambda(\{1/2\}) = 0$. El evento “observar un racional” es

$$R = \mathbb{Q} \cap [0, 1].$$

Como R es una unión numerable de singletons, la subaditividad da $\mathbb{P}(R) = 0$. Así, el resultado es irracional casi seguramente.

No puede sustituirse “numerable” por “arbitraria”: $[0, 1] = \bigcup_{x \in [0, 1]} \{x\}$ tiene probabilidad uno. En un espacio no completo, un subconjunto de un evento nulo no tiene por qué ser medible; aquí solo asignamos probabilidades a eventos de $\mathcal{F}$.

Sesión 1 · 4. Condicionar y actualizar

Definición. Para $B \in \mathcal{F}$ con $\mathbb{P}(B) > 0$, se define

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

La información B cambia las proporciones con las que se ponderan los resultados. El denominador es la probabilidad de la información disponible.

Proposición 3. Para B fijo de probabilidad positiva, $A \mapsto \mathbb{P}(A | B)$ es una probabilidad sobre $(\Omega, \mathcal{F})$.

Demostración. Es no negativa y $\mathbb{P}(\Omega | B) = 1$. Si los A_n son disjuntos, los $A_n \cap B$ también lo son; luego

$$\mathbb{P}\left(\bigcup_n A_n \mid B\right) = \frac{\sum_n \mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_n \mathbb{P}(A_n | B). \quad \square$$

Teorema 4: probabilidad total y Bayes. Sea $(B_i)_{i \in I}$ una partición finita o numerable de Ω en eventos con $\mathbb{P}(B_i) > 0$. Entonces

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i).$$

Si además $\mathbb{P}(A) > 0$, para cada $j \in I$,

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(A | B_j) \mathbb{P}(B_j)}{\sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i)}.$$

Demostración. Los $A \cap B_i$ son disjuntos y su unión es A . La aditividad da $\mathbb{P}(A) = \sum_i \mathbb{P}(A \cap B_i)$; la definición de condicionamiento da la primera fórmula. Sustituirla en $\mathbb{P}(B_j | A) = \mathbb{P}(A \cap B_j) / \mathbb{P}(A)$ prueba la segunda. $\square$

Si una celda de la partición es nula, su intersección con A es nula. Se omite esa celda de la suma; no se utiliza una expresión indefinida multiplicada por cero.

Ejemplo resuelto: procedencia de una pieza. Enunciado. Dos líneas de producción aportan, respectivamente, el 60 % y el 40 % de las piezas de una fábrica. El 2 % de las piezas producidas por la línea 1 y el 5 % de las producidas por la línea 2 son defectuosas. Se elige al azar una pieza de la producción conjunta y se la inspecciona.

- ¿Cuál es la probabilidad de que la pieza elegida sea defectuosa?
- Si la pieza elegida resulta defectuosa, ¿cuál es la probabilidad de que proceda de la línea 2?

Modelización. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un modelo para este experimento: cada $\omega \in \Omega$ representa una pieza seleccionada junto con su procedencia y su estado. Definimos directamente los eventos

$$L_1 = \{\text{la pieza procede de la línea 1}\},$$

$$L_2 = \{\text{la pieza procede de la línea 2}\}, \quad D = \{\text{la pieza es defectuosa}\}.$$

Los eventos L_1, L_2 forman una partición de Ω . Los datos del modelo, escritos como probabilidades, son

$$\mathbb{P}(L_1) = 0.60, \quad \mathbb{P}(L_2) = 0.40, \quad \mathbb{P}(D | L_1) = 0.02, \quad \mathbb{P}(D | L_2) = 0.05.$$

La primera pregunta es “¿cuál es la probabilidad de defecto?”, es decir, calcular $\mathbb{P}(D)$. Descomponemos primero el evento:

$$D = (D \cap L_1) \dot{\cup} (D \cap L_2).$$

Por probabilidad total,

$$\mathbb{P}(D) = 0.60(0.02) + 0.40(0.05) = 0.032.$$

La segunda pregunta es “dada una pieza defectuosa, ¿cuál es la probabilidad de que proceda de la línea 2?”: el evento buscado es L_2 y la información condicionante es D . Entonces

$$\mathbb{P}(L_2 | D) = \frac{\mathbb{P}(L_2 \cap D)}{\mathbb{P}(D)} = \frac{\mathbb{P}(D | L_2)\mathbb{P}(L_2)}{\mathbb{P}(D)} = \frac{0.05(0.40)}{0.032} = \frac{5}{8}.$$

Entre 10000 piezas bajo estas proporciones, los conteos de referencia serían 120 y 200 defectuosas por línea: $200/320 = 5/8$. Es una traducción de las proporciones del modelo, no una afirmación sobre un lote observado.

Cierre. $\mathbb{P}(D | L_2) = 0.05$ no es $\mathbb{P}(L_2 | D) = 0.625$. Si $\mathbb{P}(B) = 0$, el cociente de la definición no existe. El condicionamiento respecto de variables y σ -álgebras se desarrollará en la semana 8.



Sesión 2. Variables y leyes

Unidad 1 · Primera semana

Objetivos. Separar variable y ley; verificar medibilidad; deducir las propiedades de una función de distribución y distinguir leyes discretas, con densidad y mixtas.

Regla de trabajo. Para una pregunta sobre X , escribiremos primero el modelo $(\Omega, \mathcal{F}, \mathbb{P})$, la definición de X y el evento como preimagen; por ejemplo, “ $X \leq x$ ” significa $\{\omega : X(\omega) \leq x\}$. La probabilidad se aplica al evento, no al símbolo aislado.

1. Una variable es una función medible

Advertencia terminológica. Se suele decir, con intención provocadora:

“Una variable aleatoria ni es variable ni es aleatoria”.

En efecto, X es una función fija: a cada resultado ω le asigna un valor $X(\omega)$. Lo que varía es el resultado del experimento, y la incertidumbre proviene de no saber qué ω ocurrirá; la ley de X describe cómo esa incertidumbre sobre Ω se transporta al espacio de valores.

Definición. Una variable aleatoria real es una aplicación medible $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Esto significa que

$$\{X \in C\} := X^{-1}(C) = \{\omega : X(\omega) \in C\} \in \mathcal{F} \quad \text{para todo } C \in \mathcal{B}(\mathbb{R}).$$

La notación $\{X \leq x\}$ abrevia $X^{-1}((-\infty, x])$. La medibilidad garantiza que las preguntas acerca de la observación tengan probabilidades definidas.

Proposición 5: criterio práctico. X es medible si y solo si $\{X \leq x\} \in \mathcal{F}$ para cada $x \in \mathbb{R}$.

Demostración. La necesidad se sigue de la definición. Para la suficiencia, la clase $\mathcal{C} = \{C \subset \mathbb{R} : X^{-1}(C) \in \mathcal{F}\}$ es una σ -álgebra, pues las preimágenes preservan complementos y uniones. Por hipótesis contiene todos los intervalos $(-\infty, x]$. Estos generan $\mathcal{B}(\mathbb{R})$: $(-\infty, b) = \bigcup_n (-\infty, b - 1/n]$, los intervalos abiertos se obtienen por diferencias y todo abierto de $\mathbb{R}$ es unión numerable de intervalos con extremos racionales. Por tanto $\mathcal{B}(\mathbb{R}) \subset \mathcal{C}$. $\square$

Ejemplo: una observación demasiado fina. Sean $\Omega = \{1, 2, 3, 4\}$ y $\mathcal{F} = \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}\}$. Para decidir medibilidad todavía no necesitamos fijar una probabilidad. Definimos explícitamente

$$X(1) = X(2) = 0, \quad X(3) = X(4) = 1,$$

y

$$Y(1) = Y(3) = 0, \quad Y(2) = Y(4) = 1.$$

Para X , las preimágenes de sus valores son $\{X = 0\} = \{1, 2\} \in \mathcal{F}$ y $\{X = 1\} = \{3, 4\} \in \mathcal{F}$; por tanto, todas sus preimágenes borelianas pertenecen a $\mathcal{F}$. En cambio, el evento que correspondería a observar $Y \leq 0$ es

$$\{Y \leq 0\} = Y^{-1}((-\infty, 0]) = \{1, 3\} \notin \mathcal{F}.$$

Así, X es medible y Y no lo es: con la información representada por $\mathcal{F}$, Y pretende distinguir resultados que el modelo no distingue.

2. La ley es una medida sobre los valores

Definición y verificación. La *ley* de X es $\mu_X(C) = \mathbb{P}(X \in C)$, para C boreliano. Es una probabilidad: $\mu_X(\mathbb{R}) = 1$, es no negativa y, si los C_n son disjuntos, sus preimágenes también lo son, de modo que

$$\mu_X\left(\bigcup_n C_n\right) = \mathbb{P}\left(\bigcup_n X^{-1}(C_n)\right) = \sum_n \mu_X(C_n).$$

En el modelo de dos lanzamientos de la sesión 1 definimos ahora la variable “número de caras” mediante

$$N(00) = 0, \quad N(01) = N(10) = 1, \quad N(11) = 2.$$

Sus preimágenes $\{N = 0\}$, $\{N = 1\}$ y $\{N = 2\}$ son precisamente los eventos A_0, A_1, A_2 ya identificados. Por tanto, su ley satisface

$$\mu_N(\{0\}) = \frac{1}{4}, \quad \mu_N(\{1\}) = \frac{1}{2}, \quad \mu_N(\{2\}) = \frac{1}{4}.$$

No confundir. X , $X(\omega)$ y μ_X son, respectivamente, función, valor observado y medida. Dos variables pueden tener la misma ley sin coincidir. En el modelo $(\Omega, \mathcal{F}, \mathbb{P}) = ([0, 1], \mathcal{B}([0, 1]), \lambda)$, definamos $U(\omega) = \omega$ y $V(\omega) = 1 - \omega$. Para $0 \leq x \leq 1$, los eventos son

$$\{U \leq x\} = [0, x], \quad \{V \leq x\} = [1 - x, 1].$$

Ambos tienen probabilidad x , así que U y V tienen la misma ley uniforme. Sin embargo, $\{U = V\} = \{1/2\}$ es un evento nulo.

Sesión 2 · 3. Función de distribución

Para cada $x \in \mathbb{R}$ fijamos primero el evento

$$A_x = \{X \leq x\} = X^{-1}((-\infty, x]).$$

La familia (A_x) es creciente en x y todas sus probabilidades están definidas por la medibilidad de X .

Convención del curso. Para toda variable real X ,

$$F_X(x) = \mathbb{P}(X \leq x).$$

Usaremos siempre $\leq$. Saporta usa $\mathbb{P}(X < x)$ en la edición consultada; no se trasladan sus convenciones de continuidad ni sus extremos de intervalos sin ajustarlos.

Teorema 6. F_X es no decreciente, continua por la derecha y satisface

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

Además, con $F_X(x-) = \lim_{t \uparrow x} F_X(t)$,

$$F_X(x-) = \mathbb{P}(X < x), \quad \mathbb{P}(X = x) = F_X(x) - F_X(x-).$$

Demostración. Si $x \leq y$, $\{X \leq x\} \subset \{X \leq y\}$, y la monotonía de $\mathbb{P}$ prueba la de F_X . Como X toma valores reales finitos,

$$\{X \leq n\} \uparrow \Omega, \quad \{X \leq -n\} \downarrow \emptyset.$$

La continuidad de $\mathbb{P}$ da los límites a lo largo de enteros; la monotonía los extiende al límite real.

Si $x_n \downarrow x$, entonces $\{X \leq x_n\} \downarrow \{X \leq x\}$, de donde $F_X(x_n) \rightarrow F_X(x)$. Esta es la continuidad por la derecha.

Si $x_n \uparrow x$ con $x_n < x$, entonces $\{X \leq x_n\} \uparrow \{X < x\}$. Por continuidad desde abajo, $F_X(x-) = \mathbb{P}(X < x)$. Finalmente, $\{X \leq x\} = \{X < x\} \cup \{X = x\}$ es una unión disjunta; restar prueba la fórmula del salto. $\square$

Corolario 7: probabilidades de intervalos. Para $a < b$,

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= F_X(b) - F_X(a), \\ \mathbb{P}(a \leq X \leq b) &= F_X(b) - F_X(a-), \\ \mathbb{P}(a < X < b) &= F_X(b-) - F_X(a), \\ \mathbb{P}(a \leq X < b) &= F_X(b-) - F_X(a-). \end{aligned}$$

Demostración. Cada fórmula resta la probabilidad de la semirrecta que se excluye de la semirrecta que se incluye. Por ejemplo, $\{X \leq b\} = \{X < a\} \cup \{a \leq X \leq b\}$, disjuntamente, prueba la segunda. Las otras descomposiciones son idénticas con sus respectivos extremos. $\square$

Consecuencia. F_X es continua en x si y solo si $\mathbb{P}(X = x) = 0$. Una función de distribución continua no tiene átomos; eso, por sí solo, no afirma que admita densidad.

Sesión 2 · 4. Tres tipos de ley

Discreta. Si $\mathbb{P}(X \in \{x_1, x_2, \dots\}) = 1$, con valores distintos, entonces $p_k = \mathbb{P}(X = x_k)$ y

$$\mu_X(C) = \sum_{k: x_k \in C} p_k, \quad F_X(x) = \sum_{k: x_k \leq x} p_k.$$

Estas fórmulas resultan de la aditividad sobre los singletons disjuntos; el complemento del conjunto de valores tiene masa cero. Para precisar el caso Bernoulli, sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, sea $A \in \mathcal{F}$ un evento y definamos $X = \mathbf{1}_A$. Entonces

$$\{X = 1\} = A, \quad \{X = 0\} = A^c, \quad p = \mathbb{P}(A).$$

Antes de calcular $F_X(x)$, las preimágenes son $\{X \leq x\} = \emptyset$ si $x < 0$, A^c si $0 \leq x < 1$ y Ω si $x \geq 1$. Por tanto,

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - p, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

Se llama ley de Bernoulli de parámetro p . Las masas son los saltos.

Con densidad. La ley admite densidad si hay $f \geq 0$ medible con $\int_{\mathbb{R}} f \, dx = 1$ y $\mu_X(C) = \int_C f \, dx$ para todo boreliano C . Entonces

$$F_X(x) = \int_{-\infty}^x f(t) \, dt, \quad \mathbb{P}(X = x) = 0.$$

La segunda igualdad se debe a que un singleton tiene medida de Lebesgue cero. Una densidad es una función que se integra; $f(x)$ no es la probabilidad de $X = x$ y puede ser mayor que uno. Por el teorema fundamental para la integral de Lebesgue, $F'_X = f$ casi en todas partes, no necesariamente en cada punto.

Ejemplo con densidad. Construimos primero el modelo canónico: $\Omega = \mathbb{R}$, $\mathcal{F} = \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(C) = \int_C 2t \mathbf{1}_{(0,1)}(t) \, dt, \quad X(\omega) = \omega.$$

La función $f(t) = 2t \mathbf{1}_{(0,1)}(t)$ es no negativa e integra uno. El evento $\{X \leq x\}$ es $(-\infty, x]$; por eso

$$F_X(x) = \begin{cases} 0, & x \leq 0, \\ x^2, & 0 < x < 1, \\ 1, & x \geq 1. \end{cases}$$

Para la pregunta de intervalo identificamos

$$B = \{1/2 < X \leq 1\} = X^{-1}((1/2, 1]) = (1/2, 1].$$

Luego $\mathbb{P}(B) = F_X(1) - F_X(1/2) = 1 - 1/4 = 3/4$. La aditividad de $\mathbb{P}$ se obtiene por convergencia monótona aplicada a las sumas de indicadores disjuntos.

Mixta: cero o tiempo positivo. Para $0 < q < 1$, definir

$$\mu(C) = q \mathbf{1}_{\{0 \in C\}} + \frac{1-q}{2} \lambda(C \cap (1, 3)).$$

Tomamos el modelo canónico $(\Omega, \mathcal{F}, \mathbb{P}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mu)$ y la variable identidad $X(\omega) = \omega$. La medida combina una masa q en cero y una masa $1 - q$ distribuida uniformemente en $(1, 3)$. Para hallar la función de distribución usamos el evento $A_x = \{X \leq x\} = (-\infty, x]$ y obtenemos

$$F(x) = \begin{cases} 0, & x < 0, \\ q, & 0 \leq x < 1, \\ q + (1-q)(x-1)/2, & 1 \leq x < 3, \\ 1, & x \geq 3. \end{cases}$$

Tiene un salto q en cero y una parte con densidad. No tiene una densidad global respecto de Lebesgue: la integral sobre $\{0\}$ sería cero, pero su masa es q . Para comparar extremos de intervalo, definimos

$$B = \{0 < X \leq 2\} = (0, 2], \quad C = \{0 \leq X \leq 2\} = [0, 2].$$

El segundo evento contiene además el átomo $\{X = 0\} = \{0\}$. Por tanto,

$$\mathbb{P}(B) = \frac{1-q}{2}, \quad \mathbb{P}(C) = q + \frac{1-q}{2}.$$

Anexo de la sesión 2 · Caracterización completa

Lectura complementaria con demostración. No se exigirá reproducir esta prueba en una evaluación si no se ha trabajado en clase. El resultado explica por qué una función de distribución determina una ley y permite construirla.

Teorema 8. Sea $F : \mathbb{R} \rightarrow [0, 1]$ no decreciente, continua por la derecha, con límites 0 y 1 en $-\infty$ y $+\infty$. Existe una única probabilidad μ en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ con $\mu((-\infty, x]) = F(x)$.

Demostración. Existencia. En $\Omega = (0, 1)$ con probabilidad uniforme, para $0 < u < 1$ poner

$$Q(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}.$$

El conjunto es no vacío por el límite en $+\infty$ y está acotado inferiormente por el límite en $-\infty$. Por tanto $Q(u)$ es real. Si $a = Q(u)$, para cada n hay $y_n < a + 1/n$ con $F(y_n) \geq u$. Luego $F(a + 1/n) \geq u$; la continuidad por la derecha da $F(a) \geq u$. Así el ínfimo pertenece al conjunto.

En consecuencia, para cualquier x ,

$$Q(u) \leq x \iff u \leq F(x).$$

La implicación hacia la derecha usa $F(Q(u)) \geq u$ y monotonía; la inversa usa que x pertenece al conjunto cuyo ínfimo se toma. Por ello $\{u : Q(u) \leq x\} = (0, F(x)] \cap (0, 1)$ es boreliano, y Q es medible por la proposición 5. La ley de Q satisface

$$\mathbb{P}(Q \leq x) = \lambda((0, F(x)] \cap (0, 1)) = F(x).$$

Unicidad. Recordemos el lema π - λ de teoría de la medida: una clase cerrada bajo intersecciones finitas genera un σ -álgebra contenida en cualquier sistema de Dynkin que la contenga. Un sistema de Dynkin contiene el espacio total y es cerrado bajo complementos y uniones numerables disjuntas.

Si μ, ν son dos probabilidades con la misma F , la clase $\mathcal{D} = \{C \in \mathcal{B}(\mathbb{R}) : \mu(C) = \nu(C)\}$ contiene a $\mathbb{R}$, es cerrada bajo complementos (ambas masas totales son uno) y bajo uniones disjuntas (por aditividad). Contiene $\mathcal{P} = \{\mathbb{R}\} \cup \{(-\infty, x] : x \in \mathbb{R}\}$, cerrada bajo intersecciones y generadora de $\mathcal{B}(\mathbb{R})$. El lema da $\mathcal{D} = \mathcal{B}(\mathbb{R})$, lo que prueba la unicidad. $\square$

Qué se ha usado como prerrequisito. Medida de Lebesgue, convergencia monótona, el teorema fundamental de la integral de Lebesgue y el lema π - λ . Las aplicaciones nuevas se han justificado; no se repite la construcción de medidas ni la demostración de esos resultados del curso previo.

Lecturas de apoyo. G. Saporta, *Probabilités, analyse des données et statistique*, 2.^a ed., 2006: capítulo 1, §§1.1–1.3, y capítulo 2, §2.1.1 (ajustar la convención de F). R. Durrett, *Probability: Theory and Examples*, ed. 4.1: §§1.1 y 1.3. S. Sheffield, MIT 18.175 (2014): clase 1 y selección de la clase 2 sobre distribuciones en la recta. Estas notas y sus ejemplos son una elaboración para CM4H1, no una traducción literal.



Notas · Semana 2

Teoría de la Probabilidad · CM4H1

Esperanza, desigualdades, independencia y convolución

Oswaldo Velásquez Castañón

Profesor Principal · Escuela Profesional de Matemática

Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 2

De la ley a los promedios y a la independencia

Propósito. La sesión 1 construye la esperanza como integral y demuestra Markov, Chebyshev y Jensen. La sesión 2 introduce la ley conjunta, formaliza la independencia y deduce la convolución. En cada ejemplo se definen primero el modelo, las variables y los eventos.

Recordatorios de medida. Usaremos aproximación por funciones simples, convergencia monótona y dominada, medida producto, Tonelli, Fubini y el lema π - λ . Se enunciarán antes de aplicarlos, aunque sus demostraciones pertenecen al curso de Teoría de la Medida.

Sesión 1. Esperanza, momentos y desigualdades

Objetivo de la sesión. Definir la esperanza desde la integral, transferirla a la ley y controlar probabilidades de cola.

2.1. Construcción de la esperanza

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $X : \Omega \rightarrow \mathbb{R}$ una variable aleatoria.

Definición 2.1. Si $X \geq 0$, se define $\mathbb{E}X = \int_{\Omega} X \, d\mathbb{P} \in [0, \infty]$. Para X arbitraria ponemos $X^+ = \max(X, 0)$ y $X^- = \max(-X, 0)$. La variable es *integrable* si

$$\mathbb{E}|X| = \mathbb{E}X^+ + \mathbb{E}X^- < \infty; \quad \text{entonces} \quad \mathbb{E}X = \mathbb{E}X^+ - \mathbb{E}X^-.$$

La condición evita $\infty - \infty$. Si $X = \sum_{j=1}^m x_j \mathbf{1}_{A_j}$, donde $A_j = \{X = x_j\}$ forman una partición, la integral simple da

$$\mathbb{E}X = \sum_{j=1}^m x_j \mathbb{P}(A_j).$$

Las probabilidades pertenecen a las preimágenes A_j ; no se supone equiprobabilidad de los valores.

Observación (Recordatorio: convergencia monótona). Para $X \geq 0$ medible existen simples $0 \leq s_n \uparrow X$. El teorema de convergencia monótona afirma $\int s_n \, d\mathbb{P} \uparrow \int X \, d\mathbb{P}$. Es el mecanismo para extender identidades de indicadores a variables no negativas. Para variables integrables se trabaja con las partes positiva y negativa.

Teorema 2.2 (Fórmula de transferencia). Sea $\mu_X = \mathbb{P} \circ X^{-1}$. Si g es boreliana y $g(X) \geq 0$, o si $g(X)$ es integrable,

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \mu_X(dx).$$

Demostración. Para $g = \mathbf{1}_C$, ambos lados valen $\mathbb{P}(X \in C) = \mu_X(C)$. La linealidad extiende la identidad a simples. Para $g \geq 0$, elegir simples $s_n \uparrow g$ y aplicar convergencia monótona a $s_n(X)$ y a s_n . El caso integrable se obtiene restando las fórmulas de g^+ y g^- . $\square$

2.2. Propiedades, momentos y dos cálculos completos

Para variables integrables, la integral da linealidad, monotonía y $|\mathbb{E}X| \leq \mathbb{E}|X|$. Si $X \in L^2$,

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}X^2 - (\mathbb{E}X)^2, \quad \text{Var}(aX + b) = a^2 \text{Var}(X).$$

La expansión solo se usa después de comprobar $X \in L^2$. Cauchy–Schwarz implica $L^2 \subset L^1$ porque $\mathbb{E}|X| \leq (\mathbb{E}X^2)^{1/2}$.

Ejemplo 2.3 (Número de caras). En dos lanzamientos equilibrados, definimos $N(00) = 0$, $N(01) = N(10) = 1$ y $N(11) = 2$. Los eventos $A_k = \{N = k\}$ tienen probabilidades $1/4, 1/2, 1/4$. Por transferencia,

$$\mathbb{E}N = 0 \cdot \frac{1}{4} + 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} = 1, \quad \mathbb{E}N^2 = 0 + \frac{1}{2} + 4 \cdot \frac{1}{4} = \frac{3}{2}.$$

Así $\text{Var}(N) = 3/2 - 1 = 1/2$. No se asigna $1/3$ a los valores $0, 1, 2$.

Ejemplo 2.4 (Densidad triangular). En el modelo canónico con densidad $f(x) = 2x\mathbf{1}_{(0,1)}(x)$, la variable es $X(\omega) = \omega$. Antes de integrar se identifica su ley. Entonces

$$\mathbb{E}X = \int_0^1 2x^2 \, dx = \frac{2}{3}, \quad \mathbb{E}X^2 = \int_0^1 2x^3 \, dx = \frac{1}{2}, \quad \text{Var}(X) = \frac{1}{18}.$$

Proposición 2.5 (Cambio afín y suma). Si $X, Y \in L^2$, entonces

$$\text{Var}(X + Y) = \text{Var} X + \text{Var} Y + 2 \text{Cov}(X, Y), \quad \text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}X\mathbb{E}Y.$$

Demostración. Cauchy–Schwarz garantiza $XY \in L^1$. Se expande el producto centrado y luego el cuadrado de $(X - \mathbb{E}X) + (Y - \mathbb{E}Y)$; la linealidad de la esperanza identifica los términos. $\square$

2.3. Markov y Chebyshev

Teorema 2.6 (Markov). Si $Y \geq 0$ y $a > 0$, entonces $\mathbb{P}(Y \geq a) \leq \mathbb{E}Y/a$.

Demostración. Definir $A = \{Y \geq a\}$. Punto a punto, $a\mathbf{1}_A \leq Y$. Por monotonía,

$$a\mathbb{P}(A) = \mathbb{E}(a\mathbf{1}_A) \leq \mathbb{E}Y.$$

Se divide por $a > 0$. □

La cota es óptima: si $0 \leq m \leq a$, tomar $Y = a$ con probabilidad m/a y $Y = 0$ en otro caso. Entonces $\mathbb{E}Y = m$ y $\mathbb{P}(Y \geq a) = m/a$.

Corolario 2.7 (Chebyshev). Si $X \in L^2$ y $t > 0$,

$$\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \frac{\text{Var}(X)}{t^2}.$$

Demostración. El evento es $\{(X - \mathbb{E}X)^2 \geq t^2\}$. Se aplica Markov a la variable no negativa $(X - \mathbb{E}X)^2$. □

Ejemplo 2.8 (Tamaño muestral conservador). Sean $X_1, \dots, X_n$ independientes con media μ y varianza común σ^2 . La independencia, demostrada en la sesión 2, dará $\text{Var}(\bar{X}_n) = \sigma^2/n$. Para $E_\varepsilon = \{|\bar{X}_n - \mu| \geq \varepsilon\}$,

$$\mathbb{P}(E_\varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}.$$

Si $\sigma^2 \leq 4$ y se exige $\mathbb{P}(|\bar{X}_n - \mu| < 0.1) \geq 0.95$, basta $4/(0.01n) \leq 0.05$, es decir $n \geq 8000$. Es una garantía, no una aproximación normal.

Advertencias. Markov requiere no negatividad; Chebyshev, segundo momento. Las desigualdades acotan una probabilidad, no afirman que la variable esté acotada. Antes de aplicarlas se escribe el evento de cola.

2.4. Jensen y convexidad

Una función φ es convexa si queda debajo de sus cuerdas. En cada punto interior m admite una recta soporte: existe s con $\varphi(x) \geq \varphi(m) + s(x - m)$.

Teorema 2.9 (Jensen). *Si X es integrable, toma valores en el intervalo de convexidad de φ y $\varphi(X)$ es integrable, entonces*

$$\boxed{\varphi(\mathbb{E}X) \leq \mathbb{E}\varphi(X)}.$$

Demostración. Poner $m = \mathbb{E}X$ y elegir una recta soporte en m . Sustituir $x = X(\omega)$ e integrar:

$$\mathbb{E}\varphi(X) \geq \varphi(m) + s(\mathbb{E}X - m) = \varphi(m).$$

En un extremo se aproxima desde el interior o se observa que, si la media está en un extremo del intervalo soporte, X es constante c.s. □

Aplicando Jensen a $|x|$, x^2 , e^x y $1/x$ se obtienen, bajo las hipótesis correspondientes,

$$|\mathbb{E}X| \leq \mathbb{E}|X|, \text{quad}(\mathbb{E}|X|)^2 \leq \mathbb{E}X^2, \text{quade}^{\mathbb{E}X} \leq \mathbb{E}e^X, \text{quad}(\mathbb{E}X)^{-1} \leq \mathbb{E}(X^{-1}).$$

Si φ es estrictamente convexa, la igualdad implica que X es constante c.s.: la diferencia entre la función y su soporte es no negativa y solo se anula en el punto de contacto.

Ejemplo 2.10 (Promedio armónico). Si $X > 0$ representa una duración aleatoria y $\mathbb{E}X, \mathbb{E}(1/X) < \infty$, la convexidad de $1/x$ da

$$\frac{1}{\mathbb{E}X} \leq \mathbb{E}\frac{1}{X}.$$

No se invierte una esperanza como si fuera una constante; la desigualdad cuantifica precisamente la diferencia.

Cierre. La esperanza hereda su estructura de la integral. Markov convierte un momento en una cota de cola; Chebyshev usa el momento centrado de orden dos; Jensen compara transformar antes y después de promediar.

Sesión 2. Ley conjunta, independencia y convolución

Objetivo de la sesión. Pasar de marginales a leyes conjuntas y obtener la ley de una suma independiente.

2.5. Ley conjunta y marginales

Para variables X, Y en el mismo espacio, $Z = (X, Y)$ es una variable aleatoria en $\mathbb{R}^2$. Su ley conjunta es

$$\mu_{X,Y}(C) = \mathbb{P}((X, Y) \in C), \quad C \in \mathcal{B}(\mathbb{R}^2).$$

Las marginales se recuperan mediante

$$\mu_X(A) = \mu_{X,Y}(A \times \mathbb{R}), \quad \mu_Y(B) = \mu_{X,Y}(\mathbb{R} \times B).$$

Ejemplo 2.11 (Procedencia y defecto). Definimos $X \in \{1, 2\}$ como línea y $Y \in \{0, 1\}$ como estado, con $Y = 1$ para defecto. Los eventos $C_{ij} = \{X = i, Y = j\}$ tienen la tabla

	$Y = 0$	$Y = 1$	$\mathbb{P}(X = i)$
$X = 1$	0.588	0.012	0.600
$X = 2$	0.380	0.020	0.400
$\mathbb{P}(Y = j)$	0.968	0.032	1

Las filas y columnas son marginales. Por ejemplo, $\mathbb{P}(Y = 1) = 0.012 + 0.020$.

Proposición 2.12 (Transferencia vectorial). Si h es boreliana no negativa o $h(X, Y)$ es integrable,

$$\mathbb{E}h(X, Y) = \int_{\mathbb{R}^2} h(x, y) \mu_{X,Y}(\mathrm{d}x, \mathrm{d}y).$$

Demostración. Se verifica para indicadores de borelianos de $\mathbb{R}^2$, se extiende a simples y luego por convergencia monótona y partes positiva y negativa. $\square$

Las marginales no determinan la conjunta. Dos Bernoulli(1/2) pueden ser iguales c.s., opuestas c.s. o independientes; en esos casos $\mathbb{P}(X = Y)$ es 1, 0 o 1/2.

2.6. Independencia y recordatorio de Tonelli–Fubini

Definición 2.13. X, Y son independientes si para todos $A, B \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B).$$

Equivale a $\mu_{X,Y} = \mu_X \otimes \mu_Y$ y a la independencia de $\sigma(X)$ y $\sigma(Y)$.

Observación (Recordatorio: lema π - λ). Los rectángulos $A \times B$ forman un sistema π generador de $\mathcal{B}(\mathbb{R}^2)$. Si dos probabilidades coinciden en todos los rectángulos, coinciden en toda la σ -álgebra. Por ello basta verificar la factorización en una clase generadora, por ejemplo semirrectas $(-\infty, x] \times (-\infty, y]$.

Observación (Recordatorio: Tonelli y Fubini). Para espacios σ -finitos (S, μ) y (T, ν) :

- si $h \geq 0$ es medible, Tonelli permite intercambiar las integrales, aun con valor $+\infty$;
- si $\int |h| d(\mu \otimes \nu) < \infty$, Fubini afirma que las secciones son integrables c.t.p. y las integrales iteradas coinciden y son finitas.

En símbolos, bajo una de esas hipótesis,

$$\int h d(\mu \otimes \nu) = \int_S \int_T h(s, t) \nu(dt) \mu(ds) = \int_T \int_S h(s, t) \mu(ds) \nu(dt).$$

Antes de intercambiar integrales se declara: no negatividad para Tonelli o integrabilidad absoluta para Fubini.

En la tabla anterior, $A = \{X = 2\}$ y $B = \{Y = 1\}$ satisfacen

$$\mathbb{P}(A \cap B) = 0.020 \neq 0.40(0.032) = \mathbb{P}(A)\mathbb{P}(B),$$

por lo cual línea y defecto no son independientes. Un par refuta independencia; demostrarla requiere todos los eventos o una clase generadora.

2.7. Factorización y covarianza

Teorema 2.14 (Factorización). *Si X, Y son independientes y $f(X)g(Y) \geq 0$, o el producto es integrable,*

$$\boxed{\mathbb{E}[f(X)g(Y)] = \mathbb{E}f(X) \mathbb{E}g(Y).}$$

Demostración. La conjunta es $\mu_X \otimes \mu_Y$. Para producto no negativo, transferencia y Tonelli dan

$$\begin{aligned} \mathbb{E}[f(X)g(Y)] &= \iint f(x)g(y)\mu_X(\mathrm{d}x)\mu_Y(\mathrm{d}y) \\ &= \int f(x) \left(\int g(y)\mu_Y(\mathrm{d}y) \right) \mu_X(\mathrm{d}x). \end{aligned}$$

El último término factoriza. Si hay signo, se usa Fubini bajo integrabilidad absoluta. $\square$

Para $X, Y \in L^2$, la independencia implica $\mathrm{Cov}(X, Y) = 0$ y

$$\mathrm{Var}(X + Y) = \mathrm{Var} X + \mathrm{Var} Y.$$

El recíproco es falso.

Ejemplo 2.15 (Incorrelación sin independencia). Sea X uniforme en $\{-1, 0, 1\}$ y $Y = X^2$. Por simetría, $\mathbb{E}X = 0$ y $\mathbb{E}(XY) = \mathbb{E}X^3 = 0$, así que $\mathrm{Cov}(X, Y) = 0$. Sin embargo,

$$\mathbb{P}(X = 0, Y = 0) = \frac{1}{3} \neq \mathbb{P}(X = 0)\mathbb{P}(Y = 0) = \frac{1}{9}.$$

Además, Y es función no constante de X . La covarianza detecta asociación lineal, no toda dependencia.

Si X, Y son independientes y f, g son borelianas, entonces $f(X), g(Y)$ también lo son: las preimágenes de sus eventos pertenecen a $\sigma(X)$ y $\sigma(Y)$. Esta propiedad no exige momentos.

2.8. Convolución de medidas y densidades

Teorema 2.16 (Convolución). Si X, Y son independientes, para $C \in \mathcal{B}(\mathbb{R})$,

$$\mu_{X+Y}(C) = \int \mu_X(C - y) \mu_Y(dy).$$

Si tienen densidades f, g , una densidad de $X + Y$ es

$$(f * g)(z) = \int_{\mathbb{R}} f(z - y)g(y) dy.$$

Demostración. Para $E_C = \{X + Y \in C\}$, independencia y Tonelli aplicados a $\mathbf{1}_C(x + y)$ dan

$$\mathbb{P}(E_C) = \iint \mathbf{1}_C(x + y) \mu_X(dx) \mu_Y(dy) = \int \mu_X(C - y) \mu_Y(dy).$$

Con densidades, se sustituye y se hace $z = x + y$ en la integral interior; Tonelli permite reorganizarla como $\int_C (f * g)(z) dz$. $\square$

Ejemplo 2.17 (Poisson). Para $X \sim \text{Pois}(\lambda)$, $Y \sim \text{Pois}(\mu)$ independientes, el evento $\{X + Y = n\}$ se descompone según $X = k$. Así

$$\mathbb{P}(X + Y = n) = e^{-(\lambda+\mu)} \frac{1}{n!} \sum_{k=0}^n \binom{n}{k} \lambda^k \mu^{n-k} = e^{-(\lambda+\mu)} \frac{(\lambda + \mu)^n}{n!}.$$

Luego $X + Y \sim \text{Pois}(\lambda + \mu)$.

Ejemplo 2.18 (Exponenciales). Si $X \sim \text{Exp}(\lambda)$ y $Y \sim \text{Exp}(\mu)$ son independientes, $\lambda \neq \mu$, el soporte impone $0 < y < z$ cuando $z > 0$. Por tanto

$$f_{X+Y}(z) = \int_0^z \lambda e^{-\lambda(z-y)} \mu e^{-\mu y} dy = \frac{\lambda \mu}{\lambda - \mu} (e^{-\mu z} - e^{-\lambda z})$$

para $z > 0$, y vale cero para $z \leq 0$. Si $\lambda = \mu$, el límite es $\lambda^2 z e^{-\lambda z} \mathbf{1}_{(0, \infty)}(z)$.

Cierre. La conjunta contiene la información simultánea. La independencia la convierte en producto; Tonelli–Fubini permite separar integrales; la convolución traduce sumas de variables en una operación sobre sus leyes.

Lecturas

Durrett, §1.3; Saporta, capítulos 1–2; Sheffield, clases 2–3. Estas notas emplean siempre $F_X(x) = \mathbb{P}(X \leq x)$.



Notas · Semana 3

Teoría de la Probabilidad · CM4H1

Transformaciones, familias, vectores y muestras

Oswaldo Velásquez Castañón

Profesor Principal · Escuela Profesional de Matemática

Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 3

Transformar variables y organizar información multivariada

Propósito. La sesión 1 obtiene leyes por preimágenes y por cambio de variables, y presenta distribuciones básicas como modelos generadores. La sesión 2 desarrolla vectores aleatorios, matrices de covarianza y las identidades fundamentales de una muestra i.i.d. Las distribuciones complementarias se practican en ejercicios; no se convierten en un catálogo de fórmulas.

Recordatorios de medida. Medida imagen, integración respecto de una ley, función inversa generalizada, cambio de variables en integrales de Lebesgue, Tonelli–Fubini y Cauchy–Schwarz. Se enuncian en el punto exacto donde se emplean.

Sesión 1. Transformaciones y modelos fundamentales

Objetivo de la sesión. Obtener la ley de $Y = g(X)$ desde sus preimágenes y reconocer mecanismos que producen familias probabilísticas.

3.1. La ley transformada se obtiene por preimágenes

Sea $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ una variable y $g : \mathbb{R} \rightarrow \mathbb{R}$ boreliana. Definimos $Y = g(X)$. Para cada boreliano B ,

$$\mu_Y(B) = \mathbb{P}(Y \in B) = \mathbb{P}(X \in g^{-1}(B)) = \mu_X(g^{-1}(B)).$$

Esta identidad es el punto de partida; una fórmula con derivadas solo es una consecuencia cuando g posee regularidad suficiente.

Proposición 3.1 (Transformación monótona). *Supongamos que g es estrictamente creciente y continua en un intervalo I que contiene a X c.s. Entonces, para $y \in g(I)$,*

$$F_Y(y) = F_X(g^{-1}(y)).$$

Si g es estrictamente decreciente y X no tiene átomos,

$$F_Y(y) = 1 - F_X(g^{-1}(y)).$$

En presencia de átomos debe conservarse el extremo correcto: $\mathbb{P}(X \geq a) = 1 - F_X(a-)$.

Demostración. Si g crece, $\{g(X) \leq y\} = \{X \leq g^{-1}(y)\}$. Si decrece, el evento es $\{X \geq g^{-1}(y)\}$; su probabilidad es $1 - \mathbb{P}(X < g^{-1}(y)) = 1 - F_X(g^{-1}(y)-)$. Cuando no hay átomos, $F_X(a-) = F_X(a)$. $\square$

Ejemplo 3.2 (De uniforme a exponencial). Sea U uniforme en $(0, 1)$ y $Y = -\log U$. Antes de derivar se determina el soporte: $Y > 0$. Para $y \geq 0$,

$$\{Y \leq y\} = \{-\log U \leq y\} = \{U \geq e^{-y}\}.$$

Por tanto $F_Y(y) = 1 - e^{-y}$ y $f_Y(y) = e^{-y} \mathbf{1}_{(0, \infty)}(y)$. Así $Y \sim \text{Exp}(1)$.

Observación (Recordatorio: cambio unidimensional). Si g es C^1 , estrictamente monótona y $g'(x) \neq 0$, y X tiene densidad f_X , entonces

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

en $g(I)$. Es el teorema de cambio de variables aplicado a $\int_{g^{-1}(B)} f_X(x) dx$; no se memoriza sin especificar soporte e inversa.

3.2. Transformaciones no inyectivas y varias ramas

Cuando g no es inyectiva, el evento $\{g(X) \in B\}$ reúne todas las ramas inversas. Si para casi todo y las soluciones de $g(x) = y$ son $x_1(y), \dots, x_r(y)$ y $g'(x_j(y)) \neq 0$, entonces

$$f_Y(y) = \sum_{j=1}^r \frac{f_X(x_j(y))}{|g'(x_j(y))|}.$$

Ejemplo 3.3 (Cuadrado de una normal). Sea $X \sim N(0, 1)$ y $Y = X^2$. El soporte es $[0, \infty)$. Para $y > 0$, las ramas son $x_1 = \sqrt{y}$ y $x_2 = -\sqrt{y}$, con derivadas inversas de módulo $1/(2\sqrt{y})$. Como la densidad normal ϕ es par,

$$f_Y(y) = \frac{\phi(\sqrt{y}) + \phi(-\sqrt{y})}{2\sqrt{y}} = \frac{e^{-y/2}}{\sqrt{2\pi y}}, \quad y > 0.$$

Esta es la ley χ_1^2 . También puede obtenerse primero

$$F_Y(y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) = 2\Phi(\sqrt{y}) - 1$$

y derivar. Ambas rutas empiezan por el mismo evento.

Ejemplo 3.4 (Valor absoluto y un átomo). Si X tiene una masa p en cero y densidad f fuera de cero, $Y = |X|$ conserva la masa p en cero. Para $y > 0$ su parte absolutamente continua tiene densidad $f(y) + f(-y)$. La fórmula de ramas no debe borrar el átomo: una densidad describe solo la parte continua.

Observación (Recordatorio: cambio de variables en $\mathbb{R}^d$). Si $T : U \rightarrow V$ es un difeomorfismo C^1 entre abiertos y Z tiene densidad f_Z en U , entonces $W = T(Z)$ tiene

$$f_W(w) = f_Z(T^{-1}(w)) |\det DT^{-1}(w)|, \text{ para } w \in V.$$

Si hay varias ramas inyectivas, se suman sus contribuciones. Deben identificarse dominio, imagen, ramas y jacobiano antes de integrar.

Error típico. Escribir $f_Y(y) = f_X(g^{-1}(y)) |(g^{-1})'(y)|$ para $g(x) = x^2$ conserva solo una rama y pierde la mitad de la masa.

3.3. Modelos básicos y mecanismos que los producen

Las familias se introducen por el experimento que representan.

- $B \sim \text{Bernoulli}(p)$ registra éxito o fracaso: $\mathbb{P}(B = 1) = p$.
- $S_n = \sum_{i=1}^n B_i$ para Bernoulli independientes tiene ley binomial:

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

La demostración cuenta los subconjuntos de k éxitos y usa independencia para cada patrón.

- $N \sim \text{Poisson}(\lambda)$ modela conteos con masa $e^{-\lambda} \lambda^k / k!$. La suma independiente conserva la familia y suma parámetros.
- $T \sim \text{Exp}(\lambda)$ modela un tiempo sin memoria:

$$\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t) = e^{-\lambda t}.$$

- $X \sim N(\mu, \sigma^2)$ surge por estandarización $X = \mu + \sigma Z$. Su tratamiento vectorial se reserva para las semanas 10–11.

Proposición 3.5 (Caracterización de la falta de memoria). *Si $T \geq 0$, $\mathbb{P}(T > t) > 0$ y su supervivencia $G(t) = \mathbb{P}(T > t)$ es continua, entonces*

$$\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t)$$

para $s, t \geq 0$ si y solo si $G(t) = e^{-\lambda t}$ para algún $\lambda \geq 0$.

Demostración. La propiedad equivale a $G(s+t) = G(s)G(t)$. Como G es continua, positiva, no creciente y $G(0) = 1$, $h(t) = -\log G(t)$ es continua y aditiva en $[0, \infty)$. La ecuación de Cauchy continua da $h(t) = \lambda t$. $\square$

Ejemplo 3.6 (Mínimo de tiempos exponenciales). Si $T_1, \dots, T_n$ son exponenciales independientes de tasas λ_i y $M = \min_i T_i$, entonces

$$\{M > t\} = \bigcap_i \{T_i > t\}, \text{ y } \mathbb{P}(M > t) = \prod_i e^{-\lambda_i t} = e^{-t \sum_i \lambda_i}.$$

Así $M \sim \text{Exp}(\sum_i \lambda_i)$. La identidad entre eventos precede al producto.

Las leyes gamma, beta, geométrica y multinomial aparecen en la lista autónoma como extensiones de estos mecanismos.

3.4. Transformación integral de probabilidad y cuantiles

Sea F una función de distribución y

$$Q(u) = \inf\{x : F(x) \geq u\}, \quad 0 < u < 1.$$

La semana 1 probó la equivalencia $Q(u) \leq x \iff u \leq F(x)$.

Teorema 3.7 (Método de la inversa). *Si $U \sim \text{Unif}(0, 1)$, entonces $Q(U)$ tiene función de distribución F .*

Demostración. Para cada x ,

$$\mathbb{P}(Q(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

La inversa generalizada funciona aunque F tenga saltos o intervalos planos. $\square$

Proposición 3.8 (Transformación integral). *Si X tiene función de distribución continua F_X , entonces $F_X(X)$ es uniforme en $(0, 1)$ cuando F_X es estrictamente creciente en el soporte. En general, la afirmación requiere una aleatorización dentro de los saltos.*

Demostración. En el caso estrictamente creciente, para $0 < u < 1$,

$$\{F_X(X) \leq u\} = \{X \leq F_X^{-1}(u)\},$$

y su probabilidad es u . Si hay saltos, $F_X(X)$ concentra masa y no puede ser uniforme; esta observación explica la hipótesis. $\square$

Ejemplo 3.9 (Simulación conceptual). Para generar una exponencial de tasa λ a partir de U uniforme, resolvemos

$$u = 1 - e^{-\lambda x} \implies x = -\frac{1}{\lambda} \log(1 - u).$$

Como $1 - U$ también es uniforme, suele usarse $X = -\lambda^{-1} \log U$. Esto es una construcción probabilística, no solo una receta computacional.

Cierre de la sesión. Para transformar una variable: definir Y , hallar su soporte, traducir $\{Y \leq y\}$ o $\{Y \in B\}$ a un evento de X , y solo después derivar o usar jacobianos.

Sesión 2. Vectores, covarianza y muestras i.i.d.

Objetivo de la sesión. Organizar momentos multivariados y demostrar las identidades de media y varianza muestral.

3.5. Vectores aleatorios y leyes conjuntas

Un vector $X = (X_1, \dots, X_d)^T$ es medible de $(\Omega, \mathcal{F})$ a $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ si y solo si cada coordenada es medible. Su ley conjunta determina las marginales, pero no a la inversa.

La función de distribución conjunta es

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d).$$

En dimensión dos, las probabilidades de rectángulos se obtienen por incrementos:

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F(b, d) - F(a, d) \\ &\quad - F(b, c) + F(a, c). \end{aligned}$$

Los extremos deben ajustarse con límites izquierdos si hay átomos.

Observación (Recordatorio: Tonelli para marginalizar). Si (X, Y) tiene densidad conjunta $f_{X,Y} \geq 0$, entonces

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) dy, \text{ y } f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx.$$

Tonelli justifica las integrales iteradas por no negatividad. Antes de calcular se determina el soporte de la conjunta; integrar sobre un rectángulo incorrecto cambia la marginal.

Ejemplo 3.10 (Densidad en un triángulo). Sea $f(x, y) = 2\mathbf{1}_{\{0 < x < y < 1\}}$. La constante es correcta porque el triángulo tiene área $1/2$. Para $0 < x < 1$, y recorre $(x, 1)$, luego

$$f_X(x) = \int_x^1 2 dy = 2(1 - x).$$

Para $0 < y < 1$, x recorre $(0, y)$ y $f_Y(y) = 2y$. Las marginales son distintas aunque la densidad conjunta sea constante sobre su soporte.

3.6. Media vectorial y matriz de covarianza

Si cada coordenada es integrable, $m = \mathbb{E}X = (\mathbb{E}X_1, \dots, \mathbb{E}X_d)^T$. Si están en L^2 , se define

$$\Sigma = \text{Cov}(X) = \mathbb{E}[(X - m)(X - m)^T], \text{ y } \Sigma_{ij} = \text{Cov}(X_i, X_j).$$

Proposición 3.11. Σ es simétrica y semidefinida positiva. Para toda matriz A y vector b ,

$$\mathbb{E}(AX + b) = Am + b, \text{ y } \text{Cov}(AX + b) = A\Sigma A^T.$$

Demostración. La simetría es inmediata. Para $a \in \mathbb{R}^d$,

$$a^T \Sigma a = \mathbb{E}[a^T (X - m)(X - m)^T a] = \mathbb{E}[(a^T (X - m))^2] = \text{Var}(a^T X) \geq 0.$$

La transformación de la media usa linealidad; para la covarianza se sustituye $AX + b - (Am + b) = A(X - m)$ y se extraen las matrices constantes. $\square$

Corolario 3.12. Σ es singular si y solo si existe $a \neq 0$ tal que $a^T X$ es constante c.s.

Demostración. Si Σ es singular y semidefinida positiva, existe $a \neq 0$ con $a^T \Sigma a = 0$. La identidad anterior da $\text{Var}(a^T X) = 0$, equivalente a $a^T X = \mathbb{E}(a^T X)$ c.s. El recíproco sigue en reversa. $\square$

Ejemplo 3.13. Para $Z = (X + Y, X - Y)^T = AX$, con $A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$, se tiene $\text{Cov}(Z) = A\Sigma A^T$. En particular,

$$\text{Cov}(X + Y, X - Y) = \text{Var } X - \text{Var } Y.$$

La covarianza puede anularse sin que las dos combinaciones sean independientes, salvo bajo hipótesis adicionales como gaussianidad conjunta.

3.7. Muestras i.i.d. y media muestral

Una muestra aleatoria $X_1, \dots, X_n$ de una ley P significa que las variables son independientes e idénticamente distribuidas. No significa que los valores observados sean distintos ni que se conozcan los parámetros de P .

Si $\mathbb{E}X_1 = \mu$ y $\text{Var}(X_1) = \sigma^2 < \infty$, la media

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

satisface

$$\mathbb{E}\bar{X}_n = \mu, \text{ y } \text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_i \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

La segunda igualdad usa que las covarianzas cruzadas son cero por independencia.

Ejemplo 3.14 (Muestra Bernoulli). Si X_i indica éxito con probabilidad p , entonces $\bar{X}_n$ es la proporción de éxitos. Su media es p y su varianza $p(1-p)/n$. Chebyshev da

$$\mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}.$$

La última cota es uniforme en p porque $p(1-p) \leq 1/4$.

Proposición 3.15 (Covarianzas con la media). *Para una muestra i.i.d. con segundo momento,*

$$\text{Cov}(X_i, \bar{X}_n) = \frac{\sigma^2}{n}, \text{ y } \text{Cov}(X_i - \bar{X}_n, \bar{X}_n) = 0.$$

Demostración. Por bilinealidad,

$$\text{Cov}(X_i, \bar{X}_n) = \frac{1}{n} \sum_j \text{Cov}(X_i, X_j) = \frac{\sigma^2}{n},$$

porque los términos con $j \neq i$ se anulan. Restar $\text{Var}(\bar{X}_n) = \sigma^2/n$ prueba la segunda identidad. $\square$

La incorrelación entre residuos y media no implica todavía independencia. En una muestra normal sí la implicará, pero esa demostración requiere la estructura gaussiana de las semanas 10–11.

3.8. Varianza muestral y descomposición de cuadrados

Definimos

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \text{ para } n \geq 2.$$

El denominador $n-1$ se deduce de una identidad, no es una convención arbitraria.

Teorema 3.16 (Descomposición de suma de cuadrados). *Para cualquier constante a ,*

$$\sum_{i=1}^n (X_i - a)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - a)^2.$$

Demostración. Escribir $X_i - a = (X_i - \bar{X}_n) + (\bar{X}_n - a)$ y expandir. El término cruzado es

$$2(\bar{X}_n - a) \sum_i (X_i - \bar{X}_n) = 0.$$

□

Corolario 3.17 (Insensatez). *Si la muestra es i.i.d. con varianza $\sigma^2 < \infty$, entonces $\mathbb{E}S_n^2 = \sigma^2$.*

Demostración. Tomar $a = \mu$ y esperanzas. El lado izquierdo tiene esperanza $n\sigma^2$. Además,

$$\mathbb{E}[n(\bar{X}_n - \mu)^2] = n \text{Var}(\bar{X}_n) = \sigma^2.$$

Por tanto $\mathbb{E} \sum_i (X_i - \bar{X}_n)^2 = (n-1)\sigma^2$ y dividir por $n-1$ concluye. □

Observación. La prueba solo exige independencia, igualdad de leyes y segundo momento. La distribución de S_n^2 y su independencia respecto de $\bar{X}_n$ requieren normalidad y se estudiarán en la semana 11.

Cierre. Las transformaciones se resuelven por preimágenes; los jacobianos son una herramienta derivada. En vectores, la covarianza se organiza como una matriz semidefinida positiva. En muestras i.i.d., las identidades de media y varianza preparan las leyes de los grandes números y el TCL.

Lecturas

Saporta, capítulos 2–4; Durrett, §1.3; Sheffield, clases 2–3. Las familias no desarrolladas en teoría quedan como ejercicios de transformación y reconocimiento de mecanismos.



Notas · Semana 4

Teoría de la Probabilidad · CM4H1

Modos de convergencia y Borel–Cantelli

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 4

Aproximaciones probabilísticas y eventos que se repiten

Propósito. La primera sesión distingue convergencia casi segura, en probabilidad y en L^p , demuestra sus implicaciones y obtiene la ley débil con varianza finita. La segunda traduce “infinitas veces” al lenguaje de eventos límite y demuestra ambos lemas de Borel–Cantelli.

Recordatorios de medida. Continuidad de medidas finitas, convergencia dominada para indicadores, Fatou, convergencia monótona y operaciones $\limsup$ / $\liminf$ de conjuntos. Cada resultado se enuncia antes de aplicarse.

Sesión 1. Convergencias probabilísticas

Objetivo de la sesión. Comparar convergencia casi segura, en probabilidad y en L^p , con pruebas y contraejemplos.

4.1. Definiciones y lectura de los cuantificadores

Sean X_n, X variables en un mismo espacio de probabilidad.

Definición 4.1. I) $X_n \rightarrow X$ *casi seguramente* si

$$\mathbb{P}\{\omega : X_n(\omega) \rightarrow X(\omega)\} = 1.$$

II) $X_n \rightarrow X$ *en probabilidad* si para todo $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0.$$

III) Para $p > 0$, $X_n \rightarrow X$ en L^p si

$$\mathbb{E}|X_n - X|^p \rightarrow 0.$$

Cuando $p \geq 1$ esta expresión proviene de una norma; para $0 < p < 1$ sigue definiendo una convergencia útil, aunque no una norma.

La convergencia casi segura sigue trayectorias para casi todo ω . La convergencia en probabilidad permite que el conjunto excepcional cambie con n . La convergencia L^p controla el tamaño promedio del error elevado a p .

Ejemplo 4.2 (Eventos decrecientes). En $([0, 1], \mathcal{B}, \lambda)$, sea $X_n = \mathbf{1}_{(0, 1/n)}$. Para todo $\omega > 0$, eventualmente $\omega \notin (0, 1/n)$; por tanto $X_n \rightarrow 0$ c.s. Además

$$\mathbb{P}(|X_n| > \varepsilon) = \frac{1}{n} \quad (0 < \varepsilon < 1), \quad \mathbb{E}|X_n|^p = \frac{1}{n}.$$

Aquí coinciden los tres modos, pero por razones distintas.

Observación (Recordatorio: casi seguramente). Una afirmación puntual puede fallar en un conjunto nulo. No se borra ese conjunto antes de verificar que es medible. En un espacio completo, todo subconjunto de un nulo es medible; en general se formula el evento medible donde ocurre la convergencia.

4.2. Implicaciones y unicidad

Teorema 4.3. Para $p > 0$:

$$X_n \rightarrow X \text{ en } L^p \implies X_n \rightarrow X \text{ en probabilidad.}$$

Además,

$$X_n \rightarrow X \text{ c.s.} \implies X_n \rightarrow X \text{ en probabilidad.}$$

Demostración. Para la primera implicación, fijar $\varepsilon > 0$ y aplicar Markov a $|X_n - X|^p$:

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}|X_n - X|^p}{\varepsilon^p} \rightarrow 0.$$

Para la segunda, sea $I_n = \mathbf{1}_{\{|X_n - X| > \varepsilon\}}$. La convergencia c.s. implica $I_n \rightarrow 0$ c.s. y $0 \leq I_n \leq 1$. Por convergencia dominada,

$$\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{E}I_n \rightarrow 0.$$

□

Observación (Recordatorio: convergencia dominada). Si $Z_n \rightarrow Z$ c.s. y $|Z_n| \leq G$ con $G \in L^1$, entonces $\mathbb{E}|Z_n - Z| \rightarrow 0$ y $\mathbb{E}Z_n \rightarrow \mathbb{E}Z$. En la prueba anterior el dominante es $G = 1$ y se aplica a indicadores; la finitud de $\mathbb{P}(\Omega)$ es esencial para que $1 \in L^1$.

Proposición 4.4 (Unicidad del límite en probabilidad). Si $X_n \rightarrow X$ y $X_n \rightarrow Y$ en probabilidad, entonces $X = Y$ c.s.

Demostración. Para $\varepsilon > 0$,

$$\{|X - Y| > \varepsilon\} \subset \{|X - X_n| > \varepsilon/2\} \cup \{|X_n - Y| > \varepsilon/2\}.$$

Las probabilidades del lado derecho tienden a cero, de modo que $\mathbb{P}(|X - Y| > \varepsilon) = 0$. Intersectando los eventos $\{|X - Y| \leq 1/m\}$ para $m \geq 1$ se obtiene $X = Y$ c.s. □

Proposición 4.5 (Subsucesión casi segura). Si $X_n \rightarrow X$ en probabilidad, existe una subsucesión $X_{n_k} \rightarrow X$ c.s.

Demostración. Elegir n_k creciente con $\mathbb{P}(|X_{n_k} - X| > 2^{-k}) \leq 2^{-k}$. Como la suma es finita, Borel-Cantelli I, que se probará en la sesión 2, implica que solo ocurren finitos de esos eventos. Luego $|X_{n_k} - X| \leq 2^{-k}$ eventualmente, c.s. □

4.3. Contraejemplos: por qué no hay recíprocos

Ejemplo 4.6 (Casi segura sin L^1). En $(0, 1)$ uniforme, sea $X_n = n\mathbf{1}_{(0, 1/n)}$. Para cada $\omega > 0$, $X_n(\omega) = 0$ eventualmente, así que $X_n \rightarrow 0$ c.s. Sin embargo,

$$\mathbb{E}|X_n| = n\lambda(0, 1/n) = 1,$$

y no hay convergencia L^1 . La masa se concentra en conjuntos pequeños mientras su altura crece.

Ejemplo 4.7 (En probabilidad sin casi segura: máquina de escribir). Enumeremos por niveles los intervalos diádicos

$$I_{m,k} = [k2^{-m}, (k+1)2^{-m}), \quad 0 \leq k < 2^m,$$

y sea X_n el indicador del n -ésimo intervalo de la enumeración. Su longitud tiende a cero, por lo que $\mathbb{P}(X_n = 1) \rightarrow 0$ y $X_n \rightarrow 0$ en probabilidad. Pero cada $\omega \in [0, 1)$ pertenece a exactamente un intervalo de cada nivel: $X_n(\omega) = 1$ infinitas veces y 0 infinitas veces. No existe límite puntual.

Ejemplo 4.8 (L^1 sin casi segura). La misma máquina de escribir satisface $\mathbb{E}|X_n| = \lambda(I_n) \rightarrow 0$, de modo que converge a cero en L^1 , pero no c.s.

Observación (De L^q a L^p en probabilidad). Si $0 < p < q$ y $\mathbb{P}(\Omega) = 1$, Jensen o Hölder da

$$\|Z\|_p \leq \|Z\|_q.$$

Por tanto L^q -convergencia implica L^p -convergencia. Este resultado depende de que la medida total sea finita.

Mapa correcto.

$$L^p \implies \mathbb{P}, \quad \text{c.s.} \implies \mathbb{P},$$

pero L^p y c.s. no son comparables sin hipótesis adicionales. Convergencia en probabilidad solo garantiza una subsucesión c.s.

4.4. Primera ley débil de los grandes números

Teorema 4.9 (Ley débil con varianza finita). Sean $X_1, X_2, \dots$ i.i.d., con $\mathbb{E}X_1 = \mu$ y $\text{Var}(X_1) = \sigma^2 < \infty$. Entonces

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow \mu \quad \text{en probabilidad.}$$

Demostración. La independencia anula covarianzas y da

$$\mathbb{E}\bar{X}_n = \mu, \text{ y } \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Para $\varepsilon > 0$, Chebyshev produce

$$\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

□

Ejemplo 4.10 (Frecuencia de un evento). Sea A un evento repetido independientemente y $X_i = \mathbf{1}_{A_i}$, con $\mathbb{P}(A_i) = p$. Entonces

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{A_i}$$

es la frecuencia relativa. Como $\text{Var}(X_i) = p(1-p)$,

$$\mathbb{P}(|\bar{X}_n - p| > \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}.$$

La probabilidad del modelo no se define como frecuencia; la ley débil demuestra que la frecuencia se aproxima a ella en probabilidad.

Observación. La hipótesis de segundo momento es suficiente, no óptima. La ley débil vale para i.i.d. integrables mediante truncamiento. Esa prueba se relaciona con la ley fuerte de la semana 5.

Cierre de la sesión. Los modos de convergencia responden a preguntas distintas. Las implicaciones se prueban mediante Markov o convergencia dominada; los contraejemplos muestran por qué no deben invertirse.

Sesión 2. Eventos límite y lemas de Borel–Cantelli

Objetivo de la sesión. Traducir ocurrencias infinitas a operaciones de conjuntos y decidir cuándo se repiten eventos.

4.5. Límites superior e inferior de eventos

Para eventos A_n se definen

$$\limsup_n A_n = \bigcap_{m \geq 1} \bigcup_{n \geq m} A_n, \quad \liminf_n A_n = \bigcup_{m \geq 1} \bigcap_{n \geq m} A_n.$$

Un resultado ω pertenece a $\limsup A_n$ si pertenece a infinitos A_n ; pertenece a $\liminf A_n$ si pertenece a todos salvo finitos.

Escribiremos

$$\{A_n \text{ i.o.}\} := \limsup_n A_n.$$

Por De Morgan,

$$(\limsup A_n)^c = \liminf A_n^c, \text{ y } (\liminf A_n)^c = \limsup A_n^c.$$

Ejemplo 4.11. Si $A_n = (0, 1/n)$ en $[0, 1]$, ningún $\omega > 0$ pertenece a infinitos A_n y 0 no pertenece a ninguno por el extremo abierto; entonces $\limsup A_n = \emptyset$. Si $A_n = [0, 1/n]$, el límite superior es $\{0\}$.

Observación (Recordatorio: continuidad desde arriba). Los eventos $B_m = \bigcup_{n \geq m} A_n$ decrecen y

$$\bigcap_m B_m = \limsup A_n.$$

Como $\mathbb{P}(B_1) \leq 1 < \infty$, continuidad desde arriba da

$$\mathbb{P}(A_n \text{ i.o.}) = \lim_{m \rightarrow \infty} \mathbb{P}\left(\bigcup_{n \geq m} A_n\right).$$

Esta identidad es el puente hacia Borel–Cantelli I.

4.6. Primer lema de Borel–Cantelli

Teorema 4.12 (Borel–Cantelli I). Si $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, entonces

$$\mathbb{P}(A_n \text{ i.o.}) = 0.$$

No se requiere independencia.

Demostración. Para todo m , subaditividad da

$$\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n).$$

La cola de una serie convergente tiende a cero. Por continuidad desde arriba de los eventos de cola,

$$\mathbb{P}(A_n \text{ i.o.}) = \lim_m \mathbb{P}\left(\bigcup_{n \geq m} A_n\right) = 0.$$

□

Corolario 4.13. Si para todo $\varepsilon > 0$,

$$\sum_n \mathbb{P}(|X_n - X| > \varepsilon) < \infty,$$

entonces $X_n \rightarrow X$ c.s. Esta propiedad se llama *convergencia completa*.

Demostración. Aplicar Borel–Cantelli I a $A_n^{(m)} = \{|X_n - X| > 1/m\}$. Para cada m , solo ocurren finitos. Intersectar los eventos de probabilidad uno sobre $m \in \mathbb{N}$ da convergencia puntual. □

Ejemplo 4.14 (Momento sumable). Si $p > 0$ y $\sum_n \mathbb{E}|X_n|^p < \infty$, entonces para $\varepsilon > 0$, Markov da

$$\sum_n \mathbb{P}(|X_n| > \varepsilon) \leq \varepsilon^{-p} \sum_n \mathbb{E}|X_n|^p < \infty.$$

Por el corolario, $X_n \rightarrow 0$ c.s.

El recíproco es falso: puede haber solo finitas ocurrencias c.s. aunque la suma de probabilidades diverja, si los eventos dependen fuertemente unos de otros.

4.7. Segundo lema de Borel–Cantelli

Teorema 4.15 (Borel–Cantelli II). *Si los eventos A_n son independientes y*

$$\sum_n \mathbb{P}(A_n) = \infty,$$

entonces $\mathbb{P}(A_n \text{ i.o.}) = 1$.

Demostración. Fijemos m y consideremos que no ocurra ninguno entre m y N . Por independencia,

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N (1 - \mathbb{P}(A_n)) \leq \exp\left(-\sum_{n=m}^N \mathbb{P}(A_n)\right),$$

donde se usó $1 - x \leq e^{-x}$. La suma parcial desde m diverge, así que el lado derecho tiende a cero. Continuidad desde arriba da

$$\mathbb{P}\left(\bigcap_{n \geq m} A_n^c\right) = 0.$$

Por tanto, con probabilidad uno ocurre al menos un A_n después de cada m , que es exactamente ocurrir infinitas veces. $\square$

Observación. La independencia se usa al convertir la probabilidad de la intersección finita en producto. Independencia por pares no basta en esta prueba. Existen extensiones con dependencias controladas, pero no forman parte de esta semana.

Ejemplo 4.16 (Bernoulli raras). Sean X_n Bernoulli independientes con $\mathbb{P}(X_n = 1) = 1/n$. Como $\sum 1/n = \infty$,

$$\mathbb{P}(X_n = 1 \text{ i.o.}) = 1.$$

Sin embargo, $X_n \rightarrow 0$ en probabilidad porque $\mathbb{P}(|X_n| > 1/2) = 1/n \rightarrow 0$. Este ejemplo separa de nuevo convergencia en probabilidad de convergencia c.s.

4.8. Aplicaciones y estrategia de uso

Ejemplo 4.17 (Umbral logarítmico). Sean X_n exponenciales independientes de tasa 1 y $A_n = \{X_n > c \log n\}$. Entonces

$$\mathbb{P}(A_n) = e^{-c \log n} = n^{-c}.$$

Si $c > 1$, la serie converge y Borel–Cantelli I da solo finitas superaciones. Si $0 < c \leq 1$, diverge y la independencia permite Borel–Cantelli II: hay infinitas superaciones c.s.

Ejemplo 4.18 (Control c.s. desde momentos). Si $\mathbb{E}|X_n|^p \leq Cn^{-1-\delta}$, con $p, \delta > 0$, para cualquier $\varepsilon > 0$,

$$\sum_n \mathbb{P}(|X_n| > \varepsilon) \leq C\varepsilon^{-p} \sum_n n^{-1-\delta} < \infty.$$

Luego $X_n \rightarrow 0$ c.s. El patrón es: momento $\rightarrow$ Markov $\rightarrow$ serie de probabilidades $\rightarrow$ Borel–Cantelli.

Guía de decisión.

1. Traducir la afirmación a eventos A_n .
2. Calcular o acotar $\mathbb{P}(A_n)$.
3. Decidir si $\sum \mathbb{P}(A_n)$ converge o diverge.
4. Si converge, usar BC I sin pedir independencia.
5. Si diverge, verificar independencia antes de BC II.
6. Traducir “solo finitos” o “infinitos” de regreso a la afirmación sobre variables.

Cierre. Borel–Cantelli convierte sumabilidad en información casi segura. El primer lema elimina ocurrencias repetidas; el segundo, bajo independencia, las garantiza.

Lecturas

Durrett, §2.3; Sheffield, clases 4–5; Saporta, capítulo 3 para convergencias. Los recordatorios de convergencia dominada y continuidad de medidas provienen del curso de Teoría de la Medida.



Notas · Semana 5

Teoría de la Probabilidad · CM4H1

Máximos, series independientes y ley fuerte

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 5

Del control de máximos a la convergencia casi segura

Propósito. La sesión 1 demuestra la desigualdad maximal de Kolmogorov y la usa para convertir varianzas sumables en convergencia de series. La sesión 2 desarrolla suma por partes, truncamiento y la ley fuerte i.i.d. bajo la hipótesis óptima $\mathbb{E}|X_1| < \infty$.

Recordatorios de medida. Completitud de L^2 , Fatou, convergencia dominada, Borel–Cantelli I, Tonelli para series no negativas y la relación entre integrabilidad y suma de probabilidades de cola.

Sesión 1. Máximos y series independientes

Objetivo de la sesión. Demostrar una desigualdad maximal y deducir convergencia casi segura de series con varianzas sumables.

5.1. Sumas parciales y el evento de primer cruce

Sean $X_1, \dots, X_n$ independientes, centradas y en L^2 . Definimos

$$S_k = \sum_{j=1}^k X_j, \text{ y } S_0 = 0.$$

Para controlar simultáneamente todos los S_k no basta aplicar Chebyshev a cada uno y sumar: esa ruta produciría $\sum_{k \leq n} \text{Var}(S_k)$, generalmente mucho mayor que $\text{Var}(S_n)$. La idea correcta clasifica cada trayectoria por el primer instante en que cruza el umbral.

Fijado $\lambda > 0$, definimos

$$A_k = \{|S_1| < \lambda, \dots, |S_{k-1}| < \lambda, |S_k| \geq \lambda\}.$$

Los A_k son disjuntos y

$$\bigcup_{k=1}^n A_k = \left\{ \max_{1 \leq k \leq n} |S_k| \geq \lambda \right\}.$$

Además, A_k y S_k dependen solo de $X_1, \dots, X_k$, mientras que $S_n - S_k$ depende de los incrementos posteriores y es independiente del pasado.

Observación (Recordatorio: independencia de bloques). Si $X_1, \dots, X_n$ son independientes, entonces las σ -álgebras generadas por dos subconjuntos disjuntos de coordenadas son independientes. En particular, toda variable medible respecto de $\sigma(X_1, \dots, X_k)$ es independiente de toda variable medible respecto de $\sigma(X_{k+1}, \dots, X_n)$.

Lema 5.1. Para cada k ,

$$\mathbb{E}[S_k(S_n - S_k)\mathbf{1}_{A_k}] = 0.$$

Demostración. $S_k\mathbf{1}_{A_k}$ es función del pasado y $S_n - S_k$ es independiente y centrada. La factorización de esperanzas da

$$\mathbb{E}[S_k\mathbf{1}_{A_k}(S_n - S_k)] = \mathbb{E}[S_k\mathbf{1}_{A_k}]\mathbb{E}(S_n - S_k) = 0.$$

La integrabilidad se sigue de Cauchy-Schwarz. □

5.2. Desigualdad maximal de Kolmogorov

Teorema 5.2 (Kolmogorov). *Bajo las hipótesis anteriores,*

$$\mathbb{P} \left(\max_{k \leq n} |S_k| \geq \lambda \right) \leq \frac{\text{Var}(S_n)}{\lambda^2} = \frac{\sum_{j=1}^n \text{Var}(X_j)}{\lambda^2}.$$

Demostración. En A_k , escribir $S_n = S_k + (S_n - S_k)$ y expandir:

$$\begin{aligned} \mathbb{E}[S_n^2 \mathbf{1}_{A_k}] &= \mathbb{E}[S_k^2 \mathbf{1}_{A_k}] + 2\mathbb{E}[S_k(S_n - S_k) \mathbf{1}_{A_k}] \\ &\quad + \mathbb{E}[(S_n - S_k)^2 \mathbf{1}_{A_k}]. \end{aligned}$$

El término cruzado es cero por el lema; el último es no negativo. Como $|S_k| \geq \lambda$ en A_k ,

$$\mathbb{E}[S_n^2 \mathbf{1}_{A_k}] \geq \mathbb{E}[S_k^2 \mathbf{1}_{A_k}] \geq \lambda^2 \mathbb{P}(A_k).$$

Sumar sobre los eventos disjuntos produce

$$\mathbb{E}S_n^2 \geq \sum_k \mathbb{E}[S_n^2 \mathbf{1}_{A_k}] \geq \lambda^2 \sum_k \mathbb{P}(A_k).$$

Como S_n es centrada, $\mathbb{E}S_n^2 = \text{Var}(S_n) = \sum_j \text{Var} X_j$. La unión de los A_k es el evento maximal. $\square$

Ejemplo 5.3 (Caminata simétrica). Si X_j toma ± 1 con probabilidad $1/2$, entonces $\text{Var}(S_n) = n$ y

$$\mathbb{P} \left(\max_{k \leq n} |S_k| \geq a\sqrt{n} \right) \leq \frac{1}{a^2}.$$

La cota no describe exactamente la distribución del máximo, pero es uniforme en todos los tiempos $k \leq n$.

Hipótesis. El centrado anula el término cruzado; la independencia separa pasado y futuro; L^2 hace finitas las expansiones. Para submartingalas habrá una desigualdad maximal distinta en la semana 13.

5.3. Convergencia en L^2 de series independientes

Teorema 5.4 (Criterio de varianzas sumables). Sean X_n independientes, centradas y en L^2 . Si

$$\sum_{n=1}^{\infty} \text{Var}(X_n) < \infty,$$

entonces la serie $\sum_n X_n$ converge en L^2 y casi seguramente.

Primero probamos la parte L^2 . Para $m < n$,

$$\mathbb{E}|S_n - S_m|^2 = \mathbb{E} \left| \sum_{j=m+1}^n X_j \right|^2 = \sum_{j=m+1}^n \text{Var}(X_j),$$

porque las covarianzas cruzadas se anulan. Las colas de la serie de varianzas tienden a cero, de modo que (S_n) es de Cauchy en L^2 .

Observación (Recordatorio: completitud de L^2). $L^2(\Omega, \mathcal{F}, \mathbb{P})$ es un espacio de Hilbert y, por tanto, completo: toda sucesión de Cauchy converge en L^2 a alguna variable $S \in L^2$. Esta afirmación proviene de Teoría de la Medida; aquí se usa para obtener $S_n \rightarrow S$ en L^2 .

Como L^2 implica convergencia en probabilidad, existe una subsucesión $S_{n_r} \rightarrow S$ c.s. Sin embargo, una subsucesión no controla automáticamente los términos intermedios; para eso se usa Kolmogorov.

Elegimos n_r crecientes de modo que

$$\sum_{j>n_r} \text{Var}(X_j) \leq 2^{-3r}.$$

Definimos el evento de oscilación del bloque

$$B_r = \left\{ \max_{n_r < k \leq n_{r+1}} |S_k - S_{n_r}| > 2^{-r} \right\}.$$

Kolmogorov aplicado a $X_{n_r+1}, \dots, X_{n_{r+1}}$ da $\mathbb{P}(B_r) \leq 2^{-r}$. La serie converge, así que Borel–Cantelli I implica que, c.s., las oscilaciones de bloque son a lo sumo 2^{-r} eventualmente.

5.4. Conclusión casi segura y ejemplos

Podemos escoger la subsucesión anterior, refinándola si es necesario, para que

$$\mathbb{P}(|S_{n_r} - S| > 2^{-r}) \leq 2^{-r}.$$

Borel–Cantelli da $S_{n_r} \rightarrow S$ c.s. Si $n_r < k \leq n_{r+1}$,

$$|S_k - S| \leq |S_k - S_{n_r}| + |S_{n_r} - S|.$$

Ambos términos tienden a cero c.s.; por tanto $S_n \rightarrow S$ c.s. Esto completa la prueba del criterio.

Ejemplo 5.5 (Serie de signos). Sean ε_n signos independientes simétricos. Para

$$X_n = \frac{\varepsilon_n}{n},$$

se tiene $\mathbb{E}X_n = 0$ y $\sum \text{Var}(X_n) = \sum n^{-2} < \infty$. Luego $\sum \varepsilon_n/n$ converge c.s. y en L^2 . La serie de valores absolutos diverge; la convergencia proviene de cancelación aleatoria.

Ejemplo 5.6 (Por qué centrar). Si $X_n = 1/n$, las variables son independientes en sentido trivial y las varianzas suman cero, pero $\sum X_n$ diverge. El criterio requiere variables centradas; para variables generales se aplica a $X_n - \mathbb{E}X_n$ y se analiza aparte la serie determinista de medias.

Observación (Una dirección parcial del teorema de tres series). El criterio de varianzas sumables resuelve series de incrementos acotados en L^2 . Para variables sin segundo momento, el teorema de tres series de Kolmogorov usa truncamiento, probabilidades de colas, medias truncadas y varianzas truncadas. No se desarrolla completo, pero su estrategia reaparece en la ley fuerte.

Cierre de la sesión. El primer cruce evita sumar cotas en el tiempo. La desigualdad maximal controla las oscilaciones entre una subsucesión convergente y la sucesión completa.

Sesión 2. Truncamiento y ley fuerte i.i.d.

Objetivo de la sesión. Probar la ley fuerte con primer momento finito mediante Borel–Cantelli, series y Kronecker.

5.5. Suma por partes y lema de Kronecker

La suma por partes discreta es el análogo de integración por partes. Si a_k y b_k son sucesiones y $A_k = \sum_{j=1}^k a_j$, entonces

$$\sum_{k=1}^n a_k b_k = A_n b_n + \sum_{k=1}^{n-1} A_k (b_k - b_{k+1}).$$

Se verifica expandiendo y agrupando coeficientes de cada a_j .

Lema 5.7 (Kronecker). Sea $b_n > 0$, $b_n \uparrow \infty$. Si la serie $\sum_n x_n/b_n$ converge, entonces

$$\frac{1}{b_n} \sum_{k=1}^n x_k \longrightarrow 0.$$

Demostración. Poner $a_k = x_k/b_k$ y $s_k = \sum_{j=1}^k a_j \rightarrow s$. Como $x_k = b_k(s_k - s_{k-1})$, suma por partes da

$$\frac{1}{b_n} \sum_{k=1}^n x_k = \frac{b_n s_n - \sum_{k=1}^{n-1} (b_{k+1} - b_k) s_k}{b_n}.$$

Restar y sumar s elimina la contribución constante. Fijado N , la parte $k < N$ dividida por b_n tiende a cero. La cola se acota por una constante veces $\sup_{k \geq N} |s_k - s|$. Primero hacer $n \rightarrow \infty$ y luego $N \rightarrow \infty$ concluye. $\square$

Para $b_n = n$, el lema afirma: si $\sum x_n/n$ converge, entonces $n^{-1} \sum_{k \leq n} x_k \rightarrow 0$. Esta es exactamente la forma necesaria para promedios.

Observación (Lema de Cesàro). Si $a_n \rightarrow a$, entonces $n^{-1} \sum_{k=1}^n a_k \rightarrow a$. Se prueba separando una cantidad finita de términos iniciales y una cola uniformemente cercana a a .

5.6. Integrabilidad y probabilidades de cola

Para una variable no negativa Z ,

$$\mathbb{E}Z = \int_0^\infty \mathbb{P}(Z > t) dt.$$

Observación (Recordatorio: fórmula de capas). Punto a punto, $Z(\omega) = \int_0^\infty \mathbf{1}_{\{Z(\omega) > t\}} dt$. Tonelli permite intercambiar las integrales porque el integrando es no negativo:

$$\mathbb{E}Z = \int_0^\infty \mathbb{E}\mathbf{1}_{\{Z > t\}} dt.$$

Como consecuencia, si $\mathbb{E}|X| < \infty$,

$$\sum_{n=1}^\infty \mathbb{P}(|X| > n) < \infty.$$

En efecto, la suma queda acotada, salvo una constante inicial, por la integral de la función de cola.

Para una sucesión i.i.d. X_n , definimos el truncamiento dependiente del índice

$$Y_n = X_n \mathbf{1}_{\{|X_n| \leq n\}}.$$

Entonces

$$\sum_n \mathbb{P}(X_n \neq Y_n) = \sum_n \mathbb{P}(|X_1| > n) < \infty.$$

Borel–Cantelli I implica que $X_n = Y_n$ para todo n suficientemente grande, c.s.

Por qué el nivel es n . Un umbral fijo no se acerca a X_n : recortaría siempre las mismas colas. El nivel creciente hace que la modificación desaparezca eventualmente y, al mismo tiempo, produce una serie de varianzas normalizadas sumable.

Lema 5.8 (Varianzas truncadas). *Si $\mathbb{E}|X_1| < \infty$, entonces*

$$\sum_{n=1}^\infty \frac{\text{Var}(Y_n)}{n^2} < \infty.$$

Demostración. Se acota $\text{Var}(Y_n) \leq \mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}]$. Particionando según $k-1 < |X_1| \leq k$ y usando Tonelli,

$$\sum_n \frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}]}{n^2} \leq \sum_{k \geq 1} k^2 \mathbb{P}(k-1 < |X_1| \leq k) \sum_{n \geq k} n^{-2}.$$

Como $\sum_{n \geq k} n^{-2} \leq C/k$, el lado derecho se acota por $C\mathbb{E}(|X_1| + 1) < \infty$. □

5.7. Ley fuerte de los grandes números

Teorema 5.9 (Kolmogorov: ley fuerte i.i.d.). Si $X_1, X_2, \dots$ son i.i.d. y $\mathbb{E}|X_1| < \infty$, entonces

$$\boxed{\frac{1}{n} \sum_{k=1}^n X_k \longrightarrow \mathbb{E}X_1 \quad \text{casi seguramente.}}$$

Demostración. Con $Y_n = X_n \mathbf{1}_{\{|X_n| \leq n\}}$, acabamos de probar que $X_n = Y_n$ eventualmente c.s. y

$$\sum_n \text{Var}(Y_n)/n^2 < \infty.$$

Las variables $(Y_n - \mathbb{E}Y_n)/n$ son independientes, centradas y tienen varianzas sumables. Por el teorema de series,

$$\sum_n \frac{Y_n - \mathbb{E}Y_n}{n}$$

converge c.s. El lema de Kronecker, con $b_n = n$, da

$$\frac{1}{n} \sum_{k=1}^n (Y_k - \mathbb{E}Y_k) \rightarrow 0 \quad \text{c.s.}$$

Además, $Y_n \rightarrow X_n$ en el sentido de leyes y

$$|Y_n| \leq |X_n|.$$

Como todos los X_n tienen la misma ley que X_1 , convergencia dominada sobre una copia canónica da $\mathbb{E}Y_n \rightarrow \mathbb{E}X_1$. Por Cesàro,

$$\frac{1}{n} \sum_{k=1}^n \mathbb{E}Y_k \rightarrow \mathbb{E}X_1.$$

Sumando las dos partes se obtiene el límite para los promedios de Y_k . Reemplazar Y_k por X_k cambia solo finitos términos c.s.; dividido por n , ese cambio tiende a cero. $\square$

La prueba separa tres tareas: eliminar grandes observaciones mediante BC; controlar fluctuaciones centradas mediante varianzas y series; recuperar la media mediante dominada y Cesàro.

5.8. Consecuencias, necesidad y alcance

Corolario 5.10 (Frecuencias). *Para ensayos Bernoulli i.i.d. de parámetro p ,*

$$\frac{1}{n} \sum_{k=1}^n X_k \rightarrow p \quad \text{c.s.}$$

Así la frecuencia relativa converge a la probabilidad del modelo en casi toda secuencia infinita de ensayos.

Corolario 5.11 (Promedios de funciones). *Si Z_k son i.i.d. con ley μ y $g \in L^1(\mu)$, entonces*

$$\frac{1}{n} \sum_{k=1}^n g(Z_k) \rightarrow \int g \, d\mu \quad \text{c.s.}$$

Observación (Necesidad del primer momento). Para i.i.d., la convergencia c.s. de S_n/n a una constante finita fuerza condiciones de cola estrechamente ligadas a $\mathbb{E}|X_1| < \infty$. La versión demostrada usa la hipótesis natural y óptima para converger a $\mathbb{E}X_1$.

Ejemplo 5.12 (Cauchy). Si X_k son Cauchy estándar independientes, S_n/n vuelve a tener ley Cauchy estándar para todo n . No puede converger en probabilidad a una constante. La media no existe y la ley fuerte anterior no se aplica.

Ley débil frente a ley fuerte. La ley débil de la semana 4, bajo varianza finita, controla cada n por Chebyshev. La ley fuerte, bajo solo primer momento, afirma una propiedad de la trayectoria completa y exige Borel–Cantelli, control maximal, series y truncamiento.

Cierre. La desigualdad maximal es el puente entre control cuadrático y trayectorias. El truncamiento adapta esa estrategia a variables que pueden no tener segundo momento.

Lecturas

Durrett, capítulo 2; Sheffield, clases 5–7. Los recordatorios de L^2 , Tonelli, dominada y fórmula de capas se usan como prerrequisitos de medida.



Notas · Semana 6

Teoría de la Probabilidad · CM4H1

Convergencia débil y funciones características

Oswaldo Velásquez Castañón

Profesor Principal · Escuela Profesional de Matemática

Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 6

Límites de leyes y transformadas

Propósito. La sesión 1 define convergencia en distribución, formula Portmanteau, demuestra mapeo continuo y Slutsky, y explica por qué los momentos no pasan automáticamente al límite. La sesión 2 desarrolla funciones características, productos por independencia y un argumento de unicidad.

Recordatorios de medida. Convergencia débil de probabilidades, aproximación de indicadores por funciones continuas, convergencia dominada, Fubini–Tonelli y convolución con núcleos gaussianos.

Sesión 1. Convergencia en distribución

Objetivo de la sesión. Reconocer límites de leyes y usar mapeo continuo y Slutsky con hipótesis explícitas.

6.1. Definición mediante funciones de distribución

Sean X_n variables, posiblemente definidas en espacios distintos, con funciones de distribución F_n , y sea X con función F .

Definición 6.1. Decimos que X_n converge en distribución o débilmente a X , y escribimos $X_n \Rightarrow X$, si

$$F_n(x) \longrightarrow F(x)$$

para todo punto x donde F es continua.

No se exige convergencia en los saltos de F . Si $X_n = X + 1/n$, con X Bernoulli, las funciones F_n no convergen a F exactamente en los átomos, aunque las leyes se desplazan una distancia que tiende a cero.

Observación (Por qué solo puntos de continuidad). La ley límite asigna masa $\mathbb{P}(X = x) = F(x) - F(x-)$ al salto. Aproximar el conjunto $(-\infty, x]$ desde dentro y fuera produce el mismo límite solo si su frontera $\{x\}$ tiene masa cero.

Teorema 6.2 (Portmanteau, formas usadas). *Para probabilidades μ_n, μ en $\mathbb{R}$, son equivalentes:*

- I) $\mu_n \Rightarrow \mu$;
- II) $\int f d\mu_n \rightarrow \int f d\mu$ para toda f continua y acotada;
- III) $\liminf_n \mu_n(G) \geq \mu(G)$ para todo abierto G ;
- IV) $\limsup_n \mu_n(C) \leq \mu(C)$ para todo cerrado C ;
- V) $\mu_n(A) \rightarrow \mu(A)$ si $\mu(\partial A) = 0$.

No reconstruimos toda la equivalencia. La idea de medida es aproximar indicadores de cerrados y abiertos mediante funciones continuas acotadas, y usar regularidad de probabilidades en $\mathbb{R}$.

Ejemplo 6.3. Si $X_n \sim N(0, 1/n)$, entonces para todo $x \neq 0$, $F_n(x) \rightarrow \mathbf{1}_{(0, \infty)}(x)$, que es la función de distribución de la constante 0 en sus puntos de continuidad. Así $X_n \Rightarrow 0$.

6.2. Relación con convergencia en probabilidad

Proposición 6.4. Si $X_n \rightarrow X$ en probabilidad, entonces $X_n \Rightarrow X$.

Demostración. Sea x un punto de continuidad de F_X y $\varepsilon > 0$. Las inclusiones

$$\{X_n \leq x\} \subset \{X \leq x + \varepsilon\} \cup \{|X_n - X| > \varepsilon\},$$

$$\{X \leq x - \varepsilon\} \subset \{X_n \leq x\} \cup \{|X_n - X| > \varepsilon\}$$

dan

$$F_X(x - \varepsilon) - r_n \leq F_{X_n}(x) \leq F_X(x + \varepsilon) + r_n, \quad r_n = \mathbb{P}(|X_n - X| > \varepsilon).$$

Primero $n \rightarrow \infty$ y luego $\varepsilon \downarrow 0$; la continuidad de F_X en x concluye. $\square$

El recíproco es falso. En un mismo espacio, si X es simétrica y $X_n = -X$ para todo n , entonces X_n y X tienen la misma ley, pero X_n no converge en probabilidad a X salvo que $X = 0$ c.s.

Proposición 6.5 (Límite constante). Si $X_n \Rightarrow c$, donde c es constante, entonces $X_n \rightarrow c$ en probabilidad.

Demostración. Para $\varepsilon > 0$, el intervalo cerrado $C = (-\infty, c - \varepsilon] \cup [c + \varepsilon, \infty)$ no contiene c . Portanteau da

$$\limsup_n \mathbb{P}(X_n \in C) \leq \mathbb{P}(c \in C) = 0.$$

El evento es $\{|X_n - c| \geq \varepsilon\}$. $\square$

Observación. Convergencia en distribución depende solo de las leyes y permite espacios distintos. Convergencia en probabilidad compara X_n y X en el mismo espacio mediante $|X_n - X|$.

6.3. Mapeo continuo y Slutsky

Teorema 6.6 (Mapeo continuo). Si $X_n \Rightarrow X$ y $g : \mathbb{R} \rightarrow \mathbb{R}$ es boreliana cuyo conjunto de discontinuidades D_g satisface $\mathbb{P}(X \in D_g) = 0$, entonces

$$g(X_n) \Rightarrow g(X).$$

Demostración. Para toda función continua acotada h , la composición $h \circ g$ es acotada y es continua fuera de D_g . La versión extendida de Portmanteau para funciones acotadas cuyas discontinuidades tienen masa límite cero da

$$\mathbb{E}h(g(X_n)) \rightarrow \mathbb{E}h(g(X)).$$

Portmanteau identifica la convergencia de las leyes transformadas. □

Ejemplo 6.7. Si $X_n \Rightarrow X$ y $\mathbb{P}(X = 0) = 0$, entonces $1/X_n \Rightarrow 1/X$, pues la única discontinuidad relevante de $g(x) = 1/x$ está en cero. Sin la hipótesis, la expresión puede no estar definida o no ser estable.

Teorema 6.8 (Slutsky). Si $X_n \Rightarrow X$ y $Y_n \rightarrow c$ en probabilidad, entonces

$$X_n + Y_n \Rightarrow X + c, \text{ y } X_n Y_n \Rightarrow cX.$$

Si $c \neq 0$, también $X_n/Y_n \Rightarrow X/c$.

Demostración. Primero se prueba que $(X_n, Y_n) \Rightarrow (X, c)$. Para una función continua acotada h en $\mathbb{R}^2$, se restringe a un compacto donde X_n es tensa y se usa continuidad uniforme en la segunda coordenada junto con $Y_n \rightarrow c$ en probabilidad. El mapeo continuo aplicado a suma, producto y cociente concluye. □

Ejemplo 6.9 (Estandarización estimada). Si $\sqrt{n}(\bar{X}_n - \mu)/\sigma \Rightarrow N(0, 1)$ y $S_n/\sigma \rightarrow 1$ en probabilidad, entonces

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \frac{\sigma}{S_n} \Rightarrow N(0, 1).$$

La consistencia del denominador no requiere independencia respecto del numerador.

6.4. Los momentos no pasan automáticamente al límite

Ejemplo 6.10 (Masa que escapa). Sea $X_n = n$ con probabilidad $1/n$ y 0 en otro caso. Entonces

$$\mathbb{P}(|X_n| > \varepsilon) = \frac{1}{n} \rightarrow 0,$$

de modo que $X_n \rightarrow 0$ en probabilidad y en distribución. Sin embargo,

$$\mathbb{E}X_n = 1, \text{ y } \mathbb{E}X_n^2 = n.$$

Ni la media converge a 0 ni los segundos momentos permanecen acotados.

Observación (Recordatorio: Fatou). Si $Z_n \geq 0$, entonces

$$\mathbb{E}(\liminf Z_n) \leq \liminf \mathbb{E}Z_n.$$

Fatou da una desigualdad, no igualdad. Para pasar esperanzas se necesita dominación, convergencia L^1 o integrabilidad uniforme, tema de la semana 12.

Proposición 6.11. Si $X_n \Rightarrow X$ y f es continua y acotada, entonces $\mathbb{E}f(X_n) \rightarrow \mathbb{E}f(X)$. Si f es no acotada, la conclusión puede fallar incluso para $f(x) = x$.

Ejemplo 6.12 (Probabilidades de intervalos). Si $X_n \Rightarrow X$ y $\mathbb{P}(X = a) = \mathbb{P}(X = b) = 0$, entonces

$$\mathbb{P}(a < X_n \leq b) \rightarrow \mathbb{P}(a < X \leq b).$$

El intervalo es un conjunto de continuidad porque su frontera $\{a, b\}$ tiene masa cero. Si hay un átomo en un extremo, Portmanteau no garantiza el límite.

Cierre de la sesión. La convergencia débil controla integrales de funciones continuas acotadas. Slutsky combina un límite aleatorio débil con cantidades que se estabilizan en probabilidad. Los momentos necesitan control adicional de colas.

Sesión 2. Funciones características

Objetivo de la sesión. Calcular transformadas, usar independencia y comprender por qué determinan la ley.

6.5. Definición y propiedades elementales

Definición 6.13. La función característica de una variable X es

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{\mathbb{R}} e^{itx} \mu_X(dx), \quad t \in \mathbb{R}.$$

Siempre existe porque $|e^{itX}| = 1$. Sus propiedades inmediatas son

$$\varphi_X(0) = 1, \text{ y } |\varphi_X(t)| \leq 1, \text{ y } \varphi_X(-t) = \overline{\varphi_X(t)}.$$

Proposición 6.14. φ_X es uniformemente continua en $\mathbb{R}$.

Demostración. Para $h, t \in \mathbb{R}$,

$$|\varphi_X(t+h) - \varphi_X(t)| \leq \mathbb{E}|e^{i(t+h)X} - e^{itX}| = \mathbb{E}|e^{ihX} - 1|.$$

El lado derecho no depende de t , converge puntualmente a cero cuando $h \rightarrow 0$ y está dominado por 2. Convergencia dominada concluye. $\square$

Si $\mathbb{E}|X|^k < \infty$, puede derivarse bajo la esperanza hasta orden k :

$$\varphi_X^{(j)}(t) = \mathbb{E}[(iX)^j e^{itX}], \text{ y } j \leq k.$$

En particular $\varphi_X'(0) = i\mathbb{E}X$ y $\varphi_X''(0) = -\mathbb{E}X^2$. La existencia de derivadas en cero no siempre implica el momento correspondiente sin hipótesis adicionales.

Observación (Recordatorio: dominada para derivar). El cociente incremental de e^{itX} se controla mediante $|X|$; para la segunda derivada, mediante X^2 . La derivación bajo el signo integral se justifica por dominación, no solo por cálculo formal.

6.6. Cálculos y productos por independencia

Ejemplo 6.15 (Familias discretas). Para Bernoulli(p),

$$\varphi(t) = 1 - p + pe^{it}.$$

La suma de n Bernoulli independientes tiene característica

$$(1 - p + pe^{it})^n,$$

que corresponde a la binomial. Para Poisson(λ),

$$\varphi(t) = \sum_{k=0}^{\infty} e^{itk} e^{-\lambda} \frac{\lambda^k}{k!} = \exp\{\lambda(e^{it} - 1)\}.$$

Ejemplo 6.16 (Normal). Para $Z \sim N(0, 1)$,

$$\varphi_Z(t) = e^{-t^2/2}.$$

Una demostración diferencial de la integral $I(t) = \int e^{itx} \phi(x) dx$: integración por partes da $I'(t) = -tI(t)$ e $I(0) = 1$. Por tanto $I(t) = e^{-t^2/2}$. Si $X = \mu + \sigma Z$,

$$\varphi_X(t) = e^{it\mu - \sigma^2 t^2/2}.$$

Proposición 6.17. Si X, Y son independientes,

$$\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t).$$

Demostración. $e^{it(X+Y)} = e^{itX}e^{itY}$ y ambos factores son acotados. La factorización de esperanzas para funciones de variables independientes da el producto. $\square$

Así, las funciones características transforman convoluciones en productos. Por ejemplo, la suma independiente de Poisson tiene parámetro suma, y una combinación $aX + bY$ de normales independientes es normal con media y varianza transformadas.

6.7. Unicidad: la característica determina la ley

Teorema 6.18 (Unicidad). Si $\varphi_\mu(t) = \varphi_\nu(t)$ para todo $t \in \mathbb{R}$, entonces $\mu = \nu$.

Presentamos una prueba por suavización. Sea $Z_\varepsilon \sim N(0, \varepsilon^2)$ independiente. La convolución $\mu * \gamma_\varepsilon$ tiene densidad

$$f_{\mu, \varepsilon}(x) = \int \frac{1}{\sqrt{2\pi}\varepsilon} \exp\left[-\frac{(x-y)^2}{2\varepsilon^2}\right] \mu(dy).$$

Su característica es $\varphi_\mu(t)e^{-\varepsilon^2 t^2/2}$, que es integrable en t porque el factor gaussiano lo es.

Observación (Recordatorio: inversión para transformadas integrables). Si una probabilidad tiene función característica integrable, posee densidad continua

$$f(x) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{-itx} \varphi(t) dt.$$

La prueba usa Fubini y la aproximación de la identidad de Fourier. Se toma como recordatorio de análisis; aquí se aplica solo después de verificar integrabilidad.

Si $\varphi_\mu = \varphi_\nu$, entonces las características suavizadas coinciden; la fórmula de inversión da

$$\mu * \gamma_\varepsilon = \nu * \gamma_\varepsilon \quad \text{para todo } \varepsilon > 0.$$

Finalmente, si $X \sim \mu$ y Z es normal estándar independiente,

$$X + \varepsilon Z \rightarrow X \quad \text{en probabilidad.}$$

Por ello $\mu * \gamma_\varepsilon \Rightarrow \mu$; análogamente converge a ν . La unicidad del límite débil implica $\mu = \nu$.

6.8. Identificación de leyes y preparación para Lévy

Ejemplo 6.19 (Producto reconocible). La función

$$\varphi(t) = \exp\{3(e^{it} - 1)\} e^{-2t^2}$$

es el producto de las características de $N \sim \text{Pois}(3)$ y $G \sim N(0, 4)$. Por unicidad, identifica la ley de $N + G$ cuando son independientes.

Ejemplo 6.20 (Suma normal sin teoría vectorial). Si X, Y son normales estándar independientes,

$$\varphi_{X+2Y}(t) = e^{-t^2/2} e^{-(2t)^2/2} = e^{-5t^2/2}.$$

Por unicidad, $X + 2Y \sim N(0, 5)$.

Proposición 6.21. Si $X_n \Rightarrow X$, entonces $\varphi_{X_n}(t) \rightarrow \varphi_X(t)$ para cada t .

Demostración. Para t fijo, $x \mapsto e^{itx}$ es continua y acotada. Portmanteau aplicado a sus partes real e imaginaria da la convergencia. $\square$

El recíproco necesita una condición: el límite puntual debe ser continuo en cero. Ese es el teorema de continuidad de Lévy de la semana 7. La continuidad evita pérdida de masa y garantiza que la función límite corresponda a una probabilidad.

Cierre. Las funciones características siempre existen, convierten sumas independientes en productos y determinan la ley. Su vínculo con convergencia débil permitirá demostrar el TCL.

Lecturas

Durrett, capítulo 3; Sheffield, clases 8–10; Saporta, capítulo 3. Portmanteau e inversión de Fourier se usan en las formas expresamente enunciadas.



Notas · Semana 7

Teoría de la Probabilidad · CM4H1

Continuidad de Lévy y teorema central del límite

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 7

De transformadas convergentes a límites normales

Propósito. La sesión 1 prueba que la convergencia de funciones características, con continuidad en cero del límite, equivale a convergencia débil. La sesión 2 demuestra el TCL de Lindeberg–Lévy y desarrolla su uso en conteos y medias.

Recordatorios. Tensión de probabilidades, selección de Helly, Portmanteau, convergencia dominada, expansión de Taylor con resto y el límite $(1 + u_n)^n \rightarrow e^a$ cuando $nu_n \rightarrow a$ y $nu_n^2 \rightarrow 0$.

Sesión 1. Teorema de continuidad

Objetivo de la sesión. Reconocer convergencia débil mediante funciones características y entender el papel de la continuidad en cero.

7.1. Enunciado y dirección directa

Teorema 7.1 (Continuidad de Lévy). Sean μ_n probabilidades en $\mathbb{R}$, con funciones características φ_n .

- I) Si $\mu_n \Rightarrow \mu$, entonces $\varphi_n(t) \rightarrow \varphi_\mu(t)$ para todo t .
- II) Si $\varphi_n(t) \rightarrow \varphi(t)$ para todo t y φ es continua en 0, entonces existe una probabilidad μ con $\varphi = \varphi_\mu$ y $\mu_n \Rightarrow \mu$.

La primera dirección ya está contenida en Portmanteau. Para t fijo, las funciones $x \mapsto \cos(tx)$ y $x \mapsto \sin(tx)$ son continuas y acotadas. Por tanto,

$$\int \cos(tx) \mu_n(dx) \rightarrow \int \cos(tx) \mu(dx),$$

y lo mismo para el seno. Sumando partes real e imaginaria se obtiene $\varphi_n(t) \rightarrow \varphi_\mu(t)$.

Observación. La convergencia puntual de transformadas es necesaria. La dificultad del recíproco consiste en mostrar que el límite corresponde a una probabilidad y que ninguna masa escapa hacia infinito.

Ejemplo 7.2 (Normal con varianza decreciente). Si $X_n \sim N(0, 1/n)$,

$$\varphi_n(t) = e^{-t^2/(2n)} \rightarrow 1.$$

La función límite es la característica de la constante cero; Lévy da $X_n \Rightarrow 0$.

Ejemplo 7.3 (Traslación al infinito). Para $X_n = n$, $\varphi_n(t) = e^{itn}$ no tiene límite para la mayoría de t . La falta de tensión se manifiesta como oscilación de las características.

7.2. Continuidad en cero y tensión

Una familia (μ_n) es *tensa* si para todo $\varepsilon > 0$ existe M con

$$\sup_n \mu_n([-M, M]^c) < \varepsilon.$$

Lema 7.4 (Cota de tensión mediante características). *Existe una constante universal C tal que, para toda probabilidad μ con característica φ y todo $R > 0$,*

$$\mu(|x| > 2R) \leq CR \int_{-1/R}^{1/R} (1 - \Re\varphi(t)) dt.$$

Una variante equivalente, con constantes distintas, basta para la prueba.

Idea demostrativa. Por Tonelli,

$$\int_{-T}^T (1 - \Re\varphi(t)) dt = \int \left[\int_{-T}^T (1 - \cos(tx)) dt \right] \mu(dx).$$

La integral interior es $2T - 2\sin(Tx)/x$. Cuando $|x|$ es mayor que una constante por $1/T$, este término queda acotado inferiormente por una fracción positiva de T . Restringir la integral exterior a esa cola produce la desigualdad. $\square$

Supongamos ahora $\varphi_n(t) \rightarrow \varphi(t)$ y φ continua en cero. Como $\varphi(0) = 1$, para t pequeño $1 - \Re\varphi(t)$ es pequeño. Convergencia puntual y dominación por 2 permiten integrar en un intervalo compacto:

$$\int_{-T}^T (1 - \Re\varphi_n(t)) dt \rightarrow \int_{-T}^T (1 - \Re\varphi(t)) dt.$$

El lema, primero eligiendo T pequeño y luego tratando finitos índices iniciales, demuestra tensión de (μ_n) .

Observación (Recordatorio: dominada). La integración es respecto de Lebesgue en el intervalo $[-T, T]$; el dominante constante 2 es integrable. La continuidad en cero hace pequeño el límite promedio cerca de cero.

7.3. Selección de subsucesiones e identificación

Observación (Recordatorio: selección de Helly). Toda sucesión de funciones de distribución contiene una subsucesión que converge en todos los puntos de continuidad de alguna función no decreciente y continua por la derecha. Si la familia de probabilidades es tensa, los límites en $-\infty$ y $+\infty$ son 0 y 1, de modo que la función límite es una función de distribución.

Por tensión, de cualquier subsucesión (μ_{n_k}) puede extraerse una subsucesión que converge débilmente a alguna probabilidad ν . Por la dirección directa de Lévy,

$$\varphi_{n_{k_j}}(t) \rightarrow \varphi_\nu(t).$$

Pero la sucesión original converge puntualmente a φ , luego $\varphi_\nu = \varphi$.

Si dos límites subsecuenciales ν_1, ν_2 existieran, ambos tendrían característica φ . El teorema de unicidad de la semana 6 implica $\nu_1 = \nu_2$. Por tanto todas las subsucesiones convergentes tienen el mismo límite μ .

Lema 7.5 (Criterio subsecuencial). *Si una sucesión tensa de probabilidades tiene un único posible límite débil para todas sus subsucesiones convergentes, entonces la sucesión completa converge a ese límite.*

Demostración. Si no convergiera, existirían una función continua acotada f , un $\varepsilon > 0$ y una subsucesión con

$$\left| \int f d\mu_{n_k} - \int f d\mu \right| \geq \varepsilon.$$

La tensión permite extraer una subsucesión convergente; su límite debe ser μ , contradiciendo Portmanteau. $\square$

Así queda demostrada la dirección inversa: φ es la característica del límite único y $\mu_n \Rightarrow \mu$.

7.4. Qué puede fallar y cómo se usa Lévy

La continuidad en cero no es un detalle técnico. Un límite puntual discontinuo en cero no puede ser función característica, porque toda característica es uniformemente continua y vale uno en cero.

Ejemplo 7.6 (Pérdida de masa). Sea X_n uniforme en $[-n, n]$. Su característica es

$$\varphi_n(t) = \frac{\sin(nt)}{nt}, \text{ y } \varphi_n(0) = 1.$$

Para cada $t \neq 0$, $\varphi_n(t) \rightarrow 0$, mientras el valor en cero permanece 1. El límite puntual es discontinuo en cero. Las leyes no son tensas y no tienen límite probabilístico en $\mathbb{R}$.

Procedimiento para aplicar el teorema.

1. Calcular $\varphi_n(t)$ para t fijo.
2. Hallar el límite puntual $\varphi(t)$.
3. Reconocer una función característica conocida o verificar continuidad en cero.
4. Invocar Lévy para concluir convergencia débil.

Ejemplo 7.7 (Poisson a normal: anticipo). Si $N_n \sim \text{Pois}(n\lambda)$ y

$$Z_n = \frac{N_n - n\lambda}{\sqrt{n\lambda}},$$

entonces

$$\varphi_{Z_n}(t) = \exp \left\{ n\lambda \left(e^{it/\sqrt{n\lambda}} - 1 - \frac{it}{\sqrt{n\lambda}} \right) \right\} \rightarrow e^{-t^2/2}.$$

La expansión se justificará en la sesión 2; Lévy identifica el límite normal.

Cierre. La continuidad en cero produce tensión; la tensión produce límites subsecuenciales; unicidad de características los identifica. Esta cadena lógica convierte convergencia de transformadas en convergencia de leyes.

Sesión 2. Teorema central del límite

Objetivo de la sesión. Demostrar el TCL i.i.d. de varianza finita y usarlo con normalizaciones estadísticas.

7.5. Estandarización y expansión local

Sean $X_1, X_2, \dots$ i.i.d. con media μ y varianza $0 < \sigma^2 < \infty$. Definimos

$$Y_k = \frac{X_k - \mu}{\sigma}, \quad Z_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k = \frac{S_n - n\mu}{\sigma\sqrt{n}}.$$

Entonces $\mathbb{E}Y_1 = 0$ y $\mathbb{E}Y_1^2 = 1$.

Lema 7.8 (Expansión de la característica). Si $\mathbb{E}Y = 0$ y $\mathbb{E}Y^2 = 1$, entonces

$$\varphi_Y(u) = 1 - \frac{u^2}{2} + o(u^2), \quad u \rightarrow 0.$$

Demostración. Usamos

$$e^{iv} = 1 + iv - \frac{v^2}{2} + v^2 r(v), \quad r(v) \rightarrow 0, \quad \text{quad} |r(v)| \leq C.$$

Con $v = uY$ y tomando esperanzas,

$$\varphi_Y(u) = 1 + iu\mathbb{E}Y - \frac{u^2}{2}\mathbb{E}Y^2 + u^2\mathbb{E}[Y^2 r(uY)].$$

Los dos momentos dan los términos principales. Como $Y^2|r(uY)| \leq CY^2 \in L^1$ y $r(uY) \rightarrow 0$ c.s., convergencia dominada hace que la última esperanza tienda a cero. $\square$

Observación. No se exige tercer momento. El resto se domina por Y^2 , exactamente el momento disponible. Esta elección distingue la prueba rigurosa de una expansión formal.

7.6. Demostración del TCL

Teorema 7.9 (Lindeberg–Lévy). *Bajo las hipótesis anteriores,*

$$\boxed{\frac{S_n - n\mu}{\sigma\sqrt{n}} \Rightarrow N(0, 1).}$$

Demostración. Por independencia,

$$\varphi_{Z_n}(t) = \left[\varphi_Y \left(\frac{t}{\sqrt{n}} \right) \right]^n.$$

El lema da, para t fijo,

$$\varphi_Y(t/\sqrt{n}) = 1 - \frac{t^2}{2n} + o(n^{-1}).$$

Escribamos $u_n = -t^2/(2n) + o(n^{-1})$. Entonces $nu_n \rightarrow -t^2/2$ y $nu_n^2 \rightarrow 0$. Para n grande, $1 + u_n$ está cerca de uno y

$$n \log(1 + u_n) = nu_n + nO(u_n^2) \rightarrow -\frac{t^2}{2}.$$

Al exponenciar,

$$\varphi_{Z_n}(t) = (1 + u_n)^n \rightarrow e^{-t^2/2}.$$

El límite es continuo en cero y es la característica de $N(0, 1)$. El teorema de continuidad de Lévy concluye. $\square$

Hipótesis y escala. El centrado elimina el término lineal; la varianza fija el término cuadrático; independencia eleva una característica a la potencia n ; la escala $\sqrt{n}$ mantiene un límite no degenerado.

Corolario 7.10. *Para la media muestral,*

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \Rightarrow N(0, 1).$$

Así, para $a < b$,

$$\mathbb{P} \left(a \leq \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq b \right) \rightarrow \Phi(b) - \Phi(a).$$

7.7. Aplicaciones a binomial y Poisson

Ejemplo 7.11 (Binomial). Si $B_n \sim \text{Bin}(n, p)$, puede escribirse como suma de Bernoulli i.i.d. Por el TCL,

$$\frac{B_n - np}{\sqrt{np(1-p)}} \Rightarrow N(0, 1).$$

Para aproximar $\mathbb{P}(a \leq B_n \leq b)$ se usa corrección de continuidad:

$$\mathbb{P}(a \leq B_n \leq b) \approx \Phi\left(\frac{b + 1/2 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - 1/2 - np}{\sqrt{np(1-p)}}\right).$$

La corrección traduce celdas enteras a intervalos de longitud uno.

Ejemplo 7.12 (Cálculo). Para $B \sim \text{Bin}(1000, 1/2)$,

$$\mathbb{P}(480 \leq B \leq 520) \approx 2\Phi\left(\frac{20.5}{\sqrt{250}}\right) - 1.$$

Antes de usar la aproximación se identifican media 500, varianza 250 y extremos corregidos 479.5, 520.5.

Ejemplo 7.13 (Poisson). Si $N_n \sim \text{Pois}(n\lambda)$, puede representarse como suma de n $\text{Poisson}(\lambda)$ independientes. Entonces

$$\frac{N_n - n\lambda}{\sqrt{n\lambda}} \Rightarrow N(0, 1).$$

Coincide con el cálculo directo de características de la sesión 1.

Observación. El TCL es asintótico. No proporciona por sí solo una cota del error para un n dado. El teorema de Berry–Esseen añade una cota $O(n^{-1/2})$ bajo tercer momento absoluto finito, pero se presenta solo como referencia.

7.8. Normalizaciones estimadas y límites del teorema

Proposición 7.14 (Estandarización con varianza muestral). *Si, además, $S_n^2 \rightarrow \sigma^2$ en probabilidad, entonces*

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \Rightarrow N(0, 1).$$

Demostración. La ley fuerte aplicada a $(X_i - \mu)^2$ cuando existe el segundo momento, junto con la identidad de suma de cuadrados, da consistencia de S_n^2 . Entonces $\sigma/S_n \rightarrow 1$ en probabilidad y Slutsky multiplica el TCL por ese factor. $\square$

Observación. Para una muestra normal, el cociente tiene exactamente ley Student para n finito; se demostrará en la semana 11. Para una ley general, la normalidad es solo límite asintótico.

Cuándo no se aplica.

- Si la varianza es infinita, la escala $\sqrt{n}$ puede ser incorrecta y aparecer límites estables no normales.
- Sin independencia o con dependencia fuerte, se necesitan condiciones adicionales.
- Si la distribución cambia con n , se usan versiones triangulares como Lindeberg–Feller.

Ejemplo 7.15 (Intervalo aproximado). El TCL sugiere

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right),$$

y, reemplazando σ consistentemente,

$$\bar{X}_n \pm z_{1-\alpha/2} \frac{S_n}{\sqrt{n}}.$$

La expresión se interpreta como aproximación de cobertura repetida, no como probabilidad posterior de que un parámetro fijo pertenezca al intervalo.

Cierre. Lévy convierte el límite de características en una ley límite. La expansión local usa solo dos momentos y la independencia produce la potencia que converge a la característica gaussiana.

Lecturas

Durrett, capítulo 3; Sheffield, clases 10–12; Saporta, capítulos 3–4. La prueba de tensión se presenta al nivel necesario para usar Lévy rigurosamente.