



Notas del curso · Tomo I

Teoría de la Probabilidad · CM4H1

Semanas 1–7

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2



Sesión 1. Modelos y probabilidad

Unidad 1 · Dos horas de teoría · Primera semana

«La probabilità non esiste.»
Bruno de Finetti

La frase no niega el cálculo que sigue: provoca una pregunta sobre qué significan sus números fuera del formalismo. Los axiomas producen consecuencias matemáticas; al aplicarlos debemos justificar por qué el espacio, los eventos y la probabilidad elegidos representan la situación.

Objetivos. Formular un modelo, justificar continuidad de probabilidades y usar el condicionamiento por eventos. La teoría de la medida se recuerda; sus aplicaciones probabilísticas se demuestran.

1. Del experimento al modelo

Un modelo especifica qué resultados distinguimos, qué sucesos podemos medir y con qué probabilidades. No hay equiprobabilidad por el solo hecho de que un conjunto sea finito.

Ejemplo: dos lanzamientos. Adoptamos el modelo

$$\Omega = \{00, 01, 10, 11\}, \quad \mathcal{F} = 2^\Omega, \quad \mathbb{P}(\{\omega\}) = \frac{1}{4}.$$

El valor 1 representa cara. Este modelo expresa dos lanzamientos equilibrados e independientes; la independencia se formalizará en la semana 2. Si solo observamos el número de caras, los resultados son 0, 1, 2, pero sus probabilidades son 1/4, 1/2, 1/4. No corresponde asignarles 1/3.

Definición. Una σ -álgebra $\mathcal{F}$ sobre Ω contiene a Ω y es cerrada bajo complementos y uniones numerables. Un *espacio de probabilidad* es una terna $(\Omega, \mathcal{F}, \mathbb{P})$ donde $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$, $\mathbb{P}(\Omega) = 1$ y, para eventos disjuntos dos a dos,

$$\mathbb{P}\left(\bigcup_{n \geq 1} A_n\right) = \sum_{n \geq 1} \mathbb{P}(A_n).$$

Un resultado es $\omega \in \Omega$; un evento es $A \in \mathcal{F}$. Sin $\mathbb{P}$, el par $(\Omega, \mathcal{F})$ se llama *espacio medible*.

Recordatorio de medida. Se tiene $\emptyset \in \mathcal{F}$ y, por De Morgan, $\bigcap_n A_n = (\bigcup_n A_n^c)^c \in \mathcal{F}$. También $A \setminus B = A \cap B^c \in \mathcal{F}$. La σ -álgebra $\mathcal{B}(\mathbb{R})$ está generada por los abiertos. Usaremos la medida de Lebesgue λ sin reconstruirla.

Dos modelos de referencia.

- En un espacio finito o numerable, dadas masas $p_\omega \geq 0$ con $\sum_\omega p_\omega = 1$, se define $\mathbb{P}(A) = \sum_{\omega \in A} p_\omega$ sobre 2^Ω . La aditividad resulta de reagrupar series no negativas.
- En $\Omega = [0, 1]$, con la σ -álgebra boreliana relativa, $\mathbb{P}(A) = \lambda(A)$. Así $\mathbb{P}([a, b]) = b - a$ para $0 \leq a \leq b \leq 1$. No definimos esta medida sobre todos los subconjuntos de $[0, 1]$.

Lectura estadística. El modelo describe la distribución de una observación antes de observarla. Los datos son realizaciones. Una frecuencia observada no es, por definición, la probabilidad del modelo; las leyes de los grandes números estudiarán su relación.

Sesión 1 · 2. Propiedades y continuidad

Todos los conjuntos que aparecen a continuación son medibles.

Proposición 1. Se cumplen:

$$\begin{aligned}\mathbb{P}(\emptyset) &= 0, \quad \mathbb{P}(A^c) = 1 - \mathbb{P}(A), \quad A \subset B \implies \mathbb{P}(A) \leq \mathbb{P}(B), \\ \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B), \quad \mathbb{P}\left(\bigcup_n A_n\right) \leq \sum_n \mathbb{P}(A_n).\end{aligned}$$

Demostración. Aplicar la aditividad a $\Omega, \emptyset, \emptyset, \dots$ fuerza $\mathbb{P}(\emptyset) = 0$. Las descomposiciones disjuntas $\Omega = A \cup A^c$ y $B = A \cup (B \setminus A)$, si $A \subset B$, prueban complemento y monotonía. Como $A \cup B = A \cup (B \setminus A)$ y $B = (B \setminus A) \cup (A \cap B)$, se obtiene la fórmula de la unión. Para la última desigualdad, poner

$$D_1 = A_1, \quad D_n = A_n \setminus \bigcup_{j < n} A_j \quad (n \geq 2).$$

Los D_n son disjuntos, $D_n \subset A_n$ y $\bigcup D_n = \bigcup A_n$. La aditividad y la monotonía dan la desigualdad. $\square$

Teorema 2: continuidad de la probabilidad. Si $A_n \uparrow A$, es decir, $A_n \subset A_{n+1}$ y $A = \bigcup_n A_n$, entonces $\mathbb{P}(A_n) \uparrow \mathbb{P}(A)$. Si $A_n \downarrow A$, con $A = \bigcap_n A_n$, entonces $\mathbb{P}(A_n) \downarrow \mathbb{P}(A)$.

Demostración. En el caso creciente, tomar $A_0 = \emptyset$ y $D_n = A_n \setminus A_{n-1}$. Son disjuntos y $A_n = \bigcup_{k=1}^n D_k$, $A = \bigcup_{k \geq 1} D_k$. Por tanto,

$$\mathbb{P}(A) = \sum_{k \geq 1} \mathbb{P}(D_k) = \lim_{n \rightarrow \infty} \sum_{k=1}^n \mathbb{P}(D_k) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

En el caso decreciente, $A_n^c \uparrow A^c$. Lo probado y la fórmula del complemento dan $1 - \mathbb{P}(A_n) \rightarrow 1 - \mathbb{P}(A)$. $\square$

Hipótesis crucial. Para una medida general, la continuidad desde arriba requiere masa finita de algún término. En Lebesgue, $[n, \infty) \downarrow \emptyset$ pero todas sus medidas son infinitas. En probabilidad la finitud es automática.

3. Nulo no significa vacío

Un evento nulo tiene probabilidad cero; una propiedad vale *casi seguramente* si el evento donde falla es nulo. En el modelo uniforme, $\{1/2\}$ es no vacío y nulo. También $\mathbb{Q} \cap [0, 1]$ es nulo: es una unión numerable de singletons y se aplica subaditividad. Así, la observación es irracional casi seguramente.

No puede sustituirse “numerable” por “arbitraria”: $[0, 1] = \bigcup_{x \in [0, 1]} \{x\}$ tiene probabilidad uno. En un espacio no completo, un subconjunto de un evento nulo no tiene por qué ser medible; aquí solo asignamos probabilidades a eventos de $\mathcal{F}$.

Sesión 1 · 4. Condicionar y actualizar

Definición. Para $B \in \mathcal{F}$ con $\mathbb{P}(B) > 0$, se define

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

La información B cambia las proporciones con las que se ponderan los resultados. El denominador es la probabilidad de la información disponible.

Proposición 3. Para B fijo de probabilidad positiva, $A \mapsto \mathbb{P}(A | B)$ es una probabilidad sobre $(\Omega, \mathcal{F})$.

Demostración. Es no negativa y $\mathbb{P}(\Omega | B) = 1$. Si los A_n son disjuntos, los $A_n \cap B$ también lo son; luego

$$\mathbb{P}\left(\bigcup_n A_n \mid B\right) = \frac{\sum_n \mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_n \mathbb{P}(A_n | B). \quad \square$$

Teorema 4: probabilidad total y Bayes. Sea $(B_i)_{i \in I}$ una partición finita o numerable de Ω en eventos con $\mathbb{P}(B_i) > 0$. Entonces

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i).$$

Si además $\mathbb{P}(A) > 0$, para cada $j \in I$,

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(A | B_j) \mathbb{P}(B_j)}{\sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i)}.$$

Demostración. Los $A \cap B_i$ son disjuntos y su unión es A . La aditividad da $\mathbb{P}(A) = \sum_i \mathbb{P}(A \cap B_i)$; la definición de condicionamiento da la primera fórmula. Sustituirla en $\mathbb{P}(B_j | A) = \mathbb{P}(A \cap B_j) / \mathbb{P}(A)$ prueba la segunda. $\square$

Si una celda de la partición es nula, su intersección con A es nula. Se omite esa celda de la suma; no se utiliza una expresión indefinida multiplicada por cero.

Ejemplo resuelto: procedencia de una pieza. Dos líneas aportan el 60 % y el 40 % de la producción. Sus tasas de defecto son 2 % y 5 %. Se elige una pieza según esas proporciones. Sean L_i su procedencia y D el defecto. Entonces

$$\mathbb{P}(D) = 0.60(0.02) + 0.40(0.05) = 0.032, \quad \mathbb{P}(L_2 | D) = \frac{0.40(0.05)}{0.032} = \frac{5}{8}.$$

Entre 10000 piezas bajo estas proporciones, los conteos de referencia serían 120 y 200 defectuosas por línea: $200/320 = 5/8$. Es una traducción de las proporciones del modelo, no una afirmación sobre un lote observado.

Cierre. $\mathbb{P}(D | L_2) = 0.05$ no es $\mathbb{P}(L_2 | D) = 0.625$. Si $\mathbb{P}(B) = 0$, el cociente de la definición no existe. El condicionamiento respecto de variables y σ -álgebras se desarrollará en la semana 8.



Sesión 2. Variables y leyes

Unidad 1 · Dos horas de teoría · Primera semana

Objetivos. Separar variable y ley; verificar medibilidad; deducir las propiedades de una función de distribución y distinguir leyes discretas, con densidad y mixtas.

1. Una variable es una función medible

Definición. Una variable aleatoria real es una aplicación medible $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Esto significa que

$$\{X \in C\} := X^{-1}(C) = \{\omega : X(\omega) \in C\} \in \mathcal{F} \quad \text{para todo } C \in \mathcal{B}(\mathbb{R}).$$

La notación $\{X \leq x\}$ abrevia $X^{-1}((-\infty, x])$. La medibilidad garantiza que las preguntas acerca de la observación tengan probabilidades definidas.

Proposición 5: criterio práctico. X es medible si y solo si $\{X \leq x\} \in \mathcal{F}$ para cada $x \in \mathbb{R}$.

Demostración. La necesidad se sigue de la definición. Para la suficiencia, la clase $\mathcal{C} = \{C \subset \mathbb{R} : X^{-1}(C) \in \mathcal{F}\}$ es una σ -álgebra, pues las preimágenes preservan complementos y uniones. Por hipótesis contiene todos los intervalos $(-\infty, x]$. Estos generan $\mathcal{B}(\mathbb{R})$: $(-\infty, b) = \bigcup_n (-\infty, b - 1/n]$, los intervalos abiertos se obtienen por diferencias y todo abierto de $\mathbb{R}$ es unión numerable de intervalos con extremos racionales. Por tanto $\mathcal{B}(\mathbb{R}) \subset \mathcal{C}$. $\square$

Ejemplo: una observación demasiado fina. Sean $\Omega = \{1, 2, 3, 4\}$ y $\mathcal{F} = \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}\}$. La función $X = (0, 0, 1, 1)$ es medible: es constante en cada bloque. $Y = (0, 1, 0, 1)$ no lo es, porque $\{Y \leq 0\} = \{1, 3\} \notin \mathcal{F}$.

2. La ley es una medida sobre los valores

Definición y verificación. La *ley* de X es $\mu_X(C) = \mathbb{P}(X \in C)$, para C boreliano. Es una probabilidad: $\mu_X(\mathbb{R}) = 1$, es no negativa y, si los C_n son disjuntos, sus preimágenes también lo son, de modo que

$$\mu_X\left(\bigcup_n C_n\right) = \mathbb{P}\left(\bigcup_n X^{-1}(C_n)\right) = \sum_n \mu_X(C_n).$$

En dos lanzamientos, X = número de caras es una función en cuatro resultados; su ley concentra masas $1/4, 1/2, 1/4$ en $0, 1, 2$.

No confundir. X , $X(\omega)$ y μ_X son, respectivamente, función, valor observado y medida. Dos variables pueden tener la misma ley sin coincidir: en $[0, 1]$ uniforme, $U(\omega) = \omega$ y $V(\omega) = 1 - \omega$ son uniformes, pero solo coinciden en $\omega = 1/2$, un evento nulo.

Sesión 2 · 3. Función de distribución

Convención del curso. Para toda variable real X ,

$$F_X(x) = \mathbb{P}(X \leq x).$$

Usaremos siempre $\leq$. Saporta usa $\mathbb{P}(X < x)$ en la edición consultada; no se trasladan sus convenciones de continuidad ni sus extremos de intervalos sin ajustarlos.

Teorema 6. F_X es no decreciente, continua por la derecha y satisface

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

Además, con $F_X(x-) = \lim_{t \uparrow x} F_X(t)$,

$$F_X(x-) = \mathbb{P}(X < x), \quad \mathbb{P}(X = x) = F_X(x) - F_X(x-).$$

Demostración. Si $x \leq y$, $\{X \leq x\} \subset \{X \leq y\}$, y la monotonía de $\mathbb{P}$ prueba la de F_X . Como X toma valores reales finitos,

$$\{X \leq n\} \uparrow \Omega, \quad \{X \leq -n\} \downarrow \emptyset.$$

La continuidad de $\mathbb{P}$ da los límites a lo largo de enteros; la monotonía los extiende al límite real.

Si $x_n \downarrow x$, entonces $\{X \leq x_n\} \downarrow \{X \leq x\}$, de donde $F_X(x_n) \rightarrow F_X(x)$. Esta es la continuidad por la derecha.

Si $x_n \uparrow x$ con $x_n < x$, entonces $\{X \leq x_n\} \uparrow \{X < x\}$. Por continuidad desde abajo, $F_X(x-) = \mathbb{P}(X < x)$. Finalmente, $\{X \leq x\} = \{X < x\} \cup \{X = x\}$ es una unión disjunta; restar prueba la fórmula del salto. $\square$

Corolario 7: probabilidades de intervalos. Para $a < b$,

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= F_X(b) - F_X(a), \\ \mathbb{P}(a \leq X \leq b) &= F_X(b) - F_X(a-), \\ \mathbb{P}(a < X < b) &= F_X(b-) - F_X(a), \\ \mathbb{P}(a \leq X < b) &= F_X(b-) - F_X(a-). \end{aligned}$$

Demostración. Cada fórmula resta la probabilidad de la semirrecta que se excluye de la semirrecta que se incluye. Por ejemplo, $\{X \leq b\} = \{X < a\} \cup \{a \leq X \leq b\}$, disjuntamente, prueba la segunda. Las otras descomposiciones son idénticas con sus respectivos extremos. $\square$

Consecuencia. F_X es continua en x si y solo si $\mathbb{P}(X = x) = 0$. Una función de distribución continua no tiene átomos; eso, por sí solo, no afirma que admita densidad.

Sesión 2 · 4. Tres tipos de ley

Discreta. Si $\mathbb{P}(X \in \{x_1, x_2, \dots\}) = 1$, con valores distintos, entonces $p_k = \mathbb{P}(X = x_k)$ y

$$\mu_X(C) = \sum_{k: x_k \in C} p_k, \quad F_X(x) = \sum_{k: x_k \leq x} p_k.$$

Estas fórmulas resultan de la aditividad sobre los singletons disjuntos; el complemento del conjunto de valores tiene masa cero. Para $X = \mathbf{1}_A$, $p = \mathbb{P}(A)$,

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - p, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

Se llama ley de Bernoulli de parámetro p . Las masas son los saltos.

Con densidad. La ley admite densidad si hay $f \geq 0$ medible con $\int_{\mathbb{R}} f \, dx = 1$ y $\mu_X(C) = \int_C f \, dx$ para todo boreliano C . Entonces

$$F_X(x) = \int_{-\infty}^x f(t) \, dt, \quad \mathbb{P}(X = x) = 0.$$

La segunda igualdad se debe a que un singleton tiene medida de Lebesgue cero. Una densidad es una función que se integra; $f(x)$ no es la probabilidad de $X = x$ y puede ser mayor que uno. Por el teorema fundamental para la integral de Lebesgue, $F'_X = f$ casi en todas partes, no necesariamente en cada punto.

Ejemplo. $f(x) = 2x\mathbf{1}_{(0,1)}(x)$ integra uno y produce

$$F_X(x) = \begin{cases} 0, & x \leq 0, \\ x^2, & 0 < x < 1, \\ 1, & x \geq 1. \end{cases} \quad \mathbb{P}(1/2 < X \leq 1) = 1 - \frac{1}{4} = \frac{3}{4}.$$

La existencia del modelo puede verse tomando como espacio muestral $\mathbb{R}$, la probabilidad $\mu(C) = \int_C f \, dx$ y la variable identidad. La aditividad de μ se obtiene por convergencia monótona aplicada a las sumas de indicadores disjuntos.

Mixta: cero o tiempo positivo. Para $0 < q < 1$, definir

$$\mu(C) = q\mathbf{1}_{\{0 \in C\}} + \frac{1-q}{2}\lambda(C \cap (1, 3)).$$

Es una probabilidad: combina la masa unitaria δ_0 en cero y la ley uniforme en $(1, 3)$. Su función de distribución es

$$F(x) = \begin{cases} 0, & x < 0, \\ q, & 0 \leq x < 1, \\ q + (1-q)(x-1)/2, & 1 \leq x < 3, \\ 1, & x \geq 3. \end{cases}$$

Tiene un salto q en cero y una parte con densidad. No tiene una densidad global respecto de Lebesgue: la integral sobre $\{0\}$ sería cero, pero su masa es q . En particular, $\mathbb{P}(0 < X \leq 2) = (1-q)/2$ y $\mathbb{P}(0 \leq X \leq 2) = q + (1-q)/2$.

Anexo de la sesión 2 · Caracterización completa

Lectura complementaria con demostración. No se exigirá reproducir esta prueba en una evaluación si no se ha trabajado en clase. El resultado explica por qué una función de distribución determina una ley y permite construirla.

Teorema 8. Sea $F : \mathbb{R} \rightarrow [0, 1]$ no decreciente, continua por la derecha, con límites 0 y 1 en $-\infty$ y $+\infty$. Existe una única probabilidad μ en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ con $\mu((-\infty, x]) = F(x)$.

Demostración. Existencia. En $\Omega = (0, 1)$ con probabilidad uniforme, para $0 < u < 1$ poner

$$Q(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}.$$

El conjunto es no vacío por el límite en $+\infty$ y está acotado inferiormente por el límite en $-\infty$. Por tanto $Q(u)$ es real. Si $a = Q(u)$, para cada n hay $y_n < a + 1/n$ con $F(y_n) \geq u$. Luego $F(a + 1/n) \geq u$; la continuidad por la derecha da $F(a) \geq u$. Así el ínfimo pertenece al conjunto.

En consecuencia, para cualquier x ,

$$Q(u) \leq x \iff u \leq F(x).$$

La implicación hacia la derecha usa $F(Q(u)) \geq u$ y monotonía; la inversa usa que x pertenece al conjunto cuyo ínfimo se toma. Por ello $\{u : Q(u) \leq x\} = (0, F(x)] \cap (0, 1)$ es boreliano, y Q es medible por la proposición 5. La ley de Q satisface

$$\mathbb{P}(Q \leq x) = \lambda((0, F(x)] \cap (0, 1)) = F(x).$$

Unicidad. Recordemos el lema π - λ de teoría de la medida: una clase cerrada bajo intersecciones finitas genera un σ -álgebra contenida en cualquier sistema de Dynkin que la contenga. Un sistema de Dynkin contiene el espacio total y es cerrado bajo complementos y uniones numerables disjuntas.

Si μ, ν son dos probabilidades con la misma F , la clase $\mathcal{D} = \{C \in \mathcal{B}(\mathbb{R}) : \mu(C) = \nu(C)\}$ contiene a $\mathbb{R}$, es cerrada bajo complementos (ambas masas totales son uno) y bajo uniones disjuntas (por aditividad). Contiene $\mathcal{P} = \{\mathbb{R}\} \cup \{(-\infty, x] : x \in \mathbb{R}\}$, cerrada bajo intersecciones y generadora de $\mathcal{B}(\mathbb{R})$. El lema da $\mathcal{D} = \mathcal{B}(\mathbb{R})$, lo que prueba la unicidad. $\square$

Qué se ha usado como prerrequisito. Medida de Lebesgue, convergencia monótona, el teorema fundamental de la integral de Lebesgue y el lema π - λ . Las aplicaciones nuevas se han justificado; no se repite la construcción de medidas ni la demostración de esos resultados del curso previo.

Lecturas de apoyo. G. Saporta, *Probabilités, analyse des données et statistique*, 2.^a ed., 2006: capítulo 1, §§1.1–1.3, y capítulo 2, §2.1.1 (ajustar la convención de F). R. Durrett, *Probability: Theory and Examples*, ed. 4.1: §§1.1 y 1.3. S. Sheffield, MIT 18.175 (2014): clase 1 y selección de la clase 2 sobre distribuciones en la recta. Estas notas y sus ejemplos son una elaboración para CM4H1, no una traducción literal.

Capítulo 1

Semana 2: esperanza, desigualdades e independencia

1.1. Esperanza, momentos y desigualdades

Objetivo de la sesión. Calcular integrales probabilísticas y demostrar las desigualdades que controlan colas.

Para una variable no negativa se define $\mathbb{E}X = \int X \, d\mathbb{P} \in [0, \infty]$. Si X es integrable, $\mathbb{E}X = \mathbb{E}X^+ - \mathbb{E}X^-$. La esperanza depende solo de la ley:

$$\mathbb{E}g(X) = \int_{\mathbb{R}} g(x) \mu_X(dx)$$

cuando $g \geq 0$ o $g(X)$ es integrable. Esta fórmula se prueba primero para indicadores, luego para funciones simples y finalmente por convergencia monótona; para funciones con signo se aplican las partes positiva y negativa.

Proposición 1.1 (Markov y Chebyshev). Si $Y \geq 0$ y $a > 0$, entonces $\mathbb{P}(Y \geq a) \leq \mathbb{E}Y/a$. Si $X \in L^2$, para $t > 0$,

$$\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \frac{\text{Var}(X)}{t^2}.$$

Demostración. La desigualdad puntual $a\mathbf{1}_{\{Y \geq a\}} \leq Y$ y la monotonía de la integral dan $a\mathbb{P}(Y \geq a) \leq \mathbb{E}Y$. Aplicar lo anterior a $Y = (X - \mathbb{E}X)^2$ y $a = t^2$ prueba Chebyshev. $\square$

Teorema 1.2 (Jensen). Si φ es convexa en un intervalo I , X toma valores en I , y las integrales involucradas existen, entonces $\varphi(\mathbb{E}X) \leq \mathbb{E}\varphi(X)$.

Demostración. Sea $m = \mathbb{E}X$. Una función convexa admite en cada punto interior una recta soporte: existe s tal que $\varphi(x) \geq \varphi(m) + s(x - m)$. Integrar produce $\mathbb{E}\varphi(X) \geq \varphi(m) + s(\mathbb{E}X - m) = \varphi(m)$. En un extremo se usa un soporte lateral o aproximación desde el interior. $\square$

Como aplicaciones, $|\mathbb{E}X| \leq \mathbb{E}|X|$, $(\mathbb{E}|X|)^2 \leq \mathbb{E}X^2$ y, para $X > 0$, $(\mathbb{E}X)^{-1} \leq \mathbb{E}(X^{-1})$ bajo integrabilidad.

1.2. Ley conjunta, independencia y convolución

Objetivo de la sesión. Pasar de leyes marginales a leyes conjuntas y obtener la ley de una suma independiente.

La ley conjunta de (X, Y) es la medida imagen sobre $\mathbb{R}^2$. Sus marginales se recuperan por $\mu_X(A) = \mu_{(X,Y)}(A \times \mathbb{R})$. Las variables son independientes si

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$$

para todo par de borelianos. Por el lema π - λ , basta comprobarlo en semirrectas. La independencia equivale a que la ley conjunta sea $\mu_X \otimes \mu_Y$.

Proposición 1.3. *Si X, Y son independientes y f, g son medibles con producto integrable (o no negativo),*

$$\mathbb{E}[f(X)g(Y)] = \mathbb{E}f(X) \mathbb{E}g(Y).$$

Si además están en L^2 , $\text{Cov}(X, Y) = 0$ y $\text{Var}(X + Y) = \text{Var } X + \text{Var } Y$.

Demostración. La identidad se sigue de Tonelli–Fubini para la medida producto. La covarianza resulta tomando $f(x) = x$, $g(y) = y$. Expandir el cuadrado centrado da la fórmula de la varianza. $\square$

El recíproco de la incorrelación es falso: si X es simétrica, no degenerada y con cuarto momento finito, $\text{Cov}(X, X^2) = \mathbb{E}X^3 - \mathbb{E}X\mathbb{E}X^2 = 0$, pero X^2 es función de X y no es independiente de él.

Proposición 1.4 (Convolución). *Si X, Y son independientes, $\mu_{X+Y}(C) = \int \mu_X(C - y)\mu_Y(dy)$. Si tienen densidades f, g , una densidad de $X + Y$ es*

$$(f * g)(z) = \int_{\mathbb{R}} f(z - y)g(y) dy.$$

Demostración. Escribir $\mathbb{P}(X + Y \in C) = \iint \mathbf{1}_C(x + y)\mu_X(dx)\mu_Y(dy)$ y aplicar Tonelli. En el caso de densidades, sustituir $z = x + y$ en la integral interior y volver a aplicar Tonelli. $\square$

Capítulo 2

Semana 3: transformaciones, familias y vectores

2.1. Transformaciones y modelos fundamentales

Objetivo de la sesión. Obtener leyes mediante preimágenes y reconocer mecanismos que producen distribuciones.

Si $Y = h(X)$, su ley se determina por $F_Y(y) = \mathbb{P}(h(X) \leq y)$. Cuando h es estrictamente monótona y diferenciable, la sustitución en integrales produce

$$f_Y(y) = f_X(h^{-1}(y)) \left| \frac{d}{dy} h^{-1}(y) \right|$$

en la imagen. Si hay varias ramas regulares, se suman sus contribuciones. La fórmula no debe aplicarse en puntos críticos sin revisar las preimágenes.

Los modelos centrales se presentan por su mecanismo: Bernoulli para un indicador; binomial para una suma de Bernoulli independientes; Poisson para conteos raros; exponencial para espera sin memoria; normal para agregación y geometría cuadrática. Por ejemplo, si $X \sim \text{Exp}(\lambda)$,

$$\mathbb{P}(X > s + t \mid X > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}.$$

Recíprocamente, una supervivencia derecha continua S con $S(s+t) = S(s)S(t)$ y no degenerada es exponencial: $a(t) = -\log S(t)$ es aditiva y no decreciente, luego $a(t) = \lambda t$.

La función generadora de momentos se usará solo donde sea finita cerca de cero. La función característica $\varphi_X(t) = \mathbb{E}e^{itX}$ existe siempre y se estudiará en la semana 6.

2.2. Vectores, covarianza y muestras i.i.d.

Objetivo de la sesión. Organizar momentos de un vector y calcular media y varianza de estadísticas muestrales.

Para $X = (X_1, \dots, X_d)^T \in L^2$, $m = \mathbb{E}X$ y

$$\Sigma = \mathbb{E}[(X - m)(X - m)^T], \quad \Sigma_{ij} = \text{Cov}(X_i, X_j).$$

Para todo vector determinista a , $\text{Var}(a^T X) = a^T \Sigma a \geq 0$; por tanto Σ es simétrica semidefinida positiva. Si $Y = AX + b$, entonces $\mathbb{E}Y = Am + b$ y $\text{Cov}(Y) = A\Sigma A^T$.

Una muestra $X_1, \dots, X_n$ es i.i.d. si sus variables son independientes y tienen la misma ley. Para $\mathbb{E}X_1 = \mu$, $\text{Var } X_1 = \sigma^2 < \infty$,

$$\bar{X}_n = \frac{1}{n} \sum_{j=1}^n X_j, \quad \mathbb{E}\bar{X}_n = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Con $S_n^2 = (n-1)^{-1} \sum_j (X_j - \bar{X}_n)^2$,

$$\sum_j (X_j - \bar{X}_n)^2 = \sum_j (X_j - \mu)^2 - n(\bar{X}_n - \mu)^2.$$

Tomar esperanzas prueba $\mathbb{E}S_n^2 = \sigma^2$. No se ha supuesto normalidad; la ley exacta de S_n^2 sí requerirá el bloque gaussiano.

Proposición 2.1 (Cauchy–Schwarz para covarianzas). $|\text{Cov}(X, Y)|^2 \leq \text{Var}(X) \text{Var}(Y)$ para $X, Y \in L^2$.

Demostración. Para todo t , $0 \leq \text{Var}(X + tY) = \text{Var } X + 2t \text{Cov}(X, Y) + t^2 \text{Var } Y$. Si $\text{Var } Y > 0$, minimizar el trinomio en t da la desigualdad; el caso $\text{Var } Y = 0$ implica $Y = \mathbb{E}Y$ casi seguramente y covarianza cero. $\square$

Capítulo 3

Semana 4: modos de convergencia y Borel–Cantelli

3.1. Convergencias probabilísticas

Objetivo de la sesión. Distinguir convergencia casi segura, en probabilidad y en L^p , y probar sus implicaciones.

Se escribe $X_n \rightarrow X$ c.s. si la convergencia puntual ocurre fuera de un evento nulo; $X_n \rightarrow X$ en probabilidad si $\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$ para todo $\varepsilon > 0$; y en L^p si $\mathbb{E}|X_n - X|^p \rightarrow 0$.

Proposición 3.1. *La convergencia en L^p implica convergencia en probabilidad. La convergencia casi segura implica convergencia en probabilidad. La convergencia en probabilidad contiene una subsucesión que converge casi seguramente.*

Demostración. Markov da $\mathbb{P}(|X_n - X| > \varepsilon) \leq \varepsilon^{-p} \mathbb{E}|X_n - X|^p$. Para la segunda afirmación, $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \rightarrow 0$ c.s. y está dominada por uno; convergencia dominada da el límite de probabilidades. Para la tercera, elegir n_k creciente con $\mathbb{P}(|X_{n_k} - X| > 2^{-k}) \leq 2^{-k}$. Borel–Cantelli implica que solo finitos de esos eventos ocurren; por tanto $X_{n_k} \rightarrow X$ c.s. $\square$

Los recíprocos fallan. En $[0, 1]$, los intervalos que recorren sucesivamente las particiones diádicas tienen indicadores que convergen en probabilidad a cero pero no puntualmente en ningún punto. Para $X_n = n\mathbf{1}_{(0, 1/n)}$, se tiene convergencia c.s. a cero, pero $\mathbb{E}X_n = 1$, de modo que no hay convergencia en L^1 .

Teorema 3.2 (Ley débil con varianza finita). *Si (X_n) son i.i.d., $\mathbb{E}X_1 = \mu$ y $\text{Var } X_1 = \sigma^2 < \infty$, entonces $\bar{X}_n \rightarrow \mu$ en probabilidad.*

Demostración. Por independencia, $\text{Var}(\bar{X}_n) = \sigma^2/n$. Chebyshev da $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \sigma^2/(n\varepsilon^2) \rightarrow 0$. $\square$

3.2. Eventos límite y lemas de Borel–Cantelli

Objetivo de la sesión. Traducir ocurrencias infinitas a límites de eventos y controlar su probabilidad.

$$\limsup A_n = \bigcap_{m \geq 1} \bigcup_{n \geq m} A_n = \{A_n \text{ ocurre infinitas veces}\}, \quad \liminf A_n = \bigcup_{m \geq 1} \bigcap_{n \geq m} A_n.$$

Teorema 3.3 (Borel–Cantelli). (i) Si $\sum_n \mathbb{P}(A_n) < \infty$, entonces $\mathbb{P}(\limsup A_n) = 0$. (ii) Si los A_n son independientes y $\sum_n \mathbb{P}(A_n) = \infty$, entonces $\mathbb{P}(\limsup A_n) = 1$.

Demostración. Para (i), $\mathbb{P}(\bigcup_{n \geq m} A_n) \leq \sum_{n \geq m} \mathbb{P}(A_n) \rightarrow 0$; continuidad desde arriba concluye. Para (ii), para $N \geq m$,

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N (1 - \mathbb{P}(A_n)) \leq \exp\left(-\sum_{n=m}^N \mathbb{P}(A_n)\right) \rightarrow 0.$$

Continuidad desde arriba da probabilidad cero a que ninguno ocurra después de m ; la unión sobre m de esos eventos sigue siendo nula. $\square$

La independencia solo se usa en la segunda parte. Como aplicación, si X_n son independientes y $\mathbb{P}(|X_n| > \varepsilon)$ es sumable para cada ε racional positivo, entonces $X_n \rightarrow 0$ c.s.

Capítulo 4

Semana 5: desigualdad de Kolmogorov y ley fuerte

4.1. Máximos y series independientes

Objetivo de la sesión. Demostrar una desigualdad maximal y convertir varianzas sumables en convergencia casi segura.

Teorema 4.1 (Desigualdad maximal de Kolmogorov). *Sean $X_1, \dots, X_n$ independientes, centradas y con segundo momento finito; $S_k = \sum_{j \leq k} X_j$. Para $\lambda > 0$,*

$$\mathbb{P}\left(\max_{k \leq n} |S_k| \geq \lambda\right) \leq \frac{\text{Var}(S_n)}{\lambda^2}.$$

Demostración. Sea $A_k = \{|S_j| < \lambda, j < k; |S_k| \geq \lambda\}$. Los A_k son disjuntos y su unión es el evento maximal. Como $S_n = S_k + (S_n - S_k)$ y A_k, S_k dependen de $X_1, \dots, X_k$, mientras $S_n - S_k$ es independiente y centrado,

$$\mathbb{E}[S_n^2 \mathbf{1}_{A_k}] = \mathbb{E}[S_k^2 \mathbf{1}_{A_k}] + \mathbb{E}[(S_n - S_k)^2] \mathbb{P}(A_k) \geq \lambda^2 \mathbb{P}(A_k).$$

Sumar y usar disjunción da $\mathbb{E}S_n^2 \geq \sum_k \mathbb{E}[S_n^2 \mathbf{1}_{A_k}] \geq \lambda^2 \mathbb{P}(\cup_k A_k)$. □

Teorema 4.2 (Convergencia de series). *Si (X_n) son independientes, centradas, $X_n \in L^2$ y $\sum_n \text{Var } X_n < \infty$, entonces $\sum_n X_n$ converge casi seguramente y en L^2 .*

Demostración. En L^2 , las sumas parciales son de Cauchy porque $\mathbb{E}|S_n - S_m|^2 = \sum_{m < j \leq n} \text{Var } X_j$. Para la convergencia c.s., elegir n_r con $\sum_{j > n_r} \text{Var } X_j \leq 2^{-3r}$. Kolmogorov da

$$\mathbb{P}\left(\max_{n_r < k \leq n_{r+1}} |S_k - S_{n_r}| > 2^{-r}\right) \leq 2^{-r}.$$

Borel–Cantelli muestra que los máximos de bloque tienden a cero. La subsucesión S_{n_r} converge c.s. tras escogerla también con $\sum_r \mathbb{P}(|S_{n_r} - S| > 2^{-r}) < \infty$, usando convergencia L^2 . Ambos hechos dan $S_n \rightarrow S$ c.s. □

4.2. Truncamiento y ley fuerte i.i.d.

Objetivo de la sesión. Probar la ley fuerte bajo la hipótesis óptima de primer momento finito.

Lema 4.3 (Kronecker). *Si $b_n \uparrow \infty$ y $\sum_n x_n/b_n$ converge, entonces $b_n^{-1} \sum_{k \leq n} x_k \rightarrow 0$.*

Demostración. Si $s_n = \sum_{k \leq n} x_k/b_k \rightarrow s$, la suma por partes da $b_n^{-1} \sum_{k \leq n} x_k = b_n^{-1} \sum_{k < n} (b_k - b_{k+1})(s_k - s) + (s_n - s) + sb_1/b_n$. La contribución inicial desaparece al dividir por b_n y la cola se acota por $\sup_{k \geq N} |s_k - s|$; hacer primero $n \rightarrow \infty$ y luego $N \rightarrow \infty$ concluye. $\square$

Teorema 4.4 (Ley fuerte de los grandes números). *Si (X_n) son i.i.d. y $\mathbb{E}|X_1| < \infty$, entonces $n^{-1} \sum_{k=1}^n X_k \rightarrow \mathbb{E}X_1$ casi seguramente.*

Demostración. Poner $Y_n = X_n \mathbf{1}_{\{|X_n| \leq n\}}$. Como $\sum_n \mathbb{P}(X_n \neq Y_n) = \sum_n \mathbb{P}(|X_1| > n) \leq \mathbb{E}|X_1| < \infty$, Borel–Cantelli dice que ambas sucesiones difieren solo finitas veces.

Además,

$$\sum_{n \geq 1} \frac{\text{Var}(Y_n)}{n^2} \leq \sum_{n \geq 1} \frac{\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| \leq n\}}]}{n^2} < \infty.$$

Para justificar la última desigualdad, descomponer según $k-1 < |X_1| \leq k$ e intercambiar sumas: $\sum_{n \geq k} n^{-2} \leq C/k$, por lo que el total se acota por $C \sum_k k \mathbb{P}(k-1 < |X_1| \leq k) \leq C' \mathbb{E}|X_1|$.

El teorema de series aplicado a $(Y_n - \mathbb{E}Y_n)/n$ y Kronecker dan $n^{-1} \sum_{k \leq n} (Y_k - \mathbb{E}Y_k) \rightarrow 0$ c.s. Por convergencia dominada, $\mathbb{E}Y_n \rightarrow \mathbb{E}X_1$; el lema de Cesàro da $n^{-1} \sum_{k \leq n} \mathbb{E}Y_k \rightarrow \mathbb{E}X_1$. Reemplazar Y_k por X_k no cambia el límite, pues solo hay finitas diferencias. $\square$

Capítulo 5

Semana 6: convergencia débil y funciones características

5.1. Convergencia en distribución

Objetivo de la sesión. Usar funciones de distribución, mapeo continuo y Slutsky para obtener límites.

Se dice $X_n \Rightarrow X$ si $\mathbb{E}f(X_n) \rightarrow \mathbb{E}f(X)$ para toda f continua y acotada. En la recta esto equivale a $F_{X_n}(x) \rightarrow F_X(x)$ en cada punto de continuidad de F_X .

Proposición 5.1. *La convergencia en probabilidad implica convergencia en distribución. Si $X_n \Rightarrow X$ y g es continua, entonces $g(X_n) \Rightarrow g(X)$. Si $X_n \Rightarrow X$ y $Y_n \rightarrow c$ en probabilidad, entonces $X_n + Y_n \Rightarrow X + c$ y $X_n Y_n \Rightarrow cX$.*

Demostración. Toda subsucesión de una sucesión que converge en probabilidad contiene una subsucesión con convergencia c.s.; convergencia dominada aplicada a f prueba el primer enunciado. Para el mapeo, aplicar la definición a $f \circ g$. Para Slutsky, primero mostrar $(X_n, Y_n) \Rightarrow (X, c)$: fuera de una franja $|y - c| < \delta$, la probabilidad tiende a cero, y dentro de ella la continuidad uniforme de una función de prueba sobre compactos controla el cambio. Aplicar el mapeo continuo a suma y producto concluye. $\square$

La convergencia débil no permite, sin hipótesis adicionales, pasar momentos al límite. Por ejemplo, $X_n = n$ con probabilidad $1/n$ y cero en otro caso converge en probabilidad a cero, pero $\mathbb{E}X_n = 1$.

5.2. Funciones características

Objetivo de la sesión. Calcular transformadas, justificar su unicidad y convertir sumas independientes en productos.

$$\varphi_X(t) = \mathbb{E}e^{itX}, \quad |\varphi_X(t)| \leq 1, \quad \varphi_X(0) = 1, \quad \varphi_{X+Y} = \varphi_X \varphi_Y \quad (X \perp Y).$$

La continuidad en t se sigue de convergencia dominada. Si $\mathbb{E}|X|^k < \infty$, se puede derivar hasta orden k bajo la integral y $\varphi_X^{(j)}(0) = i^j \mathbb{E}X^j$. Con segundo momento,

$$\varphi_X(t) = 1 + it\mathbb{E}X - \frac{1}{2}t^2\mathbb{E}X^2 + o(t^2).$$

Teorema 5.2 (Unicidad). *Si $\varphi_X = \varphi_Y$, entonces X y Y tienen la misma ley.*

Idea completa mediante suavización. Sea Z_ε normal centrada, independiente, con varianza ε^2 . La función característica de $X + Z_\varepsilon$ es $\varphi_X(t)e^{-\varepsilon^2 t^2/2}$, integrable. La inversión de Fourier da una densidad determinada por esa función; por tanto $X + Z_\varepsilon$ y $Y + Z_\varepsilon$ tienen la misma ley. Al hacer $\varepsilon \downarrow 0$, $Z_\varepsilon \rightarrow 0$ en probabilidad, luego ambas leyes suavizadas convergen débilmente a las de X y Y . La unicidad del límite débil prueba la afirmación. La fórmula de inversión, recordatorio de análisis, se demuestra en el anexo técnico del curso. $\square$

Ejemplos: Bernoulli, $(1 - p) + pe^{it}$; Poisson(λ), $\exp\{\lambda(e^{it} - 1)\}$; normal $N(\mu, \sigma^2)$, $\exp(i\mu t - \sigma^2 t^2/2)$.

Capítulo 6

Semana 7: continuidad de Lévy y teorema central del límite

6.1. Teorema de continuidad

Objetivo de la sesión. Reconocer convergencia débil mediante funciones características.

Teorema 6.1 (Continuidad de Lévy). *Si $X_n \Rightarrow X$, entonces $\varphi_{X_n}(t) \rightarrow \varphi_X(t)$ para todo t . Recíprocamente, si $\varphi_{X_n}(t) \rightarrow \varphi(t)$ y φ es continua en cero, existe una ley con función característica φ y X_n converge débilmente a ella.*

La primera parte es inmediata porque $x \mapsto e^{itx}$ es continua y acotada. Para la recíproca, la identidad de suavización

$$\frac{1}{2h} \int_{-h}^h (1 - e^{itx}) dt = 1 - \frac{\sin(hx)}{hx}$$

y la continuidad de φ en cero proporcionan tensión de las leyes. Toda subsucesión tiene entonces una subsucesión débilmente convergente. La primera parte identifica la función característica de cualquier límite con φ ; unicidad obliga a que todos los límites sean el mismo. La demostración técnica se completa al final de esta semana.

6.2. Teorema central del límite

Objetivo de la sesión. Demostrar el TCL i.i.d. de varianza finita y usarlo con normalizaciones estadísticas.

Teorema 6.2 (TCL de Lindeberg–Lévy). *Si (X_k) son i.i.d., $\mathbb{E}X_1 = \mu$ y $0 < \text{Var } X_1 = \sigma^2 < \infty$, entonces*

$$\frac{\sum_{k=1}^n X_k - n\mu}{\sigma\sqrt{n}} \Rightarrow N(0, 1).$$

Demostración. Poner $Y_k = (X_k - \mu)/\sigma$. Su función característica satisface $\varphi_Y(u) = 1 - u^2/2 + o(u^2)$. Por independencia,

$$\varphi_{n^{-1/2} \sum Y_k}(t) = [\varphi_Y(t/\sqrt{n})]^n.$$

Como $n(\varphi_Y(t/\sqrt{n}) - 1) \rightarrow -t^2/2$ y $n|\varphi_Y(t/\sqrt{n}) - 1|^2 \rightarrow 0$, el logaritmo principal da convergencia a $e^{-t^2/2}$. Lévy concluye. $\square$

Si $S_n \rightarrow \sigma$ en probabilidad y $S_n > 0$, Slutsky reemplaza σ por S_n . La corrección de continuidad en aproximaciones binomiales mejora cálculos pero no forma parte del teorema asintótico. El parcial se realiza después de esta semana.

Anexo técnico: recíproca del teorema de continuidad

Escribamos μ_n para la ley de X_n . Para $h > 0$, Fubini da

$$A_{n,h} := \frac{1}{2h} \int_{-h}^h (1 - \Re \varphi_n(t)) dt = \int_{\mathbb{R}} \left(1 - \frac{\sin(hx)}{hx}\right) \mu_n(dx),$$

con el cociente igual a uno en $x = 0$. Si $|hx| \geq 2$, entonces $|\sin(hx)/(hx)| \leq 1/2$; por tanto

$$\mu_n\{|x| \geq 2/h\} \leq 2A_{n,h}.$$

Por convergencia puntual y acotación, convergencia dominada en $[-h, h]$ implica $A_{n,h} \rightarrow A_h = (2h)^{-1} \int_{-h}^h (1 - \Re \varphi(t)) dt$. La continuidad de φ en cero y $\varphi(0) = 1$ hacen $A_h \rightarrow 0$ cuando $h \downarrow 0$. Dado $\varepsilon > 0$, elegimos h con $2A_h < \varepsilon/2$; para todo n suficientemente grande la cota anterior es menor que ε . Las finitísimas leyes restantes también son tensas, de modo que, aumentando el radio, se obtiene $\sup_n \mu_n([-R, R]^c) < \varepsilon$.

Toda subsucesión posee, por el teorema de selección de Helly en la recta, una subsubsucesión cuyas funciones de distribución convergen en los puntos de continuidad de alguna función de distribución F ; la tensión impide pérdida de masa en infinito. Esta es convergencia débil a una probabilidad μ . La parte directa del teorema muestra que la característica de μ es φ . En particular, φ es una función característica. Por unicidad, dos límites subsecuenciales tienen la misma ley. Si la sucesión completa no convergiera a μ , existiría una subsubsucesión fuera de algún entorno débil de μ ; la tensión produciría dentro de ella una subsubsucesión convergente a μ , una contradicción. Luego $\mu_n \Rightarrow \mu$.