



Notas · Semana 8

Teoría de la Probabilidad · CM4H1

Esperanza condicional

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 8: información y esperanza condicional

Propósito. Construir la esperanza condicional como variable aleatoria, no como cociente informal, y dominar sus propiedades de cálculo.

Sesión 1. Información como sub- σ -álgebra; definición; existencia por Radon–Nikodym; unicidad; casos discretos.

Sesión 2. Linealidad, monotonía, extracción de factores, torre, independencia, Jensen y fórmulas con densidades.

Recordatorios de medida. Restricción de una medida, continuidad monótona, Radon–Nikodym, aproximación simple, convergencia dominada y teorema π - λ . Se usan sin redemostrar todos sus detalles.

Idea guía. $\mathbb{E}(X \mid \mathcal{G})$ es el promedio de X compatible con la información $\mathcal{G}$: es observable con $\mathcal{G}$ y conserva las integrales sobre todos los sucesos observables.

1.1. Información y definición

Objetivo de la sesión. Interpretar una sub- σ -álgebra y formular la propiedad que caracteriza la esperanza condicional.

Una sub- σ -álgebra $\mathcal{G} \subset \mathcal{F}$ representa las preguntas cuya respuesta está disponible. Si Z es $\mathcal{G}$ -medible, conocer $\mathcal{G}$ basta para conocer Z .

Definición 1.1. Para $X \in L^1$, una *versión* de $\mathbb{E}(X | \mathcal{G})$ es una variable Z tal que: (i) es $\mathcal{G}$ -medible; (ii) es integrable; y (iii)

$$\int_G Z d\mathbb{P} = \int_G X d\mathbb{P} \quad (G \in \mathcal{G}).$$

La tercera condición conserva el promedio en cada región distinguible por la información. Con $G = \Omega$ resulta $\mathbb{E}Z = \mathbb{E}X$. Se habla de versiones porque la definición determina Z solo casi seguramente.

Ejemplo: una partición. Una empresa clasifica una pieza únicamente por la línea G_j de la que procede. La pregunta natural es: *¿cuál es el costo medio de reparación cuando solo se conoce la línea?* Si (G_j) es una partición numerable y $\mathbb{P}(G_j) > 0$,

$$Z = \sum_j \frac{\mathbb{E}[X \mathbf{1}_{G_j}]}{\mathbb{P}(G_j)} \mathbf{1}_{G_j}.$$

La respuesta es constante dentro de cada celda, pues la información no distingue resultados dentro de ella. Para verificar la definición se suman las identidades sobre las celdas contenidas en $G \in \sigma(G_j : j \geq 1)$.

Dos extremos. Si X es $\mathcal{G}$ -medible, entonces $\mathbb{E}(X | \mathcal{G}) = X$. Si $\mathcal{G} = \{\emptyset, \Omega\}$, entonces $\mathbb{E}(X | \mathcal{G}) = \mathbb{E}X$.

1.2. Existencia por Radon–Nikodym

Recordatorio. Si $\nu \ll \mu$ son medidas σ -finitas, existe $h \geq 0$, única μ -c.s., tal que $\nu(A) = \int_A h d\mu$.

Teorema 1.2 (Existencia). Si $X \in L^1$ y $\mathcal{G} \subset \mathcal{F}$, existe $\mathbb{E}(X \mid \mathcal{G})$.

Demostración. Primero sea $X \geq 0$. Sobre $(\Omega, \mathcal{G})$ definimos

$$\nu(G) = \int_G X d\mathbb{P}.$$

La convergencia monótona prueba la aditividad numerable. Si $\mathbb{P}(G) = 0$, entonces $\nu(G) = 0$; por ello $\nu \ll \mathbb{P}|_{\mathcal{G}}$. Radon–Nikodym produce una función $Z \geq 0$, $\mathcal{G}$ -medible, tal que $\nu(G) = \int_G Z d\mathbb{P}$. Como $\nu(\Omega) = \mathbb{E}X < \infty$, también $Z \in L^1$.

Para $X \in L^1$, escribimos $X = X^+ - X^-$. Construimos $Z^+ = \mathbb{E}(X^+ \mid \mathcal{G})$ y $Z^- = \mathbb{E}(X^- \mid \mathcal{G})$; entonces $Z = Z^+ - Z^-$ cumple las tres condiciones. $\square$

El teorema entrega un objeto caracterizado por integrales, no siempre una fórmula puntual. Las fórmulas discretas y con densidades son representaciones particulares.

Caso de un suceso. Si $\mathcal{G} = \sigma(A)$ y $0 < \mathbb{P}(A) < 1$,

$$\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}(X \mid A)\mathbf{1}_A + \mathbb{E}(X \mid A^c)\mathbf{1}_{A^c}.$$

Aquí $\mathbb{E}(X \mid A)$ es un número, mientras que $\mathbb{E}(X \mid \mathcal{G})$ es una variable. Confundirlos elimina la dependencia respecto de la información observada.

1.3. Unicidad y clase de prueba

Teorema 1.3 (Unicidad). *Si Z_1 y Z_2 satisfacen la definición, entonces $Z_1 = Z_2$ c.s.*

Demostración. Para $G = \{Z_1 > Z_2\} \in \mathcal{G}$,

$$\int_G (Z_1 - Z_2) d\mathbb{P} = 0.$$

El integrando es no negativo, así que es cero c.s. en G y $\mathbb{P}(Z_1 > Z_2) = 0$. Intercambiar índices termina la prueba. $\square$

Para comprobar una candidata Z basta verificar medibilidad, integrabilidad e identidad de integrales. Puede reducirse la clase de conjuntos.

Lema de prueba. Suponga que $\mathcal{C}$ es un π -sistema que genera $\mathcal{G}$ y contiene Ω . Si Z es $\mathcal{G}$ -medible e integrable y

$$\mathbb{E}[Z\mathbf{1}_C] = \mathbb{E}[X\mathbf{1}_C] \quad (C \in \mathcal{C}),$$

entonces Z es una versión de $\mathbb{E}(X \mid \mathcal{G})$.

Demostración. Las aplicaciones $G \mapsto \int_G Z, d\mathbb{P}$ y $G \mapsto \int_G X, d\mathbb{P}$ son medidas con signo finitas. Aplicando el argumento de unicidad de medidas a partes positivas y negativas, o separando signos mediante una constante, la clase donde coinciden es un sistema de Dynkin. El teorema π - λ extiende la igualdad desde $\mathcal{C}$ hasta $\sigma(\mathcal{C}) = \mathcal{G}$. $\square$

Este criterio será útil para condicionar respecto de una variable y, más adelante, para demostrar propiedades de vectores gaussianos y martingalas.

1.4. Cálculo discreto

Si Y toma valores y_j con masas positivas,

$$\mathbb{E}(X | Y) = g(Y), \quad g(y_j) = \frac{\mathbb{E}[X \mathbf{1}_{\{Y=y_j\}}]}{\mathbb{P}(Y = y_j)}.$$

La expresión $\mathbb{E}(X | Y)$ abrevia $\mathbb{E}(X | \sigma(Y))$.

Pregunta. Se lanzan dos dados justos. Sabiendo únicamente la suma, ¿cuál es el valor medio del primer dado?

Modelo. $\Omega = \{1, \dots, 6\}^2$ con masa $1/36$; $X_1(i, j) = i$, $X_2(i, j) = j$ y $S = X_1 + X_2$. Dentro de $\{S = s\}$, el intercambio $(i, j) \leftrightarrow (j, i)$ conserva probabilidades. Luego

$$\mathbb{E}(X_1 | S = s) = \mathbb{E}(X_2 | S = s).$$

Como $X_1 + X_2 = s$ en esa celda, ambas esperanzas suman s , de modo que

$$\mathbb{E}(X_1 | S) = S/2.$$

Ley total de la esperanza.

$$\mathbb{E}X = \sum_j \mathbb{E}(X | Y = y_j) \mathbb{P}(Y = y_j),$$

que es simplemente $\mathbb{E}\mathbb{E}(X | Y) = \mathbb{E}X$.

Advertencia. Si Y es continua, normalmente $\mathbb{P}(Y = y) = 0$ y el cociente elemental no define el condicionamiento. Se necesita una distribución condicional regular o una fórmula con densidades, válida para casi todo y .

1.5. Propiedades estructurales

Objetivo de la sesión. Obtener reglas de cálculo desde la definición y la unicidad.

Linealidad. Para $X, Y \in L^1$,

$$\mathbb{E}(aX + bY \mid \mathcal{G}) = a\mathbb{E}(X \mid \mathcal{G}) + b\mathbb{E}(Y \mid \mathcal{G}).$$

Se verifica medibilidad e identidad de integrales y se usa unicidad.

Positividad. Si $X \geq 0$, entonces $\mathbb{E}(X \mid \mathcal{G}) \geq 0$ c.s. Si una versión Z fuese negativa en $G = \{Z < 0\} \in \mathcal{G}$, se tendría $\int_G Z < 0$ pero $\int_G X \geq 0$. Por tanto, $X \leq Y$ implica $\mathbb{E}(X \mid \mathcal{G}) \leq \mathbb{E}(Y \mid \mathcal{G})$.

Contracción. Jensen con $|x|$ produce

$$|\mathbb{E}(X \mid \mathcal{G})| \leq \mathbb{E}(|X| \mid \mathcal{G}), \quad \|\mathbb{E}(X \mid \mathcal{G})\|_1 \leq \|X\|_1.$$

Dominada condicional. Si $X_n \rightarrow X$ c.s. y $|X_n| \leq Y \in L^1$, entonces

$$\|\mathbb{E}(X_n \mid \mathcal{G}) - \mathbb{E}(X \mid \mathcal{G})\|_1 \leq \mathbb{E}|X_n - X| \rightarrow 0.$$

Esto da convergencia en L^1 , no necesariamente convergencia casi segura de toda la sucesión.

Fatou condicional. Para $X_n \geq 0$,

$$\mathbb{E}(\liminf X_n \mid \mathcal{G}) \leq \liminf \mathbb{E}(X_n \mid \mathcal{G}) \quad \text{c.s.}$$

Se integra sobre cada $G \in \mathcal{G}$, se aplica Fatou ordinario y se usa la caracterización por integrales.

1.6. Extracción de factores e independencia

Teorema 1.4. Si Y es $\mathcal{G}$ -medible y acotada, y $X \in L^1$, entonces

$$\mathbb{E}(YX \mid \mathcal{G}) = Y\mathbb{E}(X \mid \mathcal{G}).$$

Demostración. Para $Y = \mathbf{1}_H$, $H \in \mathcal{G}$, y $G \in \mathcal{G}$,

$$\int_G \mathbf{1}_H \mathbb{E}(X \mid \mathcal{G}) d\mathbb{P} = \int_{G \cap H} \mathbb{E}(X \mid \mathcal{G}) d\mathbb{P} = \int_{G \cap H} X d\mathbb{P}.$$

Linealidad extiende a funciones simples. Si Y es acotada, tomar simples $Y_n \rightarrow Y$ uniformemente acotadas y aplicar convergencia dominada a $Y_n X$ y a $Y_n \mathbb{E}(X \mid \mathcal{G})$. $\square$

En particular, para toda decisión acotada Y basada en $\mathcal{G}$,

$$\mathbb{E}(YX) = \mathbb{E}[Y\mathbb{E}(X \mid \mathcal{G})].$$

Teorema 1.5. Si X es independiente de $\mathcal{G}$, entonces $\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}X$.

Demostración. Para $X = \mathbf{1}_A$, independencia da $\mathbb{P}(A \cap G) = \mathbb{P}(A)\mathbb{P}(G)$. Se extiende a simples no negativas, después por convergencia monótona a variables no negativas y por descomposición a L^1 . $\square$

La recíproca para una sola variable X es falsa: tener media condicional constante no implica independencia. Sí es suficiente exigir $\mathbb{E}[h(X) \mid \mathcal{G}] = \mathbb{E}h(X)$ para toda h boreliana acotada.

1.7. Propiedad de la torre

Teorema 1.6. Si $\mathcal{H} \subset \mathcal{G}$ y $X \in L^1$, entonces

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) = \mathbb{E}(X | \mathcal{H}).$$

Demostración. El lado izquierdo es $\mathcal{H}$ -medible. Para $H \in \mathcal{H} \subset \mathcal{G}$,

$$\int_H \mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) d\mathbb{P} = \int_H \mathbb{E}(X | \mathcal{G}) d\mathbb{P} = \int_H X, d\mathbb{P}.$$

La unicidad concluye. □

Consecuencias:

$$\mathbb{E}\mathbb{E}(X | \mathcal{G}) = \mathbb{E}X, \quad \mathbb{E}(\mathbb{E}(X | \mathcal{H}) | \mathcal{G}) = \mathbb{E}(X | \mathcal{H})$$

si $\mathcal{H} \subset \mathcal{G}$, pues la variable interna ya es $\mathcal{G}$ -medible.

Pregunta. Una aseguradora observa primero la región y luego la región junto con el tipo de vehículo. ¿Qué sucede si el pronóstico fino se vuelve a promediar reteniendo solo la región?

Modelo. Sea X el siniestro, R la región y T el tipo. Con $\mathcal{H} = \sigma(R)$ y $\mathcal{G} = \sigma(R, T)$,

$$\mathbb{E}(\mathbb{E}(X | R, T) | R) = \mathbb{E}(X | R).$$

La torre expresa coherencia entre niveles de información. Para σ -álgebras no comparables no existe una simplificación universal.

1.8. Jensen condicional

Teorema 1.7. Si φ es convexa y $X, \varphi(X) \in L^1$, entonces

$$\varphi(\mathbb{E}(X \mid \mathcal{G})) \leq \mathbb{E}(\varphi(X) \mid \mathcal{G}) \quad c.s.$$

Demostración. Una convexa finita es el supremo de una familia numerable de rectas soporte: $\varphi(x) = \sup_k (a_k x + b_k)$. Para cada k ,

$$a_k \mathbb{E}(X \mid \mathcal{G}) + b_k = \mathbb{E}(a_k X + b_k \mid \mathcal{G}) \leq \mathbb{E}(\varphi(X) \mid \mathcal{G}).$$

Tomar el supremo en el lado izquierdo prueba la afirmación. □

Para $p \geq 1$,

$$|\mathbb{E}(X \mid \mathcal{G})|^p \leq \mathbb{E}(|X|^p \mid \mathcal{G}), \quad \|\mathbb{E}(X \mid \mathcal{G})\|_p \leq \|X\|_p.$$

Con $\varphi(x) = x^2$ y $X \in L^2$,

$$\mathbb{E}[(X - \mathbb{E}(X \mid \mathcal{G}))^2] = \mathbb{E}(X^2) - \mathbb{E}[\mathbb{E}(X \mid \mathcal{G})^2].$$

Para probarla, expandir el cuadrado y usar extracción de factores:

$$\mathbb{E}[X\mathbb{E}(X \mid \mathcal{G})] = \mathbb{E}[\mathbb{E}(X \mid \mathcal{G})^2].$$

La semana siguiente interpretará esta identidad como proyección ortogonal y mejor predictor cuadrático.

1.9. Densidades y cálculo explícito

Si (X, Y) tiene densidad conjunta, para $f_Y(y) > 0$ definimos

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad g(y) = \int x f_{X|Y}(x | y), dx.$$

Entonces $g(Y)$ es una versión de $\mathbb{E}(X | Y)$.

Demostración. Para todo boreliano B , Tonelli–Fubini da

$$\int_{\{Y \in B\}} g(Y) d\mathbb{P} = \int_B g(y) f_Y(y) dy = \int_B \int x f_{X,Y}(x, y) dx dy = \mathbb{E}[X \mathbf{1}_{\{Y \in B\}}].$$

La clase $\{Y \in B\}$ genera $\sigma(Y)$; el lema de prueba concluye. Los valores de g donde $f_Y = 0$ se eligen arbitrariamente. $\square$

Ejemplo: dos fuentes Poisson. Sean $X \sim \text{Poi}(\lambda)$ y $Y \sim \text{Poi}(\mu)$ independientes. Observado $S = X + Y$, ¿cuántos eventos se atribuyen en promedio a la primera fuente? Para $0 \leq k \leq n$,

$$\mathbb{P}(X = k | S = n) = \binom{n}{k} p^k (1-p)^{n-k}, \quad p = \frac{\lambda}{\lambda + \mu}.$$

Así, $\mathbb{E}(X | S = n) = np$ y

$$\mathbb{E}(X | S) = \frac{\lambda}{\lambda + \mu} S.$$

Lecturas. Durrett: esperanza condicional. Saporta: condicionamiento y momentos. Notas MIT: formulación abstracta y convenciones.



Notas · Semana 9

Teoría de la Probabilidad · CM4H1

Predicción y descomposición de varianza

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 9: esperanza condicional como predictor

Propósito. Pasar de la definición por integrales a su significado geométrico y estadístico: proyección, mejor predictor, varianza explicada y modelos con información latente.

Sesión 1. Geometría de L^2 , ortogonalidad, teorema del mejor predictor y ley de varianza total.

Sesión 2. Predicción lineal, comparación con el predictor óptimo, mezclas y sumas aleatorias.

Recordatorios. Completitud de L^2 , subsucesión casi segura desde convergencia L^2 , Cauchy–Schwarz, truncamiento, Tonelli para series aleatorias y funciones generatrices.

1.1. El subespacio de información

Objetivo de la sesión. Probar que las variables observables forman un subespacio cerrado de L^2 .

En $L^2(\Omega, \mathcal{F}, \mathbb{P})$ usamos

$$\langle X, Y \rangle = \mathbb{E}(XY), \quad \|X\|_2 = (\mathbb{E}X^2)^{1/2}.$$

Para $\mathcal{G} \subset \mathcal{F}$, sea $L^2(\mathcal{G})$ el conjunto de clases de variables $\mathcal{G}$ -medibles con segundo momento finito.

Proposición 1.1. $L^2(\mathcal{G})$ es un subespacio cerrado de $L^2(\mathcal{F})$.

Demostración. La estabilidad por combinaciones lineales es inmediata. Sea $Y_n \in L^2(\mathcal{G})$ y $Y_n \rightarrow Y$ en L^2 . Seleccionamos una subsucesión Y_{n_k} con

$$\|Y_{n_k} - Y\|_2^2 \leq 2^{-k}.$$

Por Markov, $\mathbb{P}(|Y_{n_k} - Y| > \varepsilon) \leq 2^{-k}/\varepsilon^2$; Borel–Cantelli implica $Y_{n_k} \rightarrow Y$ c.s. El límite puntual de funciones $\mathcal{G}$ -medibles es $\mathcal{G}$ -medible fuera de un nulo. Como trabajamos con clases c.s. y el espacio es completo, elegimos una versión $\mathcal{G}$ -medible de Y . Luego $Y \in L^2(\mathcal{G})$. $\square$

Recordatorio de Hilbert. Todo subespacio cerrado M de un espacio de Hilbert admite una proyección ortogonal: para cada x existe un único $z \in M$ tal que $x - z \perp M$. Aquí identificaremos esa proyección sin invocar el teorema como caja negra.

1.2. Ortogonalidad de la esperanza condicional

Sea $X \in L^2$ y $Z = \mathbb{E}(X \mid \mathcal{G})$. Jensen asegura $Z \in L^2(\mathcal{G})$.

Teorema 1.2. Para todo $Y \in L^2(\mathcal{G})$,

$$\mathbb{E}[(X - Z)Y] = 0.$$

Demostración. Si Y es $\mathcal{G}$ -medible y acotada, la extracción de factores y la torre dan

$$\mathbb{E}[(X - Z)Y] = \mathbb{E}\{\mathbb{E}[(X - Z)Y \mid \mathcal{G}]\} = \mathbb{E}\{Y\mathbb{E}[X - Z \mid \mathcal{G}]\} = 0.$$

Para $Y \in L^2(\mathcal{G})$, trunque $Y_m = (-m) \vee (Y \wedge m)$. Entonces $Y_m \rightarrow Y$ en L^2 . Por Cauchy-Schwarz,

$$|\mathbb{E}[(X - Z)(Y - Y_m)]| \leq \|X - Z\|_2 \|Y - Y_m\|_2 \rightarrow 0.$$

Pasar al límite completa la prueba. □

Esta igualdad contiene la definición integral: al tomar $Y = \mathbf{1}_G$, $G \in \mathcal{G}$, recuperamos $\int_G (X - Z)d\mathbb{P} = 0$. En L^2 , por tanto, la esperanza condicional puede definirse equivalentemente mediante ortogonalidad.

Interpretación. El error $X - Z$ no tiene correlación con ninguna variable cuadrado-integrable construida a partir de la información disponible. No queda una corrección lineal basada en $\mathcal{G}$ que reduzca el error.

1.3. Mejor predictor cuadrático

Teorema 1.3. Para todo $Y \in L^2(\mathcal{G})$,

$$\mathbb{E}(X - Y)^2 = \mathbb{E}(X - Z)^2 + \mathbb{E}(Z - Y)^2, \text{ donde } Z = \mathbb{E}(X \mid \mathcal{G}).$$

En consecuencia, Z es el único minimizador c.s. del error cuadrático entre los predictores $\mathcal{G}$ -medibles.

Demostración. Escribimos $X - Y = (X - Z) + (Z - Y)$ y expandimos. El término cruzado es

$$2\mathbb{E}[(X - Z)(Z - Y)] = 0$$

porque $Z - Y \in L^2(\mathcal{G})$. La identidad de Pitágoras resulta. El segundo término es no negativo y se anula únicamente si $Y = Z$ c.s. $\square$

Pregunta. Si solo se conoce una medición ruidosa Y , ¿qué función $g(Y)$ predice mejor a X en error cuadrático medio?

Modelo. La clase admisible es $L^2(\sigma(Y))$, es decir, variables de la forma $g(Y)$ bajo condiciones usuales. La respuesta es

$$g(Y) = \mathbb{E}(X \mid Y).$$

No se restringe g a ser lineal. Por ello la esperanza condicional nunca tiene error mayor que el mejor predictor afín.

Caso trivial. Si no se observa información, $\mathcal{G} = \{\emptyset, \Omega\}$ y el mejor predictor constante es $\mathbb{E}X$; el error mínimo es $\text{Var } X$.

1.4. Varianza condicional y varianza total

Definimos

$$\text{Var}(X \mid \mathcal{G}) = \mathbb{E}[(X - \mathbb{E}(X \mid \mathcal{G}))^2 \mid \mathcal{G}] = \mathbb{E}(X^2 \mid \mathcal{G}) - \mathbb{E}(X \mid \mathcal{G})^2.$$

La segunda identidad se obtiene expandiendo y extrayendo los factores $\mathcal{G}$ -medibles.

Teorema 1.4 (Varianza total). Si $X \in L^2$, entonces

$$\text{Var } X = \mathbb{E}[\text{Var}(X \mid \mathcal{G})] + \text{Var}(\mathbb{E}(X \mid \mathcal{G})).$$

Demostración. Sea $Z = \mathbb{E}(X \mid \mathcal{G})$. Descomponemos

$$X - \mathbb{E}X = (X - Z) + (Z - \mathbb{E}X).$$

Los sumandos son ortogonales, porque $Z - \mathbb{E}X \in L^2(\mathcal{G})$. Tomar normas al cuadrado da

$$\text{Var } X = \mathbb{E}(X - Z)^2 + \mathbb{E}(Z - \mathbb{E}X)^2.$$

La torre identifica el primer término con $\mathbb{E} \text{Var}(X \mid \mathcal{G})$ y $\mathbb{E}Z = \mathbb{E}X$ identifica el segundo. $\square$

La primera parte es variación residual dentro de los grupos de información; la segunda es variación entre sus medias. Ninguna es negativa, por lo cual

$$\text{Var}(\mathbb{E}(X \mid \mathcal{G})) \leq \text{Var } X.$$

Más información reduce el error cuadrático promedio, aunque la varianza condicional puntual no tiene que disminuir para cada ω .

1.5. Predicción lineal

Objetivo de la sesión. Derivar las ecuaciones normales y compararlas con la esperanza condicional. Buscamos a, b que minimicen $Q(a, b) = \mathbb{E}[(X - a - bY)^2]$, suponiendo segundos momentos y $\text{Var } Y > 0$.

Centrar variables separa la constante. Para cada b , el mejor a satisface $a = \mathbb{E}X - b\mathbb{E}Y$. Entonces

$$Q(b) = \mathbb{E}[(X - \mathbb{E}X) - b(Y - \mathbb{E}Y)]^2 = \text{Var } X - 2b \text{Cov}(X, Y) + b^2 \text{Var } Y.$$

Completar cuadrados o derivar da

$$b^* = \frac{\text{Cov}(X, Y)}{\text{Var } Y}, \quad a^* = \mathbb{E}X - b^*\mathbb{E}Y.$$

El error mínimo lineal es

$$\text{Var } X - \frac{\text{Cov}(X, Y)^2}{\text{Var } Y}.$$

Cauchy–Schwarz garantiza que es no negativo.

Ecuaciones normales. El residuo $R = X - a^* - b^*Y$ satisface $\mathbb{E}R = 0$ y $\mathbb{E}(RY) = 0$: es ortogonal al espacio generado por 1 y Y .

Comparación. El predictor $\mathbb{E}(X | Y)$ minimiza sobre todas las funciones cuadrado-integrables de Y , mientras que $a^* + b^*Y$ minimiza solo sobre funciones afines. Coinciden si $\mathbb{E}(X | Y)$ es afín; esto ocurrirá para vectores conjuntamente gaussianos.

1.6. Mezclas y variable latente

Pregunta. Una población combina dos subpoblaciones con distintas medias y varianzas. ¿Qué parte de la variabilidad total proviene de diferencias internas y qué parte de las diferencias entre grupos?

Modelo. Sea $C \in \{1, 2\}$ el grupo, $\mathbb{P}(C = 1) = p$, y

$$\mathbb{E}(X \mid C = i) = \mu_i, \text{ y } \text{Var}(X \mid C = i) = \sigma_i^2.$$

Por la torre,

$$\mathbb{E}X = p\mu_1 + (1 - p)\mu_2.$$

Por varianza total,

$$\text{Var } X = p\sigma_1^2 + (1 - p)\sigma_2^2 + p(1 - p)(\mu_1 - \mu_2)^2.$$

El último término es la varianza entre grupos. Puede ser grande aunque ambas varianzas internas sean pequeñas.

Demostración. La esperanza de la varianza condicional es $p\sigma_1^2 + (1 - p)\sigma_2^2$. Además, $\mathbb{E}(X \mid C)$ toma valores μ_1, μ_2 con probabilidades $p, 1 - p$, cuya varianza es $p(1 - p)(\mu_1 - \mu_2)^2$. $\square$

Advertencia estadística. Una mezcla de normales no suele ser normal. Condicionar en el grupo simplifica la ley, pero al eliminar la etiqueta aparece heterogeneidad y, a veces, multimodalidad.

1.7. Sumas aleatorias

Sea N entero no negativo, independiente de una sucesión i.i.d. (X_k) , con $\mathbb{E}X_1 = \mu$, $\text{Var } X_1 = \sigma^2$. Defina $S_N = \sum_{k=1}^N X_k$ y $S_0 = 0$.

Condicionado en $N = n$,

$$\mathbb{E}(S_N \mid N = n) = n\mu, \text{ y } \text{Var}(S_N \mid N = n) = n\sigma^2.$$

Por torre y varianza total,

$$\mathbb{E}S_N = \mu\mathbb{E}N, \text{ y } \text{Var}(S_N) = \sigma^2\mathbb{E}N + \mu^2 \text{Var } N.$$

Demostración. La independencia asegura que, bajo $N = n$, los primeros n sumandos conservan su ley conjunta. Así $\mathbb{E}(S_N \mid N) = N\mu$ y $\text{Var}(S_N \mid N) = N\sigma^2$. Aplicar las dos identidades totales produce las fórmulas. $\square$

Pregunta. En un día llegan N reclamos y cada costo es X_k . ¿Cómo se separan la incertidumbre por cantidad de reclamos y la incertidumbre por severidad? La primera contribuye $\mu^2 \text{Var } N$ y la segunda $\sigma^2\mathbb{E}N$.

La independencia es una hipótesis, no una consecuencia de la notación S_N . Si el número de reclamos depende de severidades anticipadas, las fórmulas pueden fallar.

1.8. Transformadas de sumas compuestas

Si $G_N(s) = \mathbb{E}(s^N)$ es la función generatriz de N y $M_X(t) = \mathbb{E}(e^{tX_1})$ existe, entonces

$$M_{S_N}(t) = \mathbb{E}[M_X(t)^N] = G_N(M_X(t)).$$

Demostración. Condicionando en N y usando independencia,

$$\mathbb{E}(e^{tS_N} \mid N = n) = M_X(t)^n.$$

La torre completa la identidad. Para funciones características no se exige existencia de la MGF:

$$\varphi_{S_N}(t) = G_N(\varphi_X(t)).$$

□

Si $N \sim \text{Poi}(\lambda)$,

$$\varphi_{S_N}(t) = \exp\{\lambda(\varphi_X(t) - 1)\},$$

la función característica de una distribución Poisson compuesta.

Ejemplo. Si además $X_k \equiv 1$, entonces $S_N = N$. Si X_k es Bernoulli(q), el adelgazamiento Poisson produce $S_N \sim \text{Poi}(\lambda q)$, pues

$$\exp\{\lambda[(1 - q + qe^{it}) - 1]\} = \exp\{\lambda q(e^{it} - 1)\}.$$

Recordatorio de Tonelli. Para $X_k \geq 0$, también puede escribirse $S_N = \sum_{k \geq 1} X_k \mathbf{1}_{\{N \geq k\}}$ e intercambiar suma y esperanza por Tonelli. Esta vía hace visibles las hipótesis cuando no hay segundos momentos.



Notas · Semana 10

Teoría de la Probabilidad · CM4H1

Vectores gaussianos

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 10: estructura gaussiana multivariada

Propósito. Definir vectores gaussianos sin depender de densidades, caracterizar su ley, estudiar transformaciones lineales y calcular distribuciones condicionales.

Sesión 1. Definiciones equivalentes, función característica, existencia, transformaciones, independencia y degeneración.

Sesión 2. Regresión gaussiana, complemento de Schur, condicionamiento y construcción mediante residuos independientes.

Recordatorios. Matrices semidefinidas positivas, raíces cuadradas espectrales, funciones características y proyección ortogonal.

1.1. Definición y caracterización

Objetivo de la sesión. Reconocer la gaussianidad mediante todas las combinaciones lineales.

Definición 1.1. Un vector $X \in \mathbb{R}^d$ es gaussiano si $t^T X$ es normal unidimensional para todo $t \in \mathbb{R}^d$. Se permiten normales degeneradas.

Si $m = \mathbb{E}X$ y $\Sigma = \mathbb{E}[(X - m)(X - m)^T]$, entonces Σ es simétrica semidefinida positiva porque

$$t^T \Sigma t = \text{Var}(t^T X) \geq 0.$$

Como $t^T X \sim N(t^T m, t^T \Sigma t)$,

$$\varphi_X(t) = \mathbb{E}e^{it^T X} = \exp\{it^T m - \frac{1}{2}t^T \Sigma t\}.$$

La unicidad de funciones características muestra que m y Σ determinan completamente la ley.

Degeneración. Si $t^T \Sigma t = 0$, entonces $t^T (X - m) = 0$ c.s.; la ley vive en un subespacio afín. Por eso no todo vector gaussiano posee densidad respecto de Lebesgue en $\mathbb{R}^d$.

Convención. Escribimos $X \sim N_d(m, \Sigma)$ aun cuando Σ sea singular.

1.2. Existencia y representación lineal

Teorema 1.2. Para todo $m \in \mathbb{R}^d$ y toda matriz simétrica semidefinida positiva Σ , existe $X \sim N_d(m, \Sigma)$.

Demostración. Por el teorema espectral, $\Sigma = Q\Lambda Q^T$ con Λ diagonal no negativa. Sea $A = Q\Lambda^{1/2}$ y Z un vector de normales estándar independientes. Defina $X = m + AZ$. Entonces

$$\mathbb{E}X = m, \text{ y } \text{Cov}(X) = AA^T = \Sigma.$$

Para cada t , $t^T X = t^T m + (A^T t)^T Z$ es combinación lineal de normales independientes y, por funciones características, es normal con varianza $\|A^T t\|^2 = t^T \Sigma t$. $\square$

La representación no es única: si U es ortogonal, $AU(U^T Z)$ da la misma ley. El rango de Σ es la dimensión efectiva del soporte.

Si Σ es definida positiva, el cambio $x = m + Az$ produce la densidad

$$f_X(x) = \frac{1}{(2\pi)^{d/2}(\det \Sigma)^{1/2}} \exp\left\{-\frac{1}{2}(x - m)^T \Sigma^{-1}(x - m)\right\}.$$

La deducción requiere el jacobiano $|\det A| = (\det \Sigma)^{1/2}$.

1.3. Transformaciones y marginales

Proposición 1.3. Si $X \sim N_d(m, \Sigma)$, B es una matriz $k \times d$ y $b \in \mathbb{R}^k$, entonces

$$BX + b \sim N_k(Bm + b, B\Sigma B^T).$$

Demostración. Para cada $s \in \mathbb{R}^k$, $s^T(BX + b) = (B^T s)^T X + s^T b$ es normal. La media y covarianza se calculan por linealidad. $\square$

Toda subcolección de coordenadas es gaussiana. Más aún, si

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}, \quad m = \begin{pmatrix} m_1 \\ m_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

entonces $X_1 \sim N(m_1, \Sigma_{11})$ y $X_2 \sim N(m_2, \Sigma_{22})$.

Suma. Si X, Y son vectores gaussianos independientes, $X + Y$ es gaussiano y sus parámetros se suman. Sin independencia, la suma sigue siendo gaussiana si el vector conjunto (X, Y) es gaussiano; su covarianza incluye los términos cruzados.

1.4. No correlación e independencia

Para variables generales, covarianza cero no implica independencia. Dentro de un vector conjuntamente gaussiano sí.

Teorema 1.4. *Si (X_1, X_2) es conjuntamente gaussiano y $\Sigma_{12} = 0$, entonces X_1 y X_2 son independientes.*

Demostración. La función característica conjunta es

$$\exp\{i(t_1^T m_1 + t_2^T m_2) - \frac{1}{2}[t_1^T \Sigma_{11} t_1 + 2t_1^T \Sigma_{12} t_2 + t_2^T \Sigma_{22} t_2]\}.$$

Si $\Sigma_{12} = 0$, factoriza como $\varphi_{X_1}(t_1)\varphi_{X_2}(t_2)$. La caracterización por funciones características da independencia. $\square$

Advertencia. Que X y Y sean marginalmente normales y no correlacionados no basta: se necesita gaussianidad conjunta. Por ejemplo, si $Z \sim N(0, 1)$ y $Y = SZ$ con un signo independiente S , entonces Y es normal y $\text{Cov}(Z, Y) = 0$, pero $|Y| = |Z|$.

La estructura gaussiana convierte una condición de segundo orden en una afirmación completa sobre la ley.

1.5. Regresión gaussiana

Objetivo de la sesión. Separar una parte lineal observable y un residuo independiente.

Considere primero (X, Y) bivariado normal, con varianzas positivas. Defina

$$\beta = \frac{\text{Cov}(X, Y)}{\text{Var } Y}, \quad R = X - \mathbb{E}X - \beta(Y - \mathbb{E}Y).$$

El par (R, Y) es conjuntamente gaussiano por transformación lineal y

$$\text{Cov}(R, Y) = \text{Cov}(X, Y) - \beta \text{Var } Y = 0.$$

Por el teorema anterior, R es independiente de Y . Además $\mathbb{E}R = 0$ y

$$\text{Var } R = \text{Var } X - \frac{\text{Cov}(X, Y)^2}{\text{Var } Y}.$$

Por tanto

$$X = \mathbb{E}X + \beta(Y - \mathbb{E}Y) + R, \text{ y } R \perp Y.$$

Condicionando en Y ,

$$\mathbb{E}(X | Y) = \mathbb{E}X + \beta(Y - \mathbb{E}Y).$$

Así el mejor predictor general coincide con el predictor afín. Esta coincidencia es una propiedad gaussiana, no una regla universal.

1.6. Condicionamiento vectorial

Sea (X_1, X_2) conjuntamente gaussiano y suponga Σ_{22} invertible. Defina

$$B = \Sigma_{12}\Sigma_{22}^{-1}, \quad R = X_1 - m_1 - B(X_2 - m_2).$$

Entonces

$$\text{Cov}(R, X_2) = \Sigma_{12} - B\Sigma_{22} = 0.$$

Como (R, X_2) es gaussiano, R y X_2 son independientes. Su covarianza es

$$\Sigma_R = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Se deduce que una versión de la ley condicional es

$$X_1 \mid X_2 = x_2 \sim N(m_1 + B(x_2 - m_2), \Sigma_R).$$

En particular,

$$\mathbb{E}(X_1 \mid X_2) = m_1 + B(X_2 - m_2).$$

La covarianza condicional no depende del valor observado. El valor cambia la media, pero no la incertidumbre residual dentro del modelo gaussiano.

1.7. Complemento de Schur

La matriz

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

se llama complemento de Schur de Σ_{22} . Es semidefinida positiva porque es la covarianza del residuo R . También puede demostrarse algebraicamente: para cualquier u , elegir $v = -\Sigma_{22}^{-1} \Sigma_{21} u$ y usar

$$0 \leq (u^T, v^T) \Sigma (u^T, v^T)^T = u^T \Sigma_{11 \cdot 2} u.$$

Pregunta. Dos instrumentos miden magnitudes correlacionadas. Observado el segundo, ¿cuánto se reduce la incertidumbre sobre el primero?

En el caso bivariado con correlación ρ ,

$$\text{Var}(X | Y) = \sigma_X^2 (1 - \rho^2).$$

La reducción es $\rho^2 \sigma_X^2$, que coincide con la varianza explicada por la regresión lineal.

Si Σ_{22} es singular, se puede restringir al subespacio efectivo o usar una inversa generalizada; para este curso trabajaremos principalmente con el caso invertible.

1.8. Deducción alternativa por densidades

Cuando Σ es definida positiva, la densidad conjunta puede factorizarse completando cuadrados:

$$(x - m)^T \Sigma^{-1} (x - m) = (x_1 - m_1 - B(x_2 - m_2))^T \Sigma_{11.2}^{-1} (\cdots) + (x_2 - m_2)^T \Sigma_{22}^{-1} (x_2 - m_2).$$

Al dividir la densidad conjunta por la marginal de X_2 , el segundo término y las constantes correspondientes se cancelan; queda la densidad normal con media y covarianza ya obtenidas.

La prueba por residuos es más corta y revela independencia. La prueba por densidades confirma la normalización y conecta con el cálculo estadístico.

Ejemplo. Si (X, Y) es normal estándar con correlación ρ ,

$$X \mid Y = y \sim N(\rho y, 1 - \rho^2).$$

Para $|\rho| = 1$ la covarianza conjunta es singular y el condicionamiento se degenera en $X = \rho Y$ c.s.

1.9. Aplicaciones y cierre

Actualización lineal. Sea $X \sim N(m, \tau^2)$ y observe $Y = X + \varepsilon$, con $\varepsilon \sim N(0, \sigma^2)$ independiente. Entonces

$$\mathbb{E}(X | Y) = m + \frac{\tau^2}{\tau^2 + \sigma^2}(Y - m), \quad \text{Var}(X | Y) = \frac{\tau^2 \sigma^2}{\tau^2 + \sigma^2}.$$

El peso de la observación aumenta cuando el ruido σ^2 disminuye.

Simulación. Para generar $N_d(m, \Sigma)$, calcular una factorización $AA^T = \Sigma$, generar Z con componentes $N(0, 1)$ independientes y usar $m + AZ$. Cholesky sirve si Σ es definida positiva; la descomposición espectral también cubre matrices singulares.

Mapa de demostraciones. La función característica prueba unicidad y independencia; el teorema espectral prueba existencia; el residuo ortogonal prueba la ley condicional; el complemento de Schur cuantifica la incertidumbre remanente.

Lecturas. Saporta, capítulos sobre ley normal multivariada; Durrett, vectores gaussianos; notas MIT, funciones características y gaussianidad.



Notas · Semana 11

Teoría de la Probabilidad · CM4H1

Muestras normales y leyes exactas

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 11: geometría de la muestra normal

Propósito. Deducir, no memorizar, las leyes de la media y la varianza muestral, su independencia y las distribuciones χ^2 , Student y Fisher.

Sesión 1. Proyecciones ortogonales, formas cuadráticas y teorema de Cochran.

Sesión 2. Distribuciones pivote, t de Student, F de Fisher e intervalos exactos.

Recordatorios. Matrices ortogonales, rango y traza de proyectores, cambio ortogonal en normales estándar, gamma y cocientes de densidades.

1.1. Normal estándar y proyecciones

Objetivo de la sesión. Traducir estadísticos muestrales en longitudes de proyecciones ortogonales.

Sea $Z = (Z_1, \dots, Z_n)^T \sim N_n(0, I_n)$. Si Q es ortogonal, entonces $QZ \sim N_n(0, I_n)$ porque su media es cero y su covarianza $QI_nQ^T = I_n$. Sus coordenadas vuelven a ser normales estándar independientes.

Sea P un proyector ortogonal: $P = P^T = P^2$, de rango r . Existe una matriz ortogonal Q tal que

$$P = Q^T \begin{pmatrix} I_r & 0 \\ 0 & 0 \end{pmatrix} Q.$$

Por ello

$$Z^T P Z = (QZ)^T \begin{pmatrix} I_r & 0 \\ 0 & 0 \end{pmatrix} (QZ) = \sum_{j=1}^r (QZ)_j^2.$$

Esto motiva la ley chi-cuadrado.

Definición 1.1. $U \sim \chi_r^2$ si U es suma de cuadrados de r normales estándar independientes.

Su MGF es $(1 - 2t)^{-r/2}$ para $t < 1/2$, su media r y su varianza $2r$.

1.2. Teorema de Cochran

Teorema 1.2 (Versión de proyectores). Sea $Z \sim N_n(0, I_n)$ y sean $P_1, \dots, P_k$ proyectores ortogonales con rangos r_j , tales que $P_i P_j = 0$ si $i \neq j$. Entonces las formas $Z^T P_j Z$ son independientes y cada una tiene ley $\chi_{r_j}^2$.

Demostración. Los espacios imagen de los P_j son mutuamente ortogonales. Se eligen bases ortonormales de cada imagen y se completan a una base de $\mathbb{R}^n$. En esa base, todos los proyectores son simultáneamente diagonales, cada uno con unos en su bloque de r_j coordenadas y ceros fuera. Si Q contiene la base, QZ tiene coordenadas estándar independientes. Cada forma es suma de cuadrados de un bloque disjunto; de allí su ley y la independencia. $\square$

Si además $\sum_j P_j = I$, entonces $\sum_j r_j = n$ y $\sum_j Z^T P_j Z = \|Z\|^2$. La condición de rangos en la versión clásica asegura que no quede un término residual.

Advertencia. Formas cuadráticas no correlacionadas no son automáticamente independientes; aquí la gaussianidad y la ortogonalidad de los subespacios son esenciales.

1.3. Descomposición de la muestra normal

Sean $X_1, \dots, X_n$ i.i.d. $N(\mu, \sigma^2)$ y $Z = (X - \mu \mathbf{1})/\sigma$. Defina

$$P = \frac{1}{n} \mathbf{1} \mathbf{1}^T, \text{ y } M = I - P.$$

P proyecta sobre las constantes y M sobre su complemento. Además $PM = 0$, $\text{rango } P = 1$ y $\text{rango } M = n - 1$.

La proyección de la muestra sobre las constantes es $PX = \bar{X} \mathbf{1}$, mientras que $MX = X - \bar{X} \mathbf{1}$. Por tanto

$$\frac{n(\bar{X} - \mu)^2}{\sigma^2} = Z^T P Z, \text{ y } \frac{(n-1)S^2}{\sigma^2} = Z^T M Z,$$

donde $S^2 = (n-1)^{-1} \sum_i (X_i - \bar{X})^2$.

Cochran da

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1), \text{ y } \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

y ambas variables son independientes. La independencia de $\bar{X}$ y S^2 no es general: caracteriza fuertemente a la familia normal.

1.4. Identidad ANOVA elemental

La geometría anterior equivale a la identidad

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

Demostración. Escribir $X_i - \mu = (X_i - \bar{X}) + (\bar{X} - \mu)$ y sumar cuadrados. El término cruzado es

$$2(\bar{X} - \mu) \sum_i (X_i - \bar{X}) = 0.$$

□

Esta es una identidad de Pitágoras: residuo respecto de la media muestral más desplazamiento de la media. En el caso normal, además, los dos cuadrados corresponden a proyecciones gaussianas independientes.

Insensamiento. Como $\mathbb{E}[(n-1)S^2/\sigma^2] = n-1$, se obtiene $\mathbb{E}S^2 = \sigma^2$. El divisor $n-1$ aparece por la dimensión del subespacio residual: al estimar la media se pierde un grado de libertad.

Varianza. De $\text{Var}(\chi_{n-1}^2) = 2(n-1)$,

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}.$$

1.5. Distribución t de Student

Objetivo de la sesión. Construir un pivote cuando la varianza es desconocida.

Definición 1.3. Si $Z \sim N(0, 1)$, $U \sim \chi^2_\nu$ e independientes, entonces

$$T = \frac{Z}{\sqrt{U/\nu}}$$

tiene distribución t_ν .

Para una muestra normal, la independencia obtenida por Cochran produce

$$T = \frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{\sqrt{[(n-1)S^2/\sigma^2]/(n-1)}} = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}.$$

La distribución no depende de μ ni de σ : T es un pivote.

La densidad es

$$f_\nu(t) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi}\Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}.$$

Puede derivarse transformando el cociente de Z y U . Sus colas son más pesadas que las normales; cuando $\nu \rightarrow \infty$, $U/\nu \rightarrow 1$ en probabilidad y Slutsky da $T \Rightarrow N(0, 1)$.

1.6. Intervalo exacto para la media

Sea $t_{\nu, 1-\alpha/2}$ el cuantil correspondiente. Como

$$\mathbb{P}\left(-t_{n-1, 1-\alpha/2} \leq \frac{\sqrt{n}(\bar{X} - \mu)}{S} \leq t_{n-1, 1-\alpha/2}\right) = 1 - \alpha,$$

despejar μ produce

$$\left[\bar{X} - t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}\right].$$

Interpretación frecuentista. El intervalo aleatorio cubre al parámetro fijo con probabilidad $1 - \alpha$ bajo repetición del muestreo. Una vez observados los datos, los extremos son fijos; no se asigna probabilidad al parámetro dentro del modelo frecuentista.

Hipótesis. La exactitud finita usa normalidad e independencia. Para muestras grandes, el TCL y Slutsky justifican una aproximación, pero no convierten automáticamente el intervalo en exacto.

Pregunta. ¿Por qué sustituir σ por S cambia la normal a Student? Porque el denominador introduce variación aleatoria; Cochran garantiza que esta variación es chi-cuadrado e independiente del numerador.

1.7. Distribución F y comparación de varianzas

Definición 1.4. Si $U_1 \sim \chi_{r_1}^2$ y $U_2 \sim \chi_{r_2}^2$ son independientes, entonces

$$F = \frac{U_1/r_1}{U_2/r_2} \sim F_{r_1, r_2}.$$

Sean dos muestras normales independientes con varianzas σ_1^2, σ_2^2 . Entonces

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}.$$

Bajo $\sigma_1^2 = \sigma_2^2$, el cociente S_1^2/S_2^2 tiene directamente esa ley.

Demostración. Cada $(n_j - 1)S_j^2/\sigma_j^2$ es chi-cuadrado con $n_j - 1$ grados. La independencia de las muestras implica independencia de los estadísticos. Dividir cada chi-cuadrado por sus grados y formar el cociente da la definición. $\square$

La identidad $1/F_{r_1, r_2} \sim F_{r_2, r_1}$ permite relacionar cuantiles inferiores y superiores.

1.8. Dos muestras y descomposición

Con dos muestras normales independientes y varianza común desconocida, el estimador combinado es

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

La suma del numerador dividida por σ^2 es $\chi_{n_1+n_2-2}^2$, pues suma chi-cuadrados independientes. Además es independiente de $\bar{X}_1 - \bar{X}_2$. Por ello

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_p \sqrt{1/n_1 + 1/n_2}} \sim t_{n_1+n_2-2}.$$

Esta fórmula exige igualdad de varianzas. Sin ella, el estadístico de Welch usa una aproximación para los grados de libertad; no es una consecuencia exacta de Cochran.

Lectura conceptual. Cada chi-cuadrado cuenta la energía cuadrática en un subespacio residual. Sumar residuos ortogonales suma grados de libertad. Dividir una normal por la raíz de una energía independiente produce Student; dividir dos energías normalizadas produce Fisher.

1.9. Cierre y límites del modelo

Los resultados exactos de esta semana descansan en cuatro pilares:

1. la muestra estandarizada es $N_n(0, I)$;
2. las transformaciones ortogonales preservan esa ley;
3. proyecciones ortogonales usan bloques independientes;
4. las sumas de cuadrados de esos bloques son chi-cuadrado.

Diagnóstico. Con datos muy asimétricos o con colas pesadas, la ley exacta de S^2 puede apartarse mucho de chi-cuadrado. El TCL ayuda a la media, pero no justifica por sí solo todos los pivotes de varianza.

Conexión futura. Los promedios parciales y las esperanzas condicionales indexadas por información creciente conducen a martingalas. No se desarrollan aquí procesos continuos, Browniano ni cálculo de Itô, reservados para CM5H1.

Lecturas. Saporta, capítulos 3–4 para normal, muestreo y estadísticos; Durrett para gaussianidad y condicionamiento; material del curso para la prueba geométrica de Cochran.



Notas · Semana 12

Teoría de la Probabilidad · CM4H1

Integrabilidad uniforme y martingalas

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 12: de convergencia en L^1 a martingalas

Propósito. Entender por qué la convergencia casi segura no controla esperanzas, introducir integrabilidad uniforme y formular martingalas en tiempo discreto.

Sesión 1. Integrabilidad uniforme, criterios, Vitali y familias de esperanzas condicionales.

Sesión 2. Filtraciones, martingalas, ejemplos, transformadas previsibles y descomposición de Doob.

Recordatorios. Continuidad absoluta de la integral, de la Vallée–Poussin, Fatou, Jensen condicional y Borel–Cantelli.

1.1. Integrabilidad uniforme

Objetivo de la sesión. Separar control de colas y acotación de primeros momentos.

Definición 1.1. Una familia $\mathcal{X} \subset L^1$ es uniformemente integrable (UI) si

$$\lim_{K \rightarrow \infty} \sup_{X \in \mathcal{X}} \mathbb{E}(|X| \mathbf{1}_{\{|X| > K\}}) = 0.$$

UI implica $\sup_{X \in \mathcal{X}} \mathbb{E}|X| < \infty$: escoger K con cola menor que uno y usar $\mathbb{E}|X| \leq K + 1$. La recíproca es falsa.

Contraejemplo. En $(0, 1)$, $X_n = n \mathbf{1}_{(0, 1/n)}$. Entonces $\mathbb{E}X_n = 1$ y $X_n \rightarrow 0$ c.s., pero para todo K y $n > K$, $\mathbb{E}[X_n \mathbf{1}_{\{X_n > K\}}] = 1$. No hay UI ni convergencia en L^1 .

UI impide que una cantidad apreciable de esperanza escape hacia valores cada vez más grandes en conjuntos cada vez más pequeños.

1.2. Criterios de integrabilidad uniforme

Dominación. Si $|X| \leq Y \in L^1$ para toda $X \in \mathcal{X}$, entonces la familia es UI, porque

$$|X|\mathbf{1}_{\{|X|>K\}} \leq Y\mathbf{1}_{\{Y>K\}}.$$

Momento superior. Si para algún $p > 1$, $\sup_X \mathbb{E}|X|^p < C$, entonces, en $\{|X| > K\}$, $|X| \leq |X|^p/K^{p-1}$ y

$$\sup_X \mathbb{E}(|X|\mathbf{1}_{\{|X|>K\}}) \leq C/K^{p-1}.$$

Teorema 1.2 (de la Vallée–Poussin). *Una familia es UI si y solo si existe una convexa creciente Φ con $\Phi(x)/x \rightarrow \infty$ y $\sup_X \mathbb{E}\Phi(|X|) < \infty$.*

La dirección suficiente sigue de $x\mathbf{1}_{x>K} \leq [K/\Phi(K)]\Phi(x)$ para una elección convexa apropiada. La construcción recíproca agrupa niveles de cola y elige pendientes crecientes; se registra como recordatorio de teoría de integración.

1.3. Teorema de Vitali

Teorema 1.3. Si $X_n \rightarrow X$ en probabilidad, entonces $X_n \rightarrow X$ en L^1 si y solo si (X_n) es UI.

Suficiencia. UI de (X_n) y Fatou implican $X \in L^1$ y que $(X_n - X)$ es UI. Fijado K , la variable $|X_n - X| \wedge K$ converge a cero en probabilidad y está acotada. Toda subsucesión contiene otra que converge c.s.; dominada muestra que su esperanza truncada converge a cero. Por el criterio de subsucesiones, toda la sucesión truncada converge en media. Las colas, uniformemente pequeñas, completan la prueba. $\square$

Necesidad. Si $\mathbb{E}|X_n - X| \rightarrow 0$, la continuidad absoluta de la integral de X y la desigualdad

$$|X_n| \mathbf{1}_{\{|X_n| > K\}} \leq |X| \mathbf{1}_{\{|X| > K/2\}} + |X_n - X| \mathbf{1}_{\{|X_n| > K\}}$$

permiten controlar uniformemente la cola, separando además un número finito de índices iniciales. $\square$

Consecuencia: convergencia c.s. más UI permite pasar esperanzas al límite, generalizando convergencia dominada.

1.4. Esperanzas condicionales como familia UI

Teorema 1.4. Si $X \in L^1$ y $\mathcal{G}$ recorre cualquier colección de sub- σ -álgebras, la familia $\{\mathbb{E}(X | \mathcal{G})\}$ es UI.

Demostración. Sea $Z = \mathbb{E}(X | \mathcal{G})$ y $A = \{|Z| > K\} \in \mathcal{G}$. Por Jensen,

$$\mathbb{E}(|Z|\mathbf{1}_A) \leq \mathbb{E}(\mathbb{E}(|X| | \mathcal{G})\mathbf{1}_A) = \mathbb{E}(|X|\mathbf{1}_A).$$

Para $L > 0$,

$$\mathbb{E}(|X|\mathbf{1}_A) \leq \mathbb{E}(|X|\mathbf{1}_{\{|X|>L\}}) + L\mathbb{P}(A).$$

Markov da $\mathbb{P}(A) \leq \mathbb{E}|Z|/K \leq \mathbb{E}|X|/K$. Elegir primero L grande y después K grande da una cota uniforme. $\square$

Este resultado es más fuerte que la mera acotación en L^1 y será la pieza que permite obtener convergencia L^1 de martingalas cerradas.

Recordatorio. Una familia acotada en L^p , $p > 1$, es UI. Por Jensen, $\|\mathbb{E}(X | \mathcal{G})\|_p \leq \|X\|_p$.

1.5. Filtraciones y martingalas

Objetivo de la sesión. Modelar información creciente y juegos justos.

Definición 1.5. Una filtración es una sucesión $\mathcal{F}_0 \subset \mathcal{F}_1 \subset \dots$. Un proceso (M_n) es martingala respecto de $(\mathcal{F}_n)$ si M_n es $\mathcal{F}_n$ -medible, integrable y

$$\mathbb{E}(M_{n+1} \mid \mathcal{F}_n) = M_n.$$

Para submartingalas se reemplaza igualdad por $\geq$ y para supermartingalas por $\leq$.

Por torre, si $m \geq n$,

$$\mathbb{E}(M_m \mid \mathcal{F}_n) = M_n, \text{ y } \mathbb{E}M_m = \mathbb{E}M_n.$$

Ejemplo: sumas centradas. Si X_k son integrables, independientes y centradas, $S_n = \sum_{k=1}^n X_k$ es martingala para $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$, pues el incremento futuro tiene esperanza condicional cero.

Ejemplo cerrado. Si $X \in L^1$, entonces $M_n = \mathbb{E}(X \mid \mathcal{F}_n)$ es martingala por la propiedad de la torre.

1.6. Ejemplos no triviales

Producto. Si X_k son independientes, no negativos y $\mathbb{E}X_k = 1$, entonces $M_n = \prod_{k=1}^n X_k$ es martingala:

$$\mathbb{E}(M_{n+1} \mid \mathcal{F}_n) = M_n \mathbb{E}X_{n+1} = M_n.$$

Puede converger a cero c.s. aunque mantenga esperanza uno; esto señala la falta de UI.

Caminata exponencial. Para incrementos Bernoulli simétricos $\xi_k \in \{-1, 1\}$ y $S_n = \sum \xi_k$,

$$M_n(\theta) = \frac{e^{\theta S_n}}{(\cosh \theta)^n}$$

es martingala, porque $\mathbb{E}e^{\theta \xi_{n+1}} = \cosh \theta$.

Cuadrado compensado. Si ξ_k son independientes, centrados, con varianza σ^2 , entonces

$$M_n = S_n^2 - n\sigma^2$$

es martingala. Expandir $(S_n + \xi_{n+1})^2$ y condicionar: el término lineal desaparece y el cuadrático aporta σ^2 .

Estos ejemplos preparan desigualdades y tiempos de parada sin entrar en procesos continuos.

1.7. Transformadas previsibles

Una sucesión (H_n) es previsible si H_n es $\mathcal{F}_{n-1}$ -medible. Para una martingala M , defina

$$(H \cdot M)_n = \sum_{k=1}^n H_k(M_k - M_{k-1}).$$

Si H_k es acotada y se cumplen las condiciones de integrabilidad, entonces $(H \cdot M)_n$ es martingala.

Demostración. El incremento es $H_n \Delta M_n$. Como H_n es conocido antes del paso,

$$\mathbb{E}(H_n \Delta M_n \mid \mathcal{F}_{n-1}) = H_n \mathbb{E}(\Delta M_n \mid \mathcal{F}_{n-1}) = 0.$$

Sumar preserva la propiedad. □

Interpretación financiera elemental. H_n es la cantidad apostada antes de observar el resultado n . Una estrategia previsible y acotada no convierte un juego justo en uno con ganancia esperada positiva.

La previsibilidad es crucial: elegir H_n después de observar ΔM_n permitiría seleccionar ganancias retrospectivamente y no modela una estrategia admisible.

1.8. Descomposición de Doob

Teorema 1.6. *Toda submartingala integrable adaptada (X_n) admite una descomposición única*

$$X_n = M_n + A_n,$$

donde M es martingala, $A_0 = 0$ y A_n es previsible e creciente.

Demostración. Defina

$$A_n = \sum_{k=1}^n \mathbb{E}(X_k - X_{k-1} \mid \mathcal{F}_{k-1}), \text{ y } M_n = X_n - A_n.$$

Cada incremento de A es $\mathcal{F}_{k-1}$ -medible y no negativo por la propiedad de submartingala. Además

$$\mathbb{E}(M_n - M_{n-1} \mid \mathcal{F}_{n-1}) = 0,$$

así que M es martingala. Para unicidad, si $X = M + A = M' + A'$, entonces $M - M' = A' - A$ es a la vez martingala y previsible con valor inicial cero. Sus incrementos son conocidos un paso antes y tienen esperanza condicional cero; por tanto son cero. $\square$

La parte A mide la deriva acumulada previsible; M conserva la fluctuación justa.

1.9. Convexidad y cierre

Si M es martingala y φ convexa con integrabilidad suficiente, Jensen condicional da

$$\mathbb{E}(\varphi(M_{n+1}) \mid \mathcal{F}_n) \geq \varphi(M_n),$$

de modo que $(\varphi(M_n))$ es submartingala. En particular, $|M_n|$ y M_n^2 lo son cuando son integrables.

Para L^2 ,

$$\mathbb{E}(M_n - M_{n-1})M_{n-1} = 0,$$

y por iteración los incrementos son ortogonales. Así

$$\mathbb{E}M_n^2 = \mathbb{E}M_0^2 + \sum_{k=1}^n \mathbb{E}(\Delta M_k)^2.$$

Esta identidad conecta martingalas con las series de variables independientes de la semana 5.

Alcance. Solo se trabaja en tiempo discreto. Movimiento Browniano, martingalas continuas e integral de Itô pertenecen al curso posterior CM5H1.

Lecturas. Durrett: integrabilidad uniforme y martingalas; notas MIT: definiciones y ejemplos; Saporta como apoyo para los aspectos estadísticos de condicionamiento.



Notas · Semana 13

Teoría de la Probabilidad · CM4H1

Parada e desigualdades de martingalas

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 13: tiempos de parada y control maximal

Propósito. Formular tiempos de parada en tiempo discreto, probar versiones seguras del muestreo opcional y obtener desigualdades maximales de Doob.

Sesión 1. Tiempos de parada, procesos detenidos y teorema de parada opcional bajo hipótesis explícitas.

Sesión 2. Desigualdades de Doob en L^1 y L^p , aplicaciones a convergencia y paseos aleatorios.

Recordatorios. Eventos de primer cruce, Fatou, Hölder, Jensen condicional y truncamiento.

1.1. Tiempos de parada

Objetivo de la sesión. Definir decisiones que usan únicamente la información disponible.

Definición 1.1. Una variable $T : \Omega \rightarrow \mathbb{N}_0 \cup \{\infty\}$ es tiempo de parada respecto de $(\mathcal{F}_n)$ si $\{T \leq n\} \in \mathcal{F}_n$ para todo n .

Equivalentemente, $\{T = n\} \in \mathcal{F}_n$. El tiempo de primera entrada

$$T = \inf\{n \geq 0 : X_n \in A\}$$

es tiempo de parada para un proceso adaptado, porque

$$\{T \leq n\} = \bigcup_{k=0}^n \{X_k \in A\}.$$

El tiempo del último retorno antes del infinito generalmente no es de parada: para saber que un retorno es el último hay que mirar el futuro.

Sigma-álgebra en T . Se define

$$\mathcal{F}_T = \{A \in \mathcal{F} : A \cap \{T \leq n\} \in \mathcal{F}_n \forall n\}.$$

Representa la información disponible al detenerse. Si X es adaptado, $X_T \mathbf{1}_{\{T < \infty\}}$ es $\mathcal{F}_T$ -medible.

1.2. Proceso detenido

Para un proceso X , defina $X_n^T = X_{n \wedge T}$. Si M es martingala y T tiempo de parada, entonces M^T es martingala, bajo integrabilidad.

Demostración. El incremento puede escribirse

$$M_{n+1}^T - M_n^T = \mathbf{1}_{\{T > n\}}(M_{n+1} - M_n).$$

El indicador $\mathbf{1}_{\{T > n\}}$ es $\mathcal{F}_n$ -medible. Por tanto

$$\mathbb{E}(M_{n+1}^T - M_n^T \mid \mathcal{F}_n) = \mathbf{1}_{\{T > n\}} \mathbb{E}(M_{n+1} - M_n \mid \mathcal{F}_n) = 0.$$

□

La identidad muestra que detener equivale a usar la estrategia previsible $H_{n+1} = \mathbf{1}_{\{T > n\}}$: se participa mientras aún no se ha detenido.

Si $T \leq N$ c.s., entonces $M_T = M_N^T$ y

$$\mathbb{E}M_T = \mathbb{E}M_0.$$

Esta es la forma básica y segura del teorema de parada opcional.

1.3. Parada opcional: hipótesis suficientes

Teorema 1.2. Sean $S \leq T$ tiempos de parada y M una martingala. Se tiene $\mathbb{E}(M_T | \mathcal{F}_S) = M_S$ si, por ejemplo:

1. T es acotado;
2. M tiene incrementos uniformemente acotados y $\mathbb{E}T < \infty$;
3. la familia $(M_{n \wedge T})$ es UI y $T < \infty$ c.s.

Para $T \leq N$, expandir

$$M_T = M_0 + \sum_{k=1}^N \mathbf{1}_{\{T \geq k\}} \Delta M_k.$$

Cada indicador es $\mathcal{F}_{k-1}$ -medible y el incremento tiene media condicional cero. La versión condicional se obtiene multiplicando por indicadores de $\mathcal{F}_S$ o deteniendo desde S .

En el caso UI, primero se aplica la identidad a $T \wedge n$ y luego se pasa al límite en L^1 .

Advertencia. Sin hipótesis adicionales, $\mathbb{E}M_T = \mathbb{E}M_0$ puede fallar. La mera finitud c.s. de T no basta.

1.4. Caminata simétrica y ruina

Sea $S_n = x + \sum_{k=1}^n \xi_k$, con $\xi_k = \pm 1$ equiprobables, y

$$T = \inf\{n : S_n \in \{0, a\}\}, \quad 0 < x < a.$$

Para justificar que $T < \infty$ c.s., en cada bloque de a pasos existe una probabilidad positiva uniforme de alcanzar una frontera; una cota geométrica concluye.

Como $S_{n \wedge T}$ está acotada entre 0 y a , es UI. Parada opcional da

$$x = \mathbb{E}S_T = a\mathbb{P}(S_T = a),$$

y por ello

$$\mathbb{P}_x(S_T = a) = x/a.$$

Para el tiempo medio use la martingala $S_n^2 - n$. Detenida en $T \wedge n$,

$$\mathbb{E}S_{T \wedge n}^2 - \mathbb{E}(T \wedge n) = x^2.$$

Dominada para el primer término y monótona para el segundo producen

$$\mathbb{E}_x T = x(a - x).$$

Cada paso de límite debe justificarse; la fórmula no sale de sustituir informalmente $n = T$.

1.5. Desigualdad maximal de Doob

Objetivo de la sesión. Controlar el máximo mediante el valor terminal.

Teorema 1.3 (Doob L^1). Si $(X_k)_{k=0}^n$ es submartingala no negativa y $\lambda > 0$, entonces

$$\lambda \mathbb{P} \left(\max_{k \leq n} X_k \geq \lambda \right) \leq \mathbb{E}[X_n \mathbf{1}_{\{\max_{k \leq n} X_k \geq \lambda\}}] \leq \mathbb{E}X_n.$$

Demostración. Sea $A_k = \{X_0 < \lambda, \dots, X_{k-1} < \lambda, X_k \geq \lambda\}$, eventos disjuntos y $A_k \in \mathcal{F}_k$. Entonces

$$\lambda \mathbb{P}(\max X_j \geq \lambda) \leq \sum_k \mathbb{E}[X_k \mathbf{1}_{A_k}].$$

Por submartingala, $X_k \leq \mathbb{E}(X_n | \mathcal{F}_k)$ en promedio condicional; multiplicar por $\mathbf{1}_{A_k}$ y sumar da

$$\sum_k \mathbb{E}[X_k \mathbf{1}_{A_k}] \leq \sum_k \mathbb{E}[X_n \mathbf{1}_{A_k}] = \mathbb{E}[X_n \mathbf{1}_{\cup A_k}].$$

□

Aplicada a $|M_k|$, controla máximos de una martingala integrable.

1.6. Desigualdad L^p

Teorema 1.4. Si $p > 1$, $q = p/(p-1)$ y (M_k) es martingala con $M_n \in L^p$, entonces

$$\left\| \max_{k \leq n} |M_k| \right\|_p \leq q \|M_n\|_p.$$

Demostración. Sea $M_n^* = \max_{k \leq n} |M_k|$. La desigualdad L^1 aplicada a $|M_k|$ da

$$\lambda \mathbb{P}(M_n^* \geq \lambda) \leq \mathbb{E}[|M_n| \mathbf{1}_{\{M_n^* \geq \lambda\}}].$$

Usamos la fórmula de capas y Tonelli:

$$\mathbb{E}(M_n^*)^p = p \int_0^\infty \lambda^{p-1} \mathbb{P}(M_n^* > \lambda) d\lambda.$$

Sustituir la cota, intercambiar esperanza e integral y calcular $\int_0^{M_n^*} \lambda^{p-2} d\lambda$ da

$$\mathbb{E}(M_n^*)^p \leq q \mathbb{E}[|M_n| (M_n^*)^{p-1}].$$

Hölder y división por $\|M_n^*\|_p^{p-1}$ concluyen. □

1.7. Convergencia maximal

Si (M_n) es martingala acotada en L^p para algún $p > 1$, Doob da

$$\sup_n \left\| \max_{k \leq n} |M_k| \right\|_p < \infty.$$

En particular, el máximo infinito es finito c.s. y en L^p mediante convergencia monótona. La convergencia c.s. requerirá además controlar oscilaciones; eso se hará con la desigualdad de subidas en la semana 14.

Para una martingala L^2 con incrementos ortogonales,

$$\mathbb{E}M_n^2 = \mathbb{E}M_0^2 + \sum_{k=1}^n \mathbb{E}(\Delta M_k)^2.$$

Si la suma de varianzas de incrementos es finita, (M_n) es acotada en L^2 . Doob y el teorema de convergencia producirán un límite $M_\infty \in L^2$.

Comparación. La desigualdad maximal de Kolmogorov usa independencia de incrementos; Doob reemplaza independencia por la propiedad de martingala y funciona para muchas dependencias adaptadas.

1.8. Aplicación exponencial

Para la caminata simétrica,

$$M_n(\theta) = \exp\{\theta S_n - n \log \cosh \theta\}$$

es martingala positiva. La desigualdad maximal aplicada a $M_k(\theta)$ permite acotar la probabilidad de que S_k cruce una frontera lineal o constante.

Por ejemplo, si $S_k \geq a$ para algún $k \leq n$, entonces

$$M_k(\theta) \geq \exp\{\theta a - n \log \cosh \theta\}$$

para $\theta > 0$. Por Doob,

$$\mathbb{P}(\max_{k \leq n} S_k \geq a) \leq \exp\{-\theta a + n \log \cosh \theta\}.$$

Optimizar en θ produce una cota de Chernoff para el máximo. Usar $\log \cosh \theta \leq \theta^2/2$ y elegir $\theta = a/n$ da

$$\mathbb{P}(\max_{k \leq n} S_k \geq a) \leq e^{-a^2/(2n)}.$$

La técnica combina una martingala exponencial con una desigualdad maximal.

1.9. Errores frecuentes y alcance

1. Un tiempo de parada decide detenerse con información presente; un último instante suele mirar el futuro.
2. La identidad de parada se prueba primero para tiempos acotados. El límite exige dominación, UI u otra hipótesis.
3. La desigualdad maximal controla $\max_{k \leq n}$, no solo M_n .
4. En L^p , la constante $p/(p-1)$ explota cuando $p \downarrow 1$; el caso $p = 1$ requiere otra formulación.

Separación curricular. No se tratarán tiempos de parada de Browniano, principio de reflexión, tiempos de salida continuos ni cálculo de Itô. Esos contenidos permanecen en CM5H1.

Lecturas. Durrett: optional stopping y desigualdades maximales; notas MIT: martingalas discretas; material semanal para las hipótesis exactas utilizadas.



Notas · Semana 14

Teoría de la Probabilidad · CM4H1

Convergencia de martingalas y cadenas finitas

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 14: cierre del curso

Propósito. Probar convergencia casi segura de submartingalas mediante subidas y ofrecer una introducción compacta a cadenas de Markov finitas, sin invadir el curso posterior.

Sesión 1. Desigualdad de subidas, convergencia de submartingalas, UI y representación cerrada.

Sesión 2. Propiedad de Markov, matriz de transición, Chapman–Kolmogorov, estados y distribución estacionaria.

Recordatorios. Fatou, Vitali, convergencia monótona, Perron–Frobenius en dimensión finita y series geométricas de matrices.

1.1. Subidas y existencia de límites

Objetivo de la sesión. Convertir el control de oscilaciones en convergencia casi segura.

Para una sucesión real (x_k) y $a < b$, el número $U_n[a, b]$ de subidas completas de $[a, b]$ antes de n cuenta cuántas veces se puede comprar al estar en o debajo de a y vender al estar en o encima de b .

Teorema 1.1 (Desigualdad de subidas). *Si $(X_k)_{k=0}^n$ es submartingala, entonces*

$$(b - a)\mathbb{E}U_n[a, b] \leq \mathbb{E}[(X_n - a)^-] - \mathbb{E}[(X_0 - a)^-]$$

y, en particular, está acotada por una expresión que depende de $\sup_k \mathbb{E}X_k^-$. Una forma equivalente usa $\mathbb{E}[(X_n - a)^-]$ y la media inicial.

Idea constructiva. Defina una estrategia previsible $H_k \in \{0, 1\}$ que compra después de cruzar hacia abajo a y mantiene una unidad hasta cruzar hacia arriba b . La ganancia $(H \cdot X)_n$ domina $(b - a)U_n[a, b]$ salvo el valor de una posición final abierta, que se controla con $(X_n - a)^-$. Como X es submartingala y $H \geq 0$ previsible acotada, $H \cdot X$ es submartingala; tomar esperanzas produce la desigualdad. $\square$

1.2. Teorema de convergencia casi segura

Teorema 1.2. *Si (X_n) es submartingala y $\sup_n \mathbb{E}X_n^+ < \infty$, entonces X_n converge c.s. a una variable finita $X_\infty \in L^1$.*

Demostración. Como $\mathbb{E}X_n \geq \mathbb{E}X_0$, la cota de partes positivas implica una cota uniforme de $\mathbb{E}X_n^-$. La desigualdad de subidas da $\sup_n \mathbb{E}U_n[a, b] < \infty$ para racionales $a < b$. Por convergencia monótona, $U_\infty[a, b] < \infty$ c.s.

Si $\liminf X_n < \limsup X_n$, existen racionales $a < b$ estrictamente entre ambos valores, lo que fuerza infinitas subidas de $[a, b]$. La unión numerable sobre pares racionales muestra que el límite existe en $[-\infty, \infty]$ c.s. La cota de $\mathbb{E}|X_n|$ y Fatou excluye valores infinitos y da $X_\infty \in L^1$. $\square$

El teorema asegura convergencia c.s., pero no necesariamente en L^1 ni conservación de esperanzas.

1.3. Convergencia en L^1 y cierre

Teorema 1.3. *Para una martingala (M_n) , las siguientes condiciones están estrechamente relacionadas:*

1. (M_n) es UI;
2. $M_n \rightarrow M_\infty$ en L^1 ;
3. existe $X \in L^1$ tal que $M_n = \mathbb{E}(X \mid \mathcal{F}_n)$.

En particular, cada una implica convergencia c.s. y las tres son equivalentes con la formulación usual de martingala cerrada.

Demostración. UI y convergencia c.s. dan L^1 por Vitali. Si $M_n \rightarrow M_\infty$ en L^1 , para $A \in \mathcal{F}_n$ y $m \geq n$, $\mathbb{E}(M_m \mathbf{1}_A) = \mathbb{E}(M_n \mathbf{1}_A)$; pasar al límite da $M_n = \mathbb{E}(M_\infty \mid \mathcal{F}_n)$. Finalmente, la familia de esperanzas condicionales de una variable integrable es UI, como se probó en la semana 12. $\square$

Si $\sup_n \mathbb{E}|M_n|^p < \infty$ para $p > 1$, la familia es UI y converge en L^1 . De hecho, con argumentos adicionales de convexidad y Doob, converge en L^p para $p > 1$.

1.4. Aplicaciones de convergencia

Series independientes. Si X_k son independientes, centradas y $\sum_k \text{Var } X_k < \infty$, las sumas S_n forman una martingala acotada en L^2 :

$$\sup_n \mathbb{E} S_n^2 = \sum_{k \geq 1} \text{Var } X_k < \infty.$$

Por el teorema de convergencia, S_n converge c.s. y en L^2 . Esto recupera parte del resultado estudiado mediante la desigualdad de Kolmogorov.

Aprendizaje de información. Si $X \in L^1$ y $\mathcal{F}_n$ crece, $M_n = \mathbb{E}(X \mid \mathcal{F}_n)$ es UI y converge en L^1 y c.s. a

$$\mathbb{E}(X \mid \mathcal{F}_\infty), \quad \mathcal{F}_\infty = \sigma \left(\bigcup_n \mathcal{F}_n \right).$$

La identificación se prueba verificando integrales primero en $\cup_n \mathcal{F}_n$ y extendiendo mediante π - λ .

Interpretación. A medida que aumenta la información, el mejor predictor se estabiliza en el mejor predictor basado en toda la información acumulada.

1.5. Cadenas de Markov finitas

Objetivo de la sesión. Presentar el lenguaje y los resultados básicos como puente al curso posterior.

Sea (X_n) un proceso con espacio de estados finito E .

Definición 1.4. Es una cadena de Markov homogénea si

$$\mathbb{P}(X_{n+1} = j \mid X_0 = i_0, \dots, X_n = i) = \mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij}.$$

La matriz $P = (p_{ij})$ es estocástica por filas: $p_{ij} \geq 0$ y $\sum_j p_{ij} = 1$.

La propiedad no dice que el futuro sea independiente del pasado; dice que, dado el presente, el resto del pasado no aporta información para el siguiente paso.

Si la distribución inicial es la fila μ , entonces

$$\mathbb{P}(X_1 = j) = \sum_i \mu_i p_{ij}, \quad \mathcal{L}(X_n) = \mu P^n.$$

Ejemplo. Para clima con estados seco/lluvioso,

$$P = \begin{pmatrix} .8 & .2 \\ .4 & .6 \end{pmatrix}.$$

La probabilidad de lluvia mañana depende solo del estado de hoy dentro del modelo.

1.6. Chapman–Kolmogorov

Defina $p_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i)$. Entonces

$$p_{ij}^{(m+n)} = \sum_{k \in E} p_{ik}^{(m)} p_{kj}^{(n)},$$

o matricialmente $P^{m+n} = P^m P^n$.

Demostración. Particionar según $X_m = k$ y usar la propiedad de Markov:

$$\mathbb{P}_i(X_{m+n} = j) = \sum_k \mathbb{P}_i(X_m = k) \mathbb{P}(X_{m+n} = j \mid X_m = k) = \sum_k p_{ik}^{(m)} p_{kj}^{(n)}.$$

□

Trayectorias. Para $i_0, \dots, i_n$,

$$\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) = \mu_{i_0} \prod_{k=0}^{n-1} p_{i_k i_{k+1}}.$$

Esta factorización determina todas las distribuciones finito-dimensionales.

Primer paso. Muchas probabilidades de alcance satisfacen ecuaciones lineales al condicionar en X_1 . Esta técnica reaparece extensamente en CM5H1.

1.7. Comunicación y clases

Se dice que $i \rightarrow j$ si $p_{ij}^{(n)} > 0$ para algún $n \geq 0$. Los estados se comunican, $i \leftrightarrow j$, si ambos accesos son posibles. La comunicación es una relación de equivalencia y divide E en clases.

Una clase C es cerrada si desde ella no se sale: $p_{ij} = 0$ para $i \in C, j \notin C$. En una cadena finita, toda trayectoria termina entrando en alguna clase cerrada con probabilidad uno bajo hipótesis elementales de accesibilidad.

El período de i es

$$d(i) = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}.$$

En una clase comunicante todos los estados comparten período. Período uno significa aperiodicidad.

Ejemplo. La cadena que alterna determinísticamente entre 0 y 1 es irreducible pero tiene período 2; sus distribuciones no convergen aunque posee distribución estacionaria.

El tratamiento se limita a definiciones, clasificación finita y cálculo matricial básico.

1.8. Distribución estacionaria

Una distribución fila π es estacionaria si

$$\pi P = \pi, \text{quad} \pi_j \geq 0, \text{quad} \sum_j \pi_j = 1.$$

Si $X_0 \sim \pi$, entonces $X_n \sim \pi$ para todo n por inducción.

Para la matriz climática anterior, resolver

$$\pi_1 = .8\pi_1 + .4\pi_2, \text{quad} \pi_1 + \pi_2 = 1$$

da $\pi = (2/3, 1/3)$.

Teorema 1.5 (Finito, enunciado). *Una cadena finita irreducible tiene una única distribución estacionaria. Si además es aperiódica, $P^n(i, j) \rightarrow \pi_j$ para todos i, j .*

No se desarrolla la prueba completa: puede obtenerse mediante Perron–Frobenius, acoplamiento o renovación. Se reserva su estudio sistemático para el curso de procesos estocásticos.

Advertencia. Estacionariedad es invariancia de la ley; no significa que la trayectoria permanezca fija. Convergencia a π requiere condiciones adicionales como aperiodicidad.

1.9. Tiempo de alcance y cierre curricular

Para $A \subset E$, sea $T_A = \inf\{n \geq 0 : X_n \in A\}$. La probabilidad

$$h(i) = \mathbb{P}_i(T_A < T_B)$$

satisface

$$h(i) = \sum_j p_{ij}h(j), \quad i \notin A \cup B; \quad h = 1 \text{ en } A, \quad h = 0 \text{ en } B.$$

La prueba condiciiona en el primer paso. En un espacio finito esto es un sistema lineal.

Análogamente, el tiempo medio $u(i) = \mathbb{E}_i T_A$ satisface

$$u(i) = 1 + \sum_j p_{ij}u(j), \quad i \notin A; \quad u = 0 \text{ en } A,$$

cuando la esperanza es finita.

Estas ecuaciones muestran el vínculo entre Markov, condicionamiento y parada, pero se presentan solo como introducción. No se incluyen cadenas generales, recurrencia avanzada, Poisson en tiempo continuo, Browniano ni Itô.

Cierre. El curso termina con tres ideas unificadoras: la medida define la probabilidad rigurosa; la convergencia y las transformadas controlan límites; la esperanza condicional organiza información, predicción y martingalas.