



Notas del curso · Tomo II

Teoría de la Probabilidad · CM4H1

Semanas 8–14

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 8: esperanza condicional

1.1. Existencia y unicidad

Objetivo de la sesión. Construir la esperanza condicional mediante Radon–Nikodym.

Definición 1.1. Para $X \in L^1$ y una sub- σ -álgebra $\mathcal{G} \subset \mathcal{F}$, una versión de $\mathbb{E}(X \mid \mathcal{G})$ es una variable Z , $\mathcal{G}$ -medible e integrable, tal que

$$\int_G Z \, d\mathbb{P} = \int_G X \, d\mathbb{P} \quad \text{para todo } G \in \mathcal{G}.$$

Teorema 1.2. *La versión existe y es única casi seguramente.*

Demostración. Si $X \geq 0$, $\nu(G) = \int_G X \, d\mathbb{P}$ es una medida finita sobre $(\Omega, \mathcal{G})$ y $\nu \ll \mathbb{P}|_{\mathcal{G}}$. Radon–Nikodym produce $Z = d\nu/d\mathbb{P}$, $\mathcal{G}$ -medible y no negativa. Para $X \in L^1$, aplicar a X^+ y X^- y restar. Si Z_1, Z_2 satisfacen la definición, el conjunto $G = \{Z_1 > Z_2\} \in \mathcal{G}$ cumple $\int_G (Z_1 - Z_2) = 0$ con integrando positivo; por tanto tiene diferencia cero c.s. Repetir intercambiando índices. $\square$

Para una partición numerable (G_j) con masas positivas, $\mathbb{E}(X \mid \sigma(G_j)) = \sum_j \mathbb{E}(X \mid G_j) \mathbf{1}_{G_j}$.

1.2. Cálculo y propiedades

Objetivo de la sesión. Demostrar torre, extracción de factores y Jensen condicional.

Linealidad y positividad se obtienen verificando la identidad de integrales y usando unicidad. Si X es $\mathcal{G}$ -medible, $\mathbb{E}(X \mid \mathcal{G}) = X$. Si Y es $\mathcal{G}$ -medible y acotada,

$$\mathbb{E}(YX \mid \mathcal{G}) = Y\mathbb{E}(X \mid \mathcal{G}).$$

Se prueba para indicadores $Y = \mathbf{1}_G$, después para simples y finalmente por aproximación dominada. Si $\mathcal{H} \subset \mathcal{G}$,

$$\mathbb{E}(\mathbb{E}(X \mid \mathcal{G}) \mid \mathcal{H}) = \mathbb{E}(X \mid \mathcal{H}),$$

porque ambos lados tienen las mismas integrales sobre cada $H \in \mathcal{H}$.

Teorema 1.3 (Jensen condicional). *Para $X, \varphi(X) \in L^1$ y φ convexa, $\varphi(\mathbb{E}(X \mid \mathcal{G})) \leq \mathbb{E}(\varphi(X) \mid \mathcal{G})$ c.s.*

Demostración. Representar una convexa real como supremo numerable de rectas soporte con pendientes e interceptos racionalmente aproximados: $\varphi(x) = \sup_k (a_k x + b_k)$. Cada recta satisface $a_k \mathbb{E}(X \mid \mathcal{G}) + b_k = \mathbb{E}(a_k X + b_k \mid \mathcal{G}) \leq \mathbb{E}(\varphi(X) \mid \mathcal{G})$. Tomar supremo concluye. $\square$

En variables con densidad conjunta, la fórmula habitual $f_{X|Y}(x | y) = f_{X,Y}(x,y)/f_Y(y)$ define una versión para casi todo y con $f_Y(y) > 0$; los valores en el conjunto excepcional pueden elegirse arbitrariamente.

Capítulo 2

Semana 9: predicción y varianza total

2.1. Proyección en L^2

Objetivo de la sesión. Interpretar la esperanza condicional como el mejor predictor cuadrático.

Sea $L^2(\mathcal{G})$ el subespacio de variables $\mathcal{G}$ -medibles en L^2 . Es cerrado: una sucesión de Cauchy converge en L^2 y contiene una subsucesión c.s.; el límite es $\mathcal{G}$ -medible. Para $Z = \mathbb{E}(X | \mathcal{G})$ y $Y \in L^2(\mathcal{G})$,

$$\mathbb{E}[(X - Z)Y] = 0,$$

primero para Y acotada y luego por truncamiento. Así Z es la proyección ortogonal de X sobre $L^2(\mathcal{G})$ y

$$\mathbb{E}(X - Y)^2 = \mathbb{E}(X - Z)^2 + \mathbb{E}(Z - Y)^2.$$

Por tanto minimiza el error cuadrático, con unicidad c.s.

Tomando $\mathcal{G}$ trivial se recupera que $\mathbb{E}X$ es la mejor constante. Definir $\text{Var}(X | \mathcal{G}) = \mathbb{E}[(X - \mathbb{E}(X | \mathcal{G}))^2 | \mathcal{G}]$ produce

$$\text{Var}(X) = \mathbb{E} \text{Var}(X | \mathcal{G}) + \text{Var}(\mathbb{E}(X | \mathcal{G})).$$

La prueba expande $X - \mathbb{E}X = (X - Z) + (Z - \mathbb{E}X)$ y anula el término cruzado por ortogonalidad.

2.2. Predicción lineal, mezclas y sumas aleatorias

Objetivo de la sesión. Comparar predictor condicional y predictor afín y aplicar esperanzas totales.

Entre predictores $a + bY$, las ecuaciones normales dan, si $\text{Var } Y > 0$,

$$b = \frac{\text{Cov}(X, Y)}{\text{Var } Y}, \quad a = \mathbb{E}X - b\mathbb{E}Y.$$

La esperanza condicional $\mathbb{E}(X | Y)$ puede ser no lineal y nunca tiene mayor error cuadrático. Coinciden cuando el predictor condicional es afín, en particular en el caso conjuntamente gaussiano.

Para una mezcla con indicador latente C , la torre y la varianza total separan variación interior y entre grupos. Para $S_N = \sum_{k=1}^N X_k$, donde N es no negativo, independiente de una sucesión i.i.d., y existen los momentos necesarios,

$$\mathbb{E}S_N = \mathbb{E}N \mathbb{E}X_1, \quad \text{Var}(S_N) = \mathbb{E}N \text{Var } X_1 + \text{Var } N (\mathbb{E}X_1)^2.$$

Condicionado a $N = n$, la suma tiene media $n\mu$ y varianza $n\sigma^2$; aplicar torre y varianza total prueba ambas fórmulas. La independencia de N y la sucesión es una hipótesis, no una consecuencia del símbolo S_N .

Capítulo 3

Semana 10: vectores gaussianos

3.1. Construcción, singularidad e independencia

Objetivo de la sesión. Caracterizar vectores gaussianos por transformaciones lineales y covarianzas.

Un vector $X \in \mathbb{R}^d$ es gaussiano si toda combinación $a^T X$ es normal, permitiendo varianza cero. Equivalentemente, existen $Z \sim N(0, I_r)$, una matriz A y m tales que $X = m + AZ$. Su función característica es

$$\varphi_X(t) = \exp\{it^T m - \frac{1}{2}t^T \Sigma t\}, \quad \Sigma = AA^T.$$

Toda matriz semidefinida positiva admite una raíz espectral, lo que prueba la existencia incluso si Σ es singular; unicidad de funciones características prueba que (m, Σ) determina la ley.

Proposición 3.1. *Dos bloques X_1, X_2 de un vector conjuntamente gaussiano son independientes si y solo si su covarianza cruzada es cero.*

Demostración. Independencia implica covarianza cero. Recíprocamente, con covarianza por bloques diagonal, la función característica conjunta factoriza en las funciones de cada bloque; unicidad da la ley producto. $\square$

Tener marginales normales no basta para gaussianidad conjunta. Si $Z \sim N(0, 1)$ y S es un signo independiente, (Z, SZ) tiene marginales normales pero su soporte está en dos rectas y no es un vector gaussiano no degenerado.

3.2. Condicionamiento gaussiano

Objetivo de la sesión. Deducir la ley condicional mediante un residuo independiente.

Sea (X, Y) conjuntamente gaussiano, con medias m_X, m_Y y Σ_{YY} invertible. Poner

$$B = \Sigma_{XY} \Sigma_{YY}^{-1}, \quad R = X - m_X - B(Y - m_Y).$$

Entonces $\text{Cov}(R, Y) = 0$; como (R, Y) es conjuntamente gaussiano, son independientes. Por tanto

$$X \mid Y = y \sim N(m_X + B(y - m_Y), \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}).$$

La prueba no consiste en manipular informalmente densidades: la identidad $X = m_X + B(Y - m_Y) + R$ y la independencia dan una versión regular de la ley condicional. Se obtiene $\mathbb{E}(X \mid Y) = m_X + B(Y - m_Y)$, de modo que el mejor predictor condicional coincide con el lineal. En el caso singular se puede trabajar sobre el soporte o usar una pseudoinversa, extensión no exigible.

Capítulo 4

Semana 11: proyecciones gaussianas y leyes de muestreo

4.1. Gamma, chi-cuadrado y proyecciones

Objetivo de la sesión. Relacionar normas gaussianas, rango e independencia.

Si $Z_1, \dots, Z_r$ son normales estándar independientes, $\sum Z_i^2 \sim \chi_r^2$, una gamma de forma $r/2$ y escala 2. Esto se prueba multiplicando transformadas de Laplace:

$$\mathbb{E}e^{-tZ^2} = (1 + 2t)^{-1/2}, \quad t \geq 0.$$

Teorema 4.1 (Cochran, caso de proyectores). Sea $Z \sim N(0, I_n)$ y sean $P_1, \dots, P_k$ proyectores ortogonales simétricos con subespacios mutuamente ortogonales. Entonces $Z^T P_j Z$ son independientes y $Z^T P_j Z \sim \chi_{r_j}^2$, donde $r_j = \text{rango } P_j$.

Demostración. Elegir una base ortonormal adaptada a la suma de las imágenes de los proyectores y completarla. En esa base, una transformación ortogonal preserva la ley $N(0, I_n)$ y cada forma cuadrática es la suma de cuadrados de un bloque disjunto de coordenadas. Los bloques son independientes y sus tamaños son los rangos. $\square$

4.2. Muestra normal y Student

Objetivo de la sesión. Derivar la independencia de media y varianza y la ley del estadístico estudiantizado.

Para $X = (X_1, \dots, X_n)^T \sim N(\mu \mathbf{1}, \sigma^2 I)$, el proyector $P = \mathbf{1}\mathbf{1}^T/n$ separa

$$\|X - \mu \mathbf{1}\|^2 = \|P(X - \mu \mathbf{1})\|^2 + \|(I - P)X\|^2.$$

Los componentes son independientes. El primero equivale a $n(\bar{X} - \mu)^2$ y el segundo a $(n - 1)S^2$. Por Cochran,

$$\sqrt{n}(\bar{X} - \mu)/\sigma \sim N(0, 1), \quad (n - 1)S^2/\sigma^2 \sim \chi_{n-1}^2,$$

y son independientes. En consecuencia

$$T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1},$$

por definición de Student como $Z/\sqrt{V/\nu}$ con $Z \sim N(0, 1)$, $V \sim \chi_\nu^2$ independientes. Son leyes probabilísticas exactas; los procedimientos de inferencia quedan fuera del curso.

Capítulo 5

Semana 12: integrabilidad uniforme y martingalas

5.1. Integrabilidad uniforme

Objetivo de la sesión. Precisar cuándo la convergencia en probabilidad permite pasar a L^1 .

Una familia $\mathcal{X} \subset L^1$ es uniformemente integrable (UI) si

$$\lim_{K \rightarrow \infty} \sup_{X \in \mathcal{X}} \mathbb{E}(|X| \mathbf{1}_{\{|X| > K\}}) = 0.$$

UI implica acotación uniforme de $\mathbb{E}|X|$. Si $\sup_{X \in \mathcal{X}} \mathbb{E}|X|^p < \infty$ para algún $p > 1$, Markov dentro de la integral da UI. Para una sola $Y \in L^1$, la familia de expectativas condicionales $\{\mathbb{E}(Y | \mathcal{G}) : \mathcal{G} \subset \mathcal{F}\}$ es UI: para $A = \{|\mathbb{E}(Y | \mathcal{G})| > K\}$,

$$\mathbb{E}(|\mathbb{E}(Y | \mathcal{G})| \mathbf{1}_A) \leq \mathbb{E}(|Y| \mathbf{1}_A), \quad \mathbb{P}(A) \leq \mathbb{E}|Y|/K,$$

y la continuidad absoluta de la integral controla uniformemente el lado derecho.

Teorema 5.1 (Vitali). Si $X_n \rightarrow X$ en probabilidad, entonces $X_n \rightarrow X$ en L^1 si y solo si (X_n) es UI.

Demostración. Si hay convergencia L^1 , aproximar la cola de X_n por la de X y tratar separadamente un número finito de índices prueba UI. Recíprocamente, toda subsucesión contiene una subsucesión que converge c.s. a X . Para $K > 0$, la parte truncada $|X_{n_k} - X| \wedge K$ converge a cero y está dominada; las colas se hacen uniformemente pequeñas usando UI de (X_n) y de X (esta última se deduce por Fatou). Así toda subsucesión contiene otra con convergencia L^1 ; por el criterio de subsucesiones, la sucesión completa converge en L^1 . $\square$

5.2. Filtraciones y martingalas

Objetivo de la sesión. Reconocer procesos cuya predicción condicional es el valor presente.

Una filtración $(\mathcal{F}_n)$ es creciente. Un proceso adaptado integrable (M_n) es martingala si $\mathbb{E}(M_{n+1} | \mathcal{F}_n) = M_n$; se reemplaza igualdad por $\geq$ para submartingala. Si X_k son independientes, centradas e integrables, $M_n = \sum_{k \leq n} X_k$ es martingala con su filtración natural. Si $Y \in L^1$, $M_n = \mathbb{E}(Y | \mathcal{F}_n)$ es martingala por la torre y es UI por el criterio anterior.

Para una función convexa φ con integrabilidad, Jensen condicional muestra que $\varphi(M_n)$ es submartingala. En particular, $|M_n|$ y M_n^2 lo son cuando están integrables. Las diferencias $D_n = M_n - M_{n-1}$ cumplen $\mathbb{E}(D_n | \mathcal{F}_{n-1}) = 0$ y son ortogonales en L^2 para índices distintos; así $\mathbb{E}M_n^2 = \mathbb{E}M_0^2 + \sum_{k \leq n} \mathbb{E}D_k^2$.

Capítulo 6

Semana 13: parada y desigualdades de Doob

6.1. Tiempos de parada y parada opcional acotada

Objetivo de la sesión. Distinguir información disponible y demostrar la versión segura del teorema de parada.

Un tiempo T es de parada si $\{T \leq n\} \in \mathcal{F}_n$. El proceso detenido es $M_{n \wedge T}$. Como

$$M_{n \wedge T} = M_0 + \sum_{k=1}^n \mathbf{1}_{\{T \geq k\}}(M_k - M_{k-1}),$$

y $\{T \geq k\} \in \mathcal{F}_{k-1}$, un proceso detenido de una martingala es martingala.

Teorema 6.1 (Parada opcional acotada). *Si $S \leq T \leq N$ son tiempos de parada acotados y M es martingala, entonces $\mathbb{E}(M_T | \mathcal{F}_S) = M_S$ y $\mathbb{E}M_T = \mathbb{E}M_0$.*

Demostración. Para $A \in \mathcal{F}_S$, $A \cap \{S < k\} \in \mathcal{F}_{k-1}$. Escribir $M_T - M_S = \sum_{k=1}^N \mathbf{1}_{\{S < k \leq T\}} D_k$ y multiplicar por $\mathbf{1}_A$. Cada indicador previo al incremento es $\mathcal{F}_{k-1}$ -medible; su esperanza con D_k es cero. La caracterización de esperanza condicional concluye. $\square$

Sin acotación se necesitan hipótesis. Para la caminata simétrica que parte de cero y el primer tiempo de llegada a 1, se tiene $M_T = 1$ c.s., aunque $\mathbb{E}M_0 = 0$; aplicar el teorema sin justificar integrabilidad uniforme sería falso.

6.2. Desigualdades maximales

Objetivo de la sesión. Controlar el máximo de una submartingala y deducir acotación L^2 .

Teorema 6.2 (Doob). *Si $(X_k)_{k \leq n}$ es submartingala y $\lambda > 0$,*

$$\lambda \mathbb{P}\left(\max_{k \leq n} X_k \geq \lambda\right) \leq \mathbb{E}[X_n \mathbf{1}_{\{\max_{k \leq n} X_k \geq \lambda\}}].$$

Si M es martingala en L^p , $p > 1$, entonces $\mathbb{E}(\max_{k \leq n} |M_k|^p) \leq q^p \mathbb{E}|M_n|^p$, $q = p/(p-1)$.

Demostración. Partir el evento maximal según el primer cruce A_k . En A_k , $X_k \geq \lambda$ y, por submartingala, $\mathbb{E}[(X_n - X_k) \mathbf{1}_{A_k}] \geq 0$. Sumar prueba la primera desigualdad. Aplicarla a $|M_k|$, integrar $p\lambda^{p-1} \mathbb{P}(M_n^* \geq \lambda)$ en λ y usar Fubini produce $\mathbb{E}(M_n^*)^p \leq p \mathbb{E}[|M_n| (M_n^*)^{p-1}]$; Hölder y división concluyen. $\square$

Para $p = 2$, una martingala acotada en L^2 tiene máximos uniformemente acotados en L^2 y diferencias con suma de varianzas finita.

Capítulo 7

Semana 14: convergencia de martingalas y cadenas finitas

7.1. Cruces ascendentes y convergencia

Objetivo de la sesión. Deducir convergencia casi segura y en L^1 bajo las hipótesis del curso.

Para $a < b$, el número $U_n[a, b]$ cuenta cruces completos de abajo de a a arriba de b antes de n . La estrategia de comprar una unidad al bajar de a y venderla al superar b da, para una submartingala,

$$(b - a)\mathbb{E}U_n[a, b] \leq \mathbb{E}[(X_n - a)^+] - \mathbb{E}[(X_0 - a)^+].$$

Demostración. Poner $Y_k = a + (X_k - a)^+$; por Jensen condicional, (Y_k) es submartingala y tiene los mismos cruces de $[a, b]$ que (X_k) . Sea H_k el indicador predecible de que, justo antes del incremento k , se mantiene una unidad comprada después de una visita a $(-\infty, a]$ y todavía no vendida en $[b, \infty)$. Cada cruce completo produce al menos $b - a$ y una operación incompleta produce ganancia no negativa porque $Y_k \geq a$. Así, camino por camino,

$$(b - a)U_n[a, b] \leq (H \cdot Y)_n := \sum_{k=1}^n H_k(Y_k - Y_{k-1}).$$

Con $K_k = 1 - H_k$, se tiene $Y_n - Y_0 = (H \cdot Y)_n + (K \cdot Y)_n$. Como $K_k \geq 0$ es predecible y Y es submartingala, $\mathbb{E}(K \cdot Y)_n \geq 0$. Por consiguiente

$$\mathbb{E}(H \cdot Y)_n \leq \mathbb{E}(Y_n - Y_0) = \mathbb{E}(X_n - a)^+ - \mathbb{E}(X_0 - a)^+,$$

y se obtiene la desigualdad anunciada. □

Si $\sup_n \mathbb{E}X_n^+ < \infty$, el lado derecho queda acotado. Monotonía y Fatou implican que $U_\infty[a, b] < \infty$ c.s. para cada par racional $a < b$. Una sucesión real que no converge realiza infinitos cruces de algún intervalo racional entre su límite inferior y superior. Por tanto X_n converge c.s. a una variable extendida. Fatou controla que el límite no sea $+\infty$; además $\mathbb{E}X_n^- = \mathbb{E}X_n^+ - \mathbb{E}X_n \leq \sup_m \mathbb{E}X_m^+ - \mathbb{E}X_0$, por lo que Fatou también descarta $-\infty$. El límite es finito e integrable.

Teorema 7.1. Una martingala UI converge c.s. y en L^1 a algún $M_\infty \in L^1$, y $M_n = \mathbb{E}(M_\infty | \mathcal{F}_n)$.

Demostración. El resultado anterior da convergencia c.s.; UI y Vitali dan convergencia L^1 . Para $A \in \mathcal{F}_n$ y $m \geq n$, $\mathbb{E}(M_m \mathbf{1}_A) = \mathbb{E}(M_n \mathbf{1}_A)$. Pasar al límite L^1 da la identidad definitoria de la esperanza condicional. □

7.2. Introducción a cadenas de Markov finitas

Objetivo de la sesión. Calcular evolución, Chapman–Kolmogorov, estacionariedad y periodicidad en ejemplos.

Una cadena homogénea sobre un conjunto finito E satisface

$$\mathbb{P}(X_{n+1} = j \mid X_0, \dots, X_n) = p_{X_n j}.$$

La matriz $P = (p_{ij})$ es estocástica por filas. Si μ_n es la ley fila de X_n , entonces $\mu_{n+1} = \mu_n P$ y $\mu_n = \mu_0 P^n$.

Proposición 7.2 (Chapman–Kolmogorov). $p_{ij}^{(m+n)} = \sum_k p_{ik}^{(m)} p_{kj}^{(n)}$; equivalentemente, $P^{m+n} = P^m P^n$.

Demostración. Condicionar por el estado $X_m = k$ y usar la propiedad de Markov y homogeneidad: $\mathbb{P}_i(X_{m+n} = j) = \sum_k \mathbb{P}_i(X_m = k) \mathbb{P}_k(X_n = j)$. $\square$

Una distribución π es estacionaria si $\pi P = \pi$. Para $P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}$ con $a+b > 0$, resolver da $\pi = (b, a)/(a+b)$. No toda cadena converge a su estacionaria: con $P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$, $\pi = (1/2, 1/2)$ es estacionaria, pero desde un estado fijo la ley alterna. Este ejemplo introduce periodicidad. No se estudian recurrencia general, cadenas numerables ni teorema ergódico.