



# Sesión 1. Modelos y probabilidad

Unidad 1 · Primera semana

«La probabilità non esiste.»  
Bruno de Finetti

La frase no niega el cálculo que sigue: provoca una pregunta sobre qué significan sus números fuera del formalismo. Los axiomas producen consecuencias matemáticas; al aplicarlos debemos justificar por qué el espacio, los eventos y la probabilidad elegidos representan la situación.

**Objetivos.** Formular un modelo, justificar continuidad de probabilidades y usar el condicionamiento por eventos. La teoría de la medida se recuerda; sus aplicaciones probabilísticas se demuestran.

**Regla de trabajo para los ejemplos.** Antes de efectuar una cuenta seguiremos tres pasos: (i) describir el experimento y su espacio de resultados; (ii) fijar la probabilidad; (iii) definir como eventos los sucesos mencionados en la pregunta. Solo entonces calcularemos. No introduciremos una variable aleatoria cuando los eventos basten; ese concepto comienza en la sesión 2.

## 1. Del experimento al modelo

Un modelo especifica qué resultados distinguimos, qué sucesos podemos medir y con qué probabilidades. No hay equiprobabilidad por el solo hecho de que un conjunto sea finito.

**Ejemplo: dos lanzamientos.** El experimento consiste en lanzar dos veces una moneda y registrar, en orden, cruz (0) o cara (1). Un resultado es un par  $\omega = (\omega_1, \omega_2)$ . Adoptamos el modelo

$$\Omega = \{00, 01, 10, 11\}, \quad \mathcal{F} = 2^\Omega, \quad \mathbb{P}(\{\omega\}) = \frac{1}{4}.$$

Este modelo expresa dos lanzamientos equilibrados e independientes; la independencia se formalizará en la semana 2. Para responder preguntas sobre el número de caras no necesitamos definir todavía una variable aleatoria. Identificamos directamente los eventos

$$A_0 = \{\text{ninguna cara}\} = \{00\}, \quad A_1 = \{\text{exactamente una cara}\} = \{01, 10\},$$

$$A_2 = \{\text{exactamente dos caras}\} = \{11\}.$$

Por aditividad,

$$\mathbb{P}(A_0) = \frac{1}{4}, \quad \mathbb{P}(A_1) = \frac{2}{4}, \quad \mathbb{P}(A_2) = \frac{1}{4}.$$

Los tres eventos corresponden a los posibles conteos 0, 1, 2, pero no son equiprobables; no corresponde asignarles  $1/3$ . Si sabemos que apareció al menos una cara, la información es el evento

$$H = A_1 \cup A_2 = \{01, 10, 11\}.$$

El suceso preguntado “dos caras” es  $A_2 \subset H$ . Por ahora observamos que  $\mathbb{P}(H) = 3/4$ ; en la sección 4, después de definir probabilidad condicional, obtendremos  $\mathbb{P}(A_2 | H) = 1/3$ .

**Definición.** Una  $\sigma$ -álgebra  $\mathcal{F}$  sobre  $\Omega$  contiene a  $\Omega$  y es cerrada bajo complementos y uniones numerables. Un *espacio de probabilidad* es una terna  $(\Omega, \mathcal{F}, \mathbb{P})$  donde  $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ ,  $\mathbb{P}(\Omega) = 1$  y, para eventos disjuntos dos a dos,

$$\mathbb{P}\left(\bigcup_{n \geq 1} A_n\right) = \sum_{n \geq 1} \mathbb{P}(A_n).$$

Un resultado es  $\omega \in \Omega$ ; un evento es  $A \in \mathcal{F}$ . Sin  $\mathbb{P}$ , el par  $(\Omega, \mathcal{F})$  se llama *espacio medible*.

**Recordatorio de medida.** Se tiene  $\emptyset \in \mathcal{F}$  y, por De Morgan,  $\bigcap_n A_n = (\bigcup_n A_n^c)^c \in \mathcal{F}$ . También  $A \setminus B = A \cap B^c \in \mathcal{F}$ . La  $\sigma$ -álgebra  $\mathcal{B}(\mathbb{R})$  está generada por los abiertos. Usaremos la medida de Lebesgue  $\lambda$  sin reconstruirla.

**Dos modelos de referencia.**

- En un espacio finito o numerable, dadas masas  $p_\omega \geq 0$  con  $\sum_\omega p_\omega = 1$ , se define  $\mathbb{P}(A) = \sum_{\omega \in A} p_\omega$  sobre  $2^\Omega$ . La aditividad resulta de reagrupar series no negativas.
- En  $\Omega = [0, 1]$ , con la  $\sigma$ -álgebra boreliana relativa,  $\mathbb{P}(A) = \lambda(A)$ . Así  $\mathbb{P}([a, b]) = b - a$  para  $0 \leq a \leq b \leq 1$ . No definimos esta medida sobre todos los subconjuntos de  $[0, 1]$ .

**Lectura estadística.** El modelo describe la distribución de una observación antes de observarla. Los datos son realizaciones. Una frecuencia observada no es, por definición, la probabilidad del modelo; las leyes de los grandes números estudiarán su relación.

## Sesión 1 · 2. Propiedades y continuidad

Todos los conjuntos que aparecen a continuación son medibles.

**Proposición 1.** Se cumplen:

$$\mathbb{P}(\emptyset) = 0, \quad \mathbb{P}(A^c) = 1 - \mathbb{P}(A), \quad A \subset B \implies \mathbb{P}(A) \leq \mathbb{P}(B),$$

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B), \quad \mathbb{P}\left(\bigcup_n A_n\right) \leq \sum_n \mathbb{P}(A_n).$$

*Demostración.* Aplicar la aditividad a  $\Omega, \emptyset, \emptyset, \dots$  fuerza  $\mathbb{P}(\emptyset) = 0$ . Las descomposiciones disjuntas  $\Omega = A \cup A^c$  y  $B = A \cup (B \setminus A)$ , si  $A \subset B$ , prueban complemento y monotonía. Como  $A \cup B = A \cup (B \setminus A)$  y  $B = (B \setminus A) \cup (A \cap B)$ , se obtiene la fórmula de la unión. Para la última desigualdad, poner

$$D_1 = A_1, \quad D_n = A_n \setminus \bigcup_{j < n} A_j \quad (n \geq 2).$$

Los  $D_n$  son disjuntos,  $D_n \subset A_n$  y  $\bigcup D_n = \bigcup A_n$ . La aditividad y la monotonía dan la desigualdad.  $\square$

**Teorema 2: continuidad de la probabilidad.** Si  $A_n \uparrow A$ , es decir,  $A_n \subset A_{n+1}$  y  $A = \bigcup_n A_n$ , entonces  $\mathbb{P}(A_n) \uparrow \mathbb{P}(A)$ . Si  $A_n \downarrow A$ , con  $A = \bigcap_n A_n$ , entonces  $\mathbb{P}(A_n) \downarrow \mathbb{P}(A)$ .

*Demostración.* En el caso creciente, tomar  $A_0 = \emptyset$  y  $D_n = A_n \setminus A_{n-1}$ . Son disjuntos y  $A_n = \bigcup_{k=1}^n D_k$ ,  $A = \bigcup_{k \geq 1} D_k$ . Por tanto,

$$\mathbb{P}(A) = \sum_{k \geq 1} \mathbb{P}(D_k) = \lim_{n \rightarrow \infty} \sum_{k=1}^n \mathbb{P}(D_k) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

En el caso decreciente,  $A_n^c \uparrow A^c$ . Lo probado y la fórmula del complemento dan  $1 - \mathbb{P}(A_n) \rightarrow 1 - \mathbb{P}(A)$ .  $\square$

**Hipótesis crucial.** Para una medida general, la continuidad desde arriba requiere masa finita de algún término. En Lebesgue,  $[n, \infty) \downarrow \emptyset$  pero todas sus medidas son infinitas. En probabilidad la finitud es automática.

### 3. Nulo no significa vacío

Un evento nulo tiene probabilidad cero; una propiedad vale *casi seguramente* si el evento donde falla es nulo. Precisemos primero el modelo:  $\Omega = [0, 1]$ ,  $\mathcal{F} = \mathcal{B}([0, 1])$  y  $\mathbb{P} = \lambda$ . El evento “el resultado es exactamente  $1/2$ ” es

$$E = \{1/2\}.$$

Es no vacío, pero  $\mathbb{P}(E) = \lambda(\{1/2\}) = 0$ . El evento “observar un racional” es

$$R = \mathbb{Q} \cap [0, 1].$$

Como  $R$  es una unión numerable de singletons, la subaditividad da  $\mathbb{P}(R) = 0$ . Así, el resultado es irracional casi seguramente.

No puede sustituirse “numerable” por “arbitraria”:  $[0, 1] = \bigcup_{x \in [0, 1]} \{x\}$  tiene probabilidad uno. En un espacio no completo, un subconjunto de un evento nulo no tiene por qué ser medible; aquí solo asignamos probabilidades a eventos de  $\mathcal{F}$ .

## Sesión 1 · 4. Condicionar y actualizar

**Definición.** Para  $B \in \mathcal{F}$  con  $\mathbb{P}(B) > 0$ , se define

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

La información  $B$  cambia las proporciones con las que se ponderan los resultados. El denominador es la probabilidad de la información disponible.

**Proposición 3.** Para  $B$  fijo de probabilidad positiva,  $A \mapsto \mathbb{P}(A | B)$  es una probabilidad sobre  $(\Omega, \mathcal{F})$ .

*Demostración.* Es no negativa y  $\mathbb{P}(\Omega | B) = 1$ . Si los  $A_n$  son disjuntos, los  $A_n \cap B$  también lo son; luego

$$\mathbb{P}\left(\bigcup_n A_n \mid B\right) = \frac{\sum_n \mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_n \mathbb{P}(A_n | B). \quad \square$$

**Teorema 4: probabilidad total y Bayes.** Sea  $(B_i)_{i \in I}$  una partición finita o numerable de  $\Omega$  en eventos con  $\mathbb{P}(B_i) > 0$ . Entonces

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i).$$

Si además  $\mathbb{P}(A) > 0$ , para cada  $j \in I$ ,

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(A | B_j) \mathbb{P}(B_j)}{\sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i)}.$$

*Demostración.* Los  $A \cap B_i$  son disjuntos y su unión es  $A$ . La aditividad da  $\mathbb{P}(A) = \sum_i \mathbb{P}(A \cap B_i)$ ; la definición de condicionamiento da la primera fórmula. Sustituirla en  $\mathbb{P}(B_j | A) = \mathbb{P}(A \cap B_j) / \mathbb{P}(A)$  prueba la segunda.  $\square$

Si una celda de la partición es nula, su intersección con  $A$  es nula. Se omite esa celda de la suma; no se utiliza una expresión indefinida multiplicada por cero.

**Ejemplo resuelto: procedencia de una pieza. Enunciado.** Dos líneas de producción aportan, respectivamente, el 60 % y el 40 % de las piezas de una fábrica. El 2 % de las piezas producidas por la línea 1 y el 5 % de las producidas por la línea 2 son defectuosas. Se elige al azar una pieza de la producción conjunta y se la inspecciona.

- ¿Cuál es la probabilidad de que la pieza elegida sea defectuosa?
- Si la pieza elegida resulta defectuosa, ¿cuál es la probabilidad de que proceda de la línea 2?

**Modelización.** Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un modelo para este experimento: cada  $\omega \in \Omega$  representa una pieza seleccionada junto con su procedencia y su estado. Definimos directamente los eventos

$$L_1 = \{\text{la pieza procede de la línea 1}\},$$

$$L_2 = \{\text{la pieza procede de la línea 2}\}, \quad D = \{\text{la pieza es defectuosa}\}.$$

Los eventos  $L_1, L_2$  forman una partición de  $\Omega$ . Los datos del modelo, escritos como probabilidades, son

$$\mathbb{P}(L_1) = 0.60, \quad \mathbb{P}(L_2) = 0.40, \quad \mathbb{P}(D | L_1) = 0.02, \quad \mathbb{P}(D | L_2) = 0.05.$$

La primera pregunta es “¿cuál es la probabilidad de defecto?”, es decir, calcular  $\mathbb{P}(D)$ . Descomponemos primero el evento:

$$D = (D \cap L_1) \dot{\cup} (D \cap L_2).$$

Por probabilidad total,

$$\mathbb{P}(D) = 0.60(0.02) + 0.40(0.05) = 0.032.$$

La segunda pregunta es “dada una pieza defectuosa, ¿cuál es la probabilidad de que proceda de la línea 2?”: el evento buscado es  $L_2$  y la información condicionante es  $D$ . Entonces

$$\mathbb{P}(L_2 | D) = \frac{\mathbb{P}(L_2 \cap D)}{\mathbb{P}(D)} = \frac{\mathbb{P}(D | L_2)\mathbb{P}(L_2)}{\mathbb{P}(D)} = \frac{0.05(0.40)}{0.032} = \frac{5}{8}.$$

Entre 10000 piezas bajo estas proporciones, los conteos de referencia serían 120 y 200 defectuosas por línea:  $200/320 = 5/8$ . Es una traducción de las proporciones del modelo, no una afirmación sobre un lote observado.

**Cierre.**  $\mathbb{P}(D | L_2) = 0.05$  no es  $\mathbb{P}(L_2 | D) = 0.625$ . Si  $\mathbb{P}(B) = 0$ , el cociente de la definición no existe. El condicionamiento respecto de variables y  $\sigma$ -álgebras se desarrollará en la semana 8.



## Sesión 2. Variables y leyes

Unidad 1 · Primera semana

**Objetivos.** Recordar el teorema  $\pi$ - $\lambda$ ; separar variable y ley; verificar medibilidad; deducir las propiedades de una función de distribución y distinguir leyes discretas, con densidad y mixtas.

**Regla de trabajo.** Para una pregunta sobre  $X$ , escribiremos primero el modelo  $(\Omega, \mathcal{F}, \mathbb{P})$ , la definición de  $X$  y el evento como preimagen; por ejemplo, “ $X \leq x$ ” significa  $\{\omega : X(\omega) \leq x\}$ . La probabilidad se aplica al evento, no al símbolo aislado.

### 0. Recordatorio: sistemas $\pi$ y sistemas de Dynkin

Sea  $E$  un conjunto. Una familia no vacía  $\mathcal{P} \subset 2^E$  es un *sistema  $\pi$*  si

$$A, B \in \mathcal{P} \implies A \cap B \in \mathcal{P}.$$

Una familia  $\mathcal{D} \subset 2^E$  es un *sistema de Dynkin*, o *sistema  $\lambda$* , si cumple:

1.  $E \in \mathcal{D}$ ;
2. si  $A \in \mathcal{D}$ , entonces  $E \setminus A \in \mathcal{D}$ ;
3. si  $A_1, A_2, \dots \in \mathcal{D}$  son disjuntos dos a dos, entonces  $\bigcup_{n \geq 1} A_n \in \mathcal{D}$ .

Denotamos por  $\lambda(\mathcal{P})$  el menor sistema de Dynkin que contiene a  $\mathcal{P}$ , es decir, la intersección de todos los sistemas de Dynkin que contienen a  $\mathcal{P}$ .

**Teorema de Dynkin, o teorema  $\pi$ - $\lambda$ .** Si  $\mathcal{P}$  es un sistema  $\pi$  sobre  $E$ , entonces

$$\lambda(\mathcal{P}) = \sigma(\mathcal{P}).$$

En particular, todo sistema de Dynkin que contiene a  $\mathcal{P}$  contiene también a la  $\sigma$ -álgebra generada por  $\mathcal{P}$ .

**Teorema de unicidad de probabilidades.** Sean  $\mu$  y  $\nu$  probabilidades sobre  $(E, \sigma(\mathcal{P}))$ , donde  $\mathcal{P}$  es un sistema  $\pi$ . Si

$$\mu(A) = \nu(A) \quad \text{para todo } A \in \mathcal{P},$$

entonces  $\mu = \nu$  en  $\sigma(\mathcal{P})$ .

**Consecuencia en la recta.** La familia

$$\mathcal{P} = \{\mathbb{R}\} \cup \{(-\infty, x] : x \in \mathbb{R}\}$$

es un sistema  $\pi$  y genera  $\mathcal{B}(\mathbb{R})$ . Por tanto, dos probabilidades sobre  $\mathbb{R}$  que coinciden en todas las semirrectas  $(-\infty, x]$  son iguales. Esta es la herramienta que permitirá concluir que una función de distribución determina una única ley.

### 1. Una variable es una función medible

**Advertencia terminológica.** Se suele decir, con intención provocadora:

*“Una variable aleatoria ni es variable ni es aleatoria”.*

En efecto,  $X$  es una función fija: a cada resultado  $\omega$  le asigna un valor  $X(\omega)$ . Lo que varía es el resultado del experimento, y la incertidumbre proviene de no saber qué  $\omega$  ocurrirá; la ley de  $X$  describe cómo esa incertidumbre sobre  $\Omega$  se transporta al espacio de valores.

**Definición.** Una variable aleatoria real es una aplicación medible  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ . Esto significa que

$$\{X \in C\} := X^{-1}(C) = \{\omega : X(\omega) \in C\} \in \mathcal{F} \quad \text{para todo } C \in \mathcal{B}(\mathbb{R}).$$

La notación  $\{X \leq x\}$  abrevia  $X^{-1}((-\infty, x])$ . La medibilidad garantiza que las preguntas acerca de la observación tengan probabilidades definidas.

**Proposición 5: criterio práctico.**  $X$  es medible si y solo si  $\{X \leq x\} \in \mathcal{F}$  para cada  $x \in \mathbb{R}$ .

*Demostración.* La necesidad se sigue de la definición. Para la suficiencia, la clase  $\mathcal{C} = \{C \subset \mathbb{R} : X^{-1}(C) \in \mathcal{F}\}$  es una  $\sigma$ -álgebra, pues las preimágenes preservan complementos y uniones. Por hipótesis contiene todos los intervalos  $(-\infty, x]$ . Estos generan  $\mathcal{B}(\mathbb{R})$ :  $(-\infty, b) = \bigcup_n (-\infty, b - 1/n]$ , los intervalos abiertos se obtienen por diferencias y todo abierto de  $\mathbb{R}$  es unión numerable de intervalos con extremos racionales. Por tanto  $\mathcal{B}(\mathbb{R}) \subset \mathcal{C}$ .  $\square$

**Ejemplo: una observación demasiado fina.** Sean  $\Omega = \{1, 2, 3, 4\}$  y  $\mathcal{F} = \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}\}$ . Para decidir medibilidad todavía no necesitamos fijar una probabilidad. Definimos explícitamente

$$X(1) = X(2) = 0, \quad X(3) = X(4) = 1,$$

y

$$Y(1) = Y(3) = 0, \quad Y(2) = Y(4) = 1.$$

Para  $X$ , las preimágenes de sus valores son  $\{X = 0\} = \{1, 2\} \in \mathcal{F}$  y  $\{X = 1\} = \{3, 4\} \in \mathcal{F}$ ; por tanto, todas sus preimágenes borelianas pertenecen a  $\mathcal{F}$ . En cambio, el evento que correspondería a observar  $Y \leq 0$  es

$$\{Y \leq 0\} = Y^{-1}((-\infty, 0]) = \{1, 3\} \notin \mathcal{F}.$$

Así,  $X$  es medible y  $Y$  no lo es: con la información representada por  $\mathcal{F}$ ,  $Y$  pretende distinguir resultados que el modelo no distingue.

## 2. La ley es una medida sobre los valores

**Definición y verificación.** La *ley* de  $X$  es  $\mu_X(C) = \mathbb{P}(X \in C)$ , para  $C$  boreliano. Es una probabilidad:  $\mu_X(\mathbb{R}) = 1$ , es no negativa y, si los  $C_n$  son disjuntos, sus preimágenes también lo son, de modo que

$$\mu_X\left(\bigcup_n C_n\right) = \mathbb{P}\left(\bigcup_n X^{-1}(C_n)\right) = \sum_n \mu_X(C_n).$$

En el modelo de dos lanzamientos de la sesión 1 definimos ahora la variable “número de caras” mediante

$$N(00) = 0, \quad N(01) = N(10) = 1, \quad N(11) = 2.$$

Sus preimágenes  $\{N = 0\}$ ,  $\{N = 1\}$  y  $\{N = 2\}$  son precisamente los eventos  $A_0, A_1, A_2$  ya identificados. Por tanto, su ley satisface

$$\mu_N(\{0\}) = \frac{1}{4}, \quad \mu_N(\{1\}) = \frac{1}{2}, \quad \mu_N(\{2\}) = \frac{1}{4}.$$

**No confundir.**  $X$ ,  $X(\omega)$  y  $\mu_X$  son, respectivamente, función, valor observado y medida. Dos variables pueden tener la misma ley sin coincidir. En el modelo  $(\Omega, \mathcal{F}, \mathbb{P}) = ([0, 1], \mathcal{B}([0, 1]), \lambda)$ , definamos  $U(\omega) = \omega$  y  $V(\omega) = 1 - \omega$ . Para  $0 \leq x \leq 1$ , los eventos son

$$\{U \leq x\} = [0, x], \quad \{V \leq x\} = [1 - x, 1].$$

Ambos tienen probabilidad  $x$ , así que  $U$  y  $V$  tienen la misma ley uniforme. Sin embargo,  $\{U = V\} = \{1/2\}$  es un evento nulo.

## Sesión 2 · 3. Función de distribución

Para cada  $x \in \mathbb{R}$  fijamos primero el evento

$$A_x = \{X \leq x\} = X^{-1}((-\infty, x]).$$

La familia  $(A_x)$  es creciente en  $x$  y todas sus probabilidades están definidas por la medibilidad de  $X$ .

**Convención del curso.** Para toda variable real  $X$ ,

$$F_X(x) = \mathbb{P}(X \leq x).$$

Usaremos siempre  $\leq$ . Saporta usa  $\mathbb{P}(X < x)$  en la edición consultada; no se trasladan sus convenciones de continuidad ni sus extremos de intervalos sin ajustarlos.

**Teorema 6.**  $F_X$  es no decreciente, continua por la derecha y satisface

$$\lim_{x \rightarrow -\infty} F_X(x) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = 1.$$

Además, con  $F_X(x-) = \lim_{t \uparrow x} F_X(t)$ ,

$$F_X(x-) = \mathbb{P}(X < x), \quad \mathbb{P}(X = x) = F_X(x) - F_X(x-).$$

*Demostración.* Si  $x \leq y$ ,  $\{X \leq x\} \subset \{X \leq y\}$ , y la monotonía de  $\mathbb{P}$  prueba la de  $F_X$ . Como  $X$  toma valores reales finitos,

$$\{X \leq n\} \uparrow \Omega, \quad \{X \leq -n\} \downarrow \emptyset.$$

La continuidad de  $\mathbb{P}$  da los límites a lo largo de enteros; la monotonía los extiende al límite real.

Si  $x_n \downarrow x$ , entonces  $\{X \leq x_n\} \downarrow \{X \leq x\}$ , de donde  $F_X(x_n) \rightarrow F_X(x)$ . Esta es la continuidad por la derecha.

Si  $x_n \uparrow x$  con  $x_n < x$ , entonces  $\{X \leq x_n\} \uparrow \{X < x\}$ . Por continuidad desde abajo,  $F_X(x-) = \mathbb{P}(X < x)$ . Finalmente,  $\{X \leq x\} = \{X < x\} \cup \{X = x\}$  es una unión disjunta; restar prueba la fórmula del salto.  $\square$

**Corolario 7: probabilidades de intervalos.** Para  $a < b$ ,

$$\begin{aligned} \mathbb{P}(a < X \leq b) &= F_X(b) - F_X(a), \\ \mathbb{P}(a \leq X \leq b) &= F_X(b) - F_X(a-), \\ \mathbb{P}(a < X < b) &= F_X(b-) - F_X(a), \\ \mathbb{P}(a \leq X < b) &= F_X(b-) - F_X(a-). \end{aligned}$$

*Demostración.* Cada fórmula resta la probabilidad de la semirrecta que se excluye de la semirrecta que se incluye. Por ejemplo,  $\{X \leq b\} = \{X < a\} \cup \{a \leq X \leq b\}$ , disjuntamente, prueba la segunda. Las otras descomposiciones son idénticas con sus respectivos extremos.  $\square$

**Consecuencia.**  $F_X$  es continua en  $x$  si y solo si  $\mathbb{P}(X = x) = 0$ . Una función de distribución continua no tiene átomos; eso, por sí solo, no afirma que admita densidad.

## Sesión 2 · 4. Tres tipos de ley

**Discreta.** Si  $\mathbb{P}(X \in \{x_1, x_2, \dots\}) = 1$ , con valores distintos, entonces  $p_k = \mathbb{P}(X = x_k)$  y

$$\mu_X(C) = \sum_{k: x_k \in C} p_k, \quad F_X(x) = \sum_{k: x_k \leq x} p_k.$$

Estas fórmulas resultan de la aditividad sobre los singletons disjuntos; el complemento del conjunto de valores tiene masa cero. Para precisar el caso Bernoulli, sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad, sea  $A \in \mathcal{F}$  un evento y definamos  $X = \mathbf{1}_A$ . Entonces

$$\{X = 1\} = A, \quad \{X = 0\} = A^c, \quad p = \mathbb{P}(A).$$

Antes de calcular  $F_X(x)$ , las preimágenes son  $\{X \leq x\} = \emptyset$  si  $x < 0$ ,  $A^c$  si  $0 \leq x < 1$  y  $\Omega$  si  $x \geq 1$ . Por tanto,

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - p, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

Se llama ley de Bernoulli de parámetro  $p$ . Las masas son los saltos.

**Con densidad.** La ley admite densidad si hay  $f \geq 0$  medible con  $\int_{\mathbb{R}} f \, dx = 1$  y  $\mu_X(C) = \int_C f \, dx$  para todo boreliano  $C$ . Entonces

$$F_X(x) = \int_{-\infty}^x f(t) \, dt, \quad \mathbb{P}(X = x) = 0.$$

La segunda igualdad se debe a que un singleton tiene medida de Lebesgue cero. Una densidad es una función que se integra;  $f(x)$  no es la probabilidad de  $X = x$  y puede ser mayor que uno. Por el teorema fundamental para la integral de Lebesgue,  $F'_X = f$  casi en todas partes, no necesariamente en cada punto.

**Ejemplo con densidad.** Construimos primero el modelo canónico:  $\Omega = \mathbb{R}$ ,  $\mathcal{F} = \mathcal{B}(\mathbb{R})$ ,

$$\mathbb{P}(C) = \int_C 2t \mathbf{1}_{(0,1)}(t) \, dt, \quad X(\omega) = \omega.$$

La función  $f(t) = 2t \mathbf{1}_{(0,1)}(t)$  es no negativa e integra uno. El evento  $\{X \leq x\}$  es  $(-\infty, x]$ ; por eso

$$F_X(x) = \begin{cases} 0, & x \leq 0, \\ x^2, & 0 < x < 1, \\ 1, & x \geq 1. \end{cases}$$

Para la pregunta de intervalo identificamos

$$B = \{1/2 < X \leq 1\} = X^{-1}((1/2, 1]) = (1/2, 1].$$

Luego  $\mathbb{P}(B) = F_X(1) - F_X(1/2) = 1 - 1/4 = 3/4$ . La aditividad de  $\mathbb{P}$  se obtiene por convergencia monótona aplicada a las sumas de indicadores disjuntos.

**Mixta: cero o tiempo positivo.** Para  $0 < q < 1$ , definir

$$\mu(C) = q \mathbf{1}_{\{0 \in C\}} + \frac{1-q}{2} \lambda(C \cap (1, 3)).$$

Tomamos el modelo canónico  $(\Omega, \mathcal{F}, \mathbb{P}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mu)$  y la variable identidad  $X(\omega) = \omega$ . La medida combina una masa  $q$  en cero y una masa  $1 - q$  distribuida uniformemente en  $(1, 3)$ . Para hallar la función de distribución usamos el evento  $A_x = \{X \leq x\} = (-\infty, x]$  y obtenemos

$$F(x) = \begin{cases} 0, & x < 0, \\ q, & 0 \leq x < 1, \\ q + (1-q)(x-1)/2, & 1 \leq x < 3, \\ 1, & x \geq 3. \end{cases}$$

Tiene un salto  $q$  en cero y una parte con densidad. No tiene una densidad global respecto de Lebesgue: la integral sobre  $\{0\}$  sería cero, pero su masa es  $q$ . Para comparar extremos de intervalo, definimos

$$B = \{0 < X \leq 2\} = (0, 2], \quad C = \{0 \leq X \leq 2\} = [0, 2].$$

El segundo evento contiene además el átomo  $\{X = 0\} = \{0\}$ . Por tanto,

$$\mathbb{P}(B) = \frac{1-q}{2}, \quad \mathbb{P}(C) = q + \frac{1-q}{2}.$$

## Anexo de la sesión 2 · Caracterización completa

**Lectura complementaria con demostración.** No se exigirá reproducir esta prueba en una evaluación si no se ha trabajado en clase. El resultado explica por qué una función de distribución determina una ley y permite construirla.

**Teorema 8.** Sea  $F : \mathbb{R} \rightarrow [0, 1]$  no decreciente, continua por la derecha, con límites 0 y 1 en  $-\infty$  y  $+\infty$ . Existe una única probabilidad  $\mu$  en  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  con  $\mu((-\infty, x]) = F(x)$ .

*Demostración. Existencia.* En  $\Omega = (0, 1)$  con probabilidad uniforme, para  $0 < u < 1$  poner

$$Q(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}.$$

El conjunto es no vacío por el límite en  $+\infty$  y está acotado inferiormente por el límite en  $-\infty$ . Por tanto  $Q(u)$  es real. Si  $a = Q(u)$ , para cada  $n$  hay  $y_n < a + 1/n$  con  $F(y_n) \geq u$ . Luego  $F(a + 1/n) \geq u$ ; la continuidad por la derecha da  $F(a) \geq u$ . Así el ínfimo pertenece al conjunto.

En consecuencia, para cualquier  $x$ ,

$$Q(u) \leq x \iff u \leq F(x).$$

La implicación hacia la derecha usa  $F(Q(u)) \geq u$  y monotonía; la inversa usa que  $x$  pertenece al conjunto cuyo ínfimo se toma. Por ello  $\{u : Q(u) \leq x\} = (0, F(x)] \cap (0, 1)$  es boreliano, y  $Q$  es medible por la proposición 5. La ley de  $Q$  satisface

$$\mathbb{P}(Q \leq x) = \lambda((0, F(x)] \cap (0, 1)) = F(x).$$

*Unicidad.* Si  $\mu, \nu$  son dos probabilidades con la misma  $F$ , la clase  $\mathcal{D} = \{C \in \mathcal{B}(\mathbb{R}) : \mu(C) = \nu(C)\}$  contiene a  $\mathbb{R}$ , es cerrada bajo complementos (ambas masas totales son uno) y bajo uniones disjuntas (por aditividad). Contiene  $\mathcal{P} = \{\mathbb{R}\} \cup \{(-\infty, x] : x \in \mathbb{R}\}$ , que es un sistema  $\pi$  y genera  $\mathcal{B}(\mathbb{R})$ . El teorema  $\pi$ - $\lambda$  enunciado al comienzo de la sesión da  $\mathcal{D} = \mathcal{B}(\mathbb{R})$ , lo que prueba la unicidad.  $\square$

**Qué se ha usado como prerrequisito.** Medida de Lebesgue, convergencia monótona, el teorema fundamental de la integral de Lebesgue y el lema  $\pi$ - $\lambda$ . Las aplicaciones nuevas se han justificado; no se repite la construcción de medidas ni la demostración de esos resultados del curso previo.

**Lecturas de apoyo.** G. Saporta, *Probabilités, analyse des données et statistique*, 2.<sup>a</sup> ed., 2006: capítulo 1, §§1.1–1.3, y capítulo 2, §2.1.1 (ajustar la convención de  $F$ ). R. Durrett, *Probability: Theory and Examples*, ed. 4.1: §§1.1 y 1.3. S. Sheffield, MIT 18.175 (2014): clase 1 y selección de la clase 2 sobre distribuciones en la recta. Estas notas y sus ejemplos son una elaboración para CM4H1, no una traducción literal.