



Notas · Semana 3

Teoría de la Probabilidad · CM4H1

Transformaciones, familias, vectores y muestras

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 3

Transformar variables y organizar información multivariada

Propósito. La sesión 1 obtiene leyes por preimágenes y por cambio de variables, y presenta distribuciones básicas como modelos generadores. La sesión 2 desarrolla vectores aleatorios, matrices de covarianza y las identidades fundamentales de una muestra i.i.d. Las distribuciones complementarias se practican en ejercicios; no se convierten en un catálogo de fórmulas.

Recordatorios de medida. Medida imagen, integración respecto de una ley, función inversa generalizada, cambio de variables en integrales de Lebesgue, Tonelli–Fubini y Cauchy–Schwarz. Se enuncian en el punto exacto donde se emplean.

Sesión 1. Transformaciones y modelos fundamentales

Objetivo de la sesión. Obtener la ley de $Y = g(X)$ desde sus preimágenes y reconocer mecanismos que producen familias probabilísticas.

3.1. La ley transformada se obtiene por preimágenes

Sea $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ una variable y $g : \mathbb{R} \rightarrow \mathbb{R}$ boreliana. Definimos $Y = g(X)$. Para cada boreliano B ,

$$\mu_Y(B) = \mathbb{P}(Y \in B) = \mathbb{P}(X \in g^{-1}(B)) = \mu_X(g^{-1}(B)).$$

Esta identidad es el punto de partida; una fórmula con derivadas solo es una consecuencia cuando g posee regularidad suficiente.

Proposición 3.1 (Transformación monótona). *Supongamos que g es estrictamente creciente y continua en un intervalo I que contiene a X c.s. Entonces, para $y \in g(I)$,*

$$F_Y(y) = F_X(g^{-1}(y)).$$

Si g es estrictamente decreciente y X no tiene átomos,

$$F_Y(y) = 1 - F_X(g^{-1}(y)).$$

En presencia de átomos debe conservarse el extremo correcto: $\mathbb{P}(X \geq a) = 1 - F_X(a-)$.

Demostración. Si g crece, $\{g(X) \leq y\} = \{X \leq g^{-1}(y)\}$. Si decrece, el evento es $\{X \geq g^{-1}(y)\}$; su probabilidad es $1 - \mathbb{P}(X < g^{-1}(y)) = 1 - F_X(g^{-1}(y)-)$. Cuando no hay átomos, $F_X(a-) = F_X(a)$. $\square$

Ejemplo 3.2 (De uniforme a exponencial). Sea U uniforme en $(0, 1)$, notación que abreviaremos por $U \sim \text{Unif}(0, 1)$, y sea $Y = -\log U$. Antes de derivar se determina el soporte: $Y > 0$. Para $y \geq 0$,

$$\begin{aligned} \{Y \leq y\} &= \{-\log U \leq y\} \\ &= \{\log U \geq -y\} \\ &= \{U \geq e^{-y}\}. \end{aligned}$$

La segunda equivalencia invierte la desigualdad al multiplicar por -1 ; la tercera usa que la exponencial es creciente. Como U no tiene átomos,

$$F_Y(y) = \mathbb{P}(U \geq e^{-y}) = 1 - e^{-y}, \quad y \geq 0,$$

mientras que $F_Y(y) = 0$ para $y < 0$. La función es absolutamente continua y

$$f_Y(y) = e^{-y} \mathbf{1}_{(0, \infty)}(y).$$

Finalmente, $\int_0^\infty e^{-y} dy = 1$; por definición, $Y \sim \text{Exp}(1)$.

Observación (Recordatorio: cambio unidimensional). Si g es de clase C^1 (continuamente diferenciable), estrictamente monótona y $g'(x) \neq 0$, y X tiene densidad f_X , entonces

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

en $g(I)$. Es el teorema de cambio de variables aplicado a $\int_{g^{-1}(B)} f_X(x) dx$; no se memoriza sin especificar soporte e inversa. En efecto, para $B \in \mathcal{B}(g(I))$,

$$\mathbb{P}(Y \in B) = \int_{g^{-1}(B)} f_X(x) dx = \int_B f_X(g^{-1}(y)) |(g^{-1})'(y)| dy.$$

La igualdad para todo boreliano B identifica la función integranda como una densidad de Y . El valor absoluto es necesario porque una densidad no puede cambiar de signo cuando g es decreciente.

3.2. Transformaciones no inyectivas y varias ramas

Cuando g no es inyectiva, el evento $\{g(X) \in B\}$ reúne todas las ramas inversas. Si para casi todo y las soluciones de $g(x) = y$ son $x_1(y), \dots, x_r(y)$ y $g'(x_j(y)) \neq 0$, entonces

$$f_Y(y) = \sum_{j=1}^r \frac{f_X(x_j(y))}{|g'(x_j(y))|}.$$

Ejemplo 3.3 (Cuadrado de una normal). Denotamos por $X \sim N(0, 1)$ una variable con ley normal estándar, cuya densidad y función de distribución son, respectivamente,

$$\phi(x) := \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad \Phi(x) := \int_{-\infty}^x \phi(t) dt.$$

Sea $Y = X^2$. El soporte es $[0, \infty)$. Para $y > 0$, las ramas son $x_1 = \sqrt{y}$ y $x_2 = -\sqrt{y}$, con derivadas inversas de módulo $1/(2\sqrt{y})$. Como ϕ es par,

$$f_Y(y) = \frac{\phi(\sqrt{y}) + \phi(-\sqrt{y})}{2\sqrt{y}} = \frac{e^{-y/2}}{\sqrt{2\pi y}}, \quad y > 0.$$

Por definición, esta distribución se denomina *ji-cuadrado con un grado de libertad* y se denota χ_1^2 . También puede obtenerse primero

$$F_Y(y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) = 2\Phi(\sqrt{y}) - 1$$

y derivar. En efecto,

$$f_Y(y) = 2\phi(\sqrt{y}) \frac{1}{2\sqrt{y}} = \frac{e^{-y/2}}{\sqrt{2\pi y}}, \quad y > 0.$$

La singularidad $y^{-1/2}$ en cero es integrable y

$$\int_0^\infty \frac{e^{-y/2}}{\sqrt{2\pi y}} dy = 2 \int_0^\infty \phi(x) dx = 1,$$

mediante $y = x^2$. Ambas rutas empiezan por el mismo evento y la última igualdad comprueba la normalización.

Ejemplo 3.4 (Valor absoluto y un átomo). Supongamos, con $0 \leq p \leq 1$, que

$$\mu_X = p\delta_0 + f(x)\mathbf{1}_{\mathbb{R} \setminus \{0\}}(x) dx, \quad \int_{\mathbb{R} \setminus \{0\}} f(x) dx = 1 - p.$$

Aquí δ_0 es la medida de Dirac en cero, definida por $\delta_0(B) = \mathbf{1}_B(0)$ para $B \in \mathcal{B}(\mathbb{R})$. Para $Y = |X|$, $\mathbb{P}(Y = 0) = \mathbb{P}(X = 0) = p$. Para $y > 0$ las ramas son y y $-y$, de modo que la parte absolutamente continua tiene densidad $f(y) + f(-y)$. En notación de medidas,

$$\mu_Y = p\delta_0 + [f(y) + f(-y)]\mathbf{1}_{(0, \infty)}(y) dy.$$

La fórmula de ramas no debe borrar el átomo: una densidad respecto de Lebesgue describe solo la parte absolutamente continua.

Observación (Recordatorio: cambio de variables en $\mathbb{R}^d$). Si $T : U \rightarrow V$ es un difeomorfismo de clase C^1 entre abiertos y Z tiene densidad f_Z en U , entonces $W = T(Z)$ tiene

$$f_W(w) = f_Z(T^{-1}(w)) |\det DT^{-1}(w)|, \quad w \in V.$$

En esta fórmula, $DT^{-1}(w)$ es la matriz de derivadas parciales de T^{-1} en w y $\det DT^{-1}(w)$ es su determinante, llamado jacobiano de la transformación inversa. Si hay varias ramas inyectivas, se suman sus contribuciones. Deben identificarse dominio, imagen, ramas y jacobiano antes de integrar.

Por ejemplo, para $T(x, y) = (u, v) = (x + y, x - y)$,

$$x = \frac{u+v}{2}, \quad y = \frac{u-v}{2}, \quad \left| \det \frac{\partial(x, y)}{\partial(u, v)} \right| = \frac{1}{2}.$$

Por tanto, si (X, Y) tiene densidad conjunta $f_{X,Y}$,

$$f_{X+Y, X-Y}(u, v) = \frac{1}{2} f_{X,Y} \left(\frac{u+v}{2}, \frac{u-v}{2} \right)$$

en la imagen del soporte original. La fórmula no determina por sí sola esa imagen; esta debe transformarse junto con las coordenadas.

Error típico. Escribir $f_Y(y) = f_X(g^{-1}(y)) |(g^{-1})'(y)|$ para $g(x) = x^2$ conserva solo una rama y pierde la mitad de la masa.

3.3. Modelos básicos y mecanismos que los producen

Las familias se introducen por el experimento que representan.

- $B \sim \text{Bernoulli}(p)$ registra éxito o fracaso: $\mathbb{P}(B = 1) = p$.
- $S_n = \sum_{i=1}^n B_i$ para Bernoulli independientes tiene ley binomial:

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

La demostración cuenta los subconjuntos de k éxitos y usa independencia para cada patrón.

- $N \sim \text{Pois}(\lambda)$ modela conteos con masa $e^{-\lambda} \lambda^k / k!$. La suma independiente conserva la familia y suma parámetros.
- $T \sim \text{Exp}(\lambda)$ modela un tiempo sin memoria:

$$\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t) = e^{-\lambda t}.$$

- La notación $X \sim N(\mu, \sigma^2)$, con $\sigma > 0$, significa que $X = \mu + \sigma Z$ para alguna $Z \sim N(0, 1)$. Su tratamiento vectorial se reserva para las semanas 10–11.

Proposición 3.5 (Caracterización de la falta de memoria). *Si $T \geq 0$, $\mathbb{P}(T > t) > 0$ y su supervivencia $G(t) = \mathbb{P}(T > t)$ es continua, entonces*

$$\mathbb{P}(T > s+t \mid T > s) = \mathbb{P}(T > t)$$

para $s, t \geq 0$ si y solo si $G(t) = e^{-\lambda t}$ para algún $\lambda \geq 0$. Si además T es finita c.s., necesariamente $\lambda > 0$.

Demostración. Como $\{T > s+t\} \subseteq \{T > s\}$ y $G(s) > 0$,

$$\mathbb{P}(T > s+t \mid T > s) = \frac{\mathbb{P}(T > s+t)}{\mathbb{P}(T > s)} = \frac{G(s+t)}{G(s)}.$$

Por ello, la propiedad equivale a $G(s+t) = G(s)G(t)$. Como G es continua, positiva, no creciente y $G(0) = 1$, $h(t) = -\log G(t)$ es continua, aditiva y no decreciente en $[0, \infty)$. La ecuación de Cauchy continua da $h(t) = \lambda t$, con $\lambda \geq 0$, y por tanto $G(t) = e^{-\lambda t}$. El recíproco se comprueba sustituyendo esta expresión en el cociente anterior. Si $T < \infty$ c.s., $G(t) \downarrow 0$ cuando $t \rightarrow \infty$; esto excluye $\lambda = 0$, caso que formalmente correspondería a un tiempo infinito. $\square$

Ejemplo 3.6 (Mínimo de tiempos exponenciales). Si $T_1, \dots, T_n$ son exponenciales independientes de tasas λ_i y $M = \min_i T_i$, entonces

$$\{M > t\} = \bigcap_i \{T_i > t\}, \quad \mathbb{P}(M > t) = \prod_i e^{-\lambda_i t} = e^{-t \sum_i \lambda_i}.$$

Así $M \sim \text{Exp}(\sum_i \lambda_i)$. La identidad entre eventos precede al producto. La segunda igualdad usa independencia. No debe confundirse el mínimo con la suma: una suma de exponenciales no es, en general, exponencial.

Las leyes gamma, beta, geométrica y multinomial aparecen en la lista autónoma como extensiones de estos mecanismos.

3.4. Transformación integral de probabilidad y cuantiles

Sea F una función de distribución y

$$Q(u) = \inf\{x : F(x) \geq u\}, \quad 0 < u < 1.$$

La semana 1 probó la equivalencia $Q(u) \leq x \iff u \leq F(x)$.

Recordemos por qué. Si $u \leq F(x)$, entonces x pertenece al conjunto cuyo ínfimo define $Q(u)$, de modo que $Q(u) \leq x$. Recíprocamente, si $Q(u) \leq x$, la monotonía y continuidad por la derecha de F permiten aproximar $Q(u)$ por puntos $x_k \downarrow Q(u)$ con $F(x_k) \geq u$; de aquí $F(x) \geq u$. Esta equivalencia incluye distribuciones con saltos.

Teorema 3.7 (Método de la inversa). *Si $U \sim \text{Unif}(0, 1)$, entonces $Q(U)$ tiene función de distribución F .*

Demostración. Para cada x ,

$$\mathbb{P}(Q(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

La inversa generalizada funciona aunque F tenga saltos o intervalos planos. $\square$

Proposición 3.8 (Transformación integral). *Si X tiene función de distribución continua F_X , entonces $F_X(X)$ es uniforme en $(0, 1)$ cuando F_X es estrictamente creciente en el soporte. En general, la afirmación requiere una aleatorización dentro de los saltos.*

Demostración. En el caso estrictamente creciente, para $0 < u < 1$,

$$\{F_X(X) \leq u\} = \{X \leq F_X^{-1}(u)\},$$

y su probabilidad es u . Si hay saltos, $F_X(X)$ concentra masa y no puede ser uniforme; esta observación explica la hipótesis. $\square$

Ejemplo 3.9 (Simulación conceptual). Para generar una exponencial de tasa λ a partir de U uniforme, resolvemos

$$u = 1 - e^{-\lambda x} \implies x = -\frac{1}{\lambda} \log(1 - u).$$

Como $1 - U$ también es uniforme, suele usarse $X = -\lambda^{-1} \log U$. Esto es una construcción probabilística, no solo una receta computacional.

Cierre de la sesión. Para transformar una variable: definir Y , hallar su soporte, traducir $\{Y \leq y\}$ o $\{Y \in B\}$ a un evento de X , y solo después derivar o usar jacobianos.

Sesión 2. Vectores, covarianza y muestras independientes

Objetivo de la sesión. Organizar momentos multivariados y demostrar las identidades de media y varianza muestral.

3.5. Vectores aleatorios y leyes conjuntas

Un vector columna $X = (X_1, \dots, X_d)^T$ es medible de $(\Omega, \mathcal{F})$ a $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ si y solo si cada coordenada es medible. El superíndice T indica transposición. Su ley conjunta determina las marginales, pero no a la inversa.

La función de distribución conjunta es

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d).$$

En dimensión dos, para un par (X, Y) abreviamos $F_{X,Y}$ por F . Las probabilidades de rectángulos se obtienen por incrementos:

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F(b, d) - F(a, d) \\ &\quad - F(b, c) + F(a, c). \end{aligned}$$

La cuenta procede de la identidad de indicadores

$$\mathbf{1}_{(a,b] \times (c,d]}(X, Y) = [\mathbf{1}_{\{X \leq b\}} - \mathbf{1}_{\{X \leq a\}}][\mathbf{1}_{\{Y \leq d\}} - \mathbf{1}_{\{Y \leq c\}}].$$

Al expandir y tomar esperanzas aparecen exactamente los cuatro términos anteriores. La fórmula ya incorpora posibles átomos en a y c , porque esos extremos están excluidos. Para rectángulos con extremos incluidos deben emplearse los límites izquierdos correspondientes, por ejemplo $F(a-, y) = \lim_{x \uparrow a} F(x, y)$.

Observación (Recordatorio: Tonelli para marginalizar). Si (X, Y) tiene densidad conjunta $f_{X,Y} \geq 0$, entonces

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx.$$

Tonelli justifica las integrales iteradas por no negatividad. Antes de calcular se determina el soporte de la conjunta; integrar sobre un rectángulo incorrecto cambia la marginal.

Ejemplo 3.10 (Densidad en un triángulo). Sea (X, Y) un vector cuya densidad conjunta está dada por

$$f_{X,Y}(x, y) := 2\mathbf{1}_{\{0 < x < y < 1\}}.$$

Antes de marginalizar se comprueba, por Tonelli, que

$$\int_0^1 \int_0^y 2 dx dy = \int_0^1 2y dy = 1.$$

Así la función es efectivamente una densidad. Para $0 < x < 1$, el soporte exige $x < y < 1$, luego

$$f_X(x) = \int_x^1 2 dy = 2(1 - x).$$

Para $0 < y < 1$, x recorre $(0, y)$ y $f_Y(y) = 2y$. Las marginales son distintas aunque la densidad conjunta sea constante sobre su soporte. Además, X e Y no son independientes: $f_X(x)f_Y(y)$ es positivo en puntos del cuadrado $(0, 1)^2$ donde $f_{X,Y}(x, y) = 0$, por ejemplo cuando $y < x$.

3.6. Media vectorial y matriz de covarianza

Si cada coordenada es integrable, $m = \mathbb{E}X = (\mathbb{E}X_1, \dots, \mathbb{E}X_d)^T$. Si están en L^2 , se define

$$\Sigma = \text{Cov}(X) = \mathbb{E}[(X - m)(X - m)^T], \quad \Sigma_{ij} = \text{Cov}(X_i, X_j).$$

Proposición 3.11. Σ es simétrica y semidefinida positiva. Para toda matriz A y vector b ,

$$\mathbb{E}(AX + b) = Am + b, \quad \text{Cov}(AX + b) = A\Sigma A^T.$$

Demostración. La simetría es inmediata. Para $a \in \mathbb{R}^d$,

$$a^T \Sigma a = \mathbb{E}[a^T (X - m)(X - m)^T a] = \mathbb{E}[(a^T (X - m))^2] = \text{Var}(a^T X) \geq 0.$$

La transformación de la media usa linealidad; para la covarianza se sustituye $AX + b - (Am + b) = A(X - m)$ y se extraen las matrices constantes. $\square$

Corolario 3.12. Σ es singular si y solo si existe $a \neq 0$ tal que $a^T X$ es constante c.s.

Demostración. Si Σ es singular y semidefinida positiva, existe $a \neq 0$ con $a^T \Sigma a = 0$. La identidad anterior da $\text{Var}(a^T X) = 0$, equivalente a $a^T X = \mathbb{E}(a^T X)$ c.s. El recíproco sigue en reversa. $\square$

Ejemplo 3.13. Escribamos

$$\Sigma = \begin{pmatrix} \sigma_X^2 & c \\ c & \sigma_Y^2 \end{pmatrix}, \quad c = \text{Cov}(X, Y).$$

Aquí $\sigma_X^2 := \text{Var}(X)$ y $\sigma_Y^2 := \text{Var}(Y)$. Para $Z = (X + Y, X - Y)^T = AX$, con $A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$, la multiplicación $A\Sigma A^T$ da

$$\text{Cov}(Z) = \begin{pmatrix} \sigma_X^2 + \sigma_Y^2 + 2c & \sigma_X^2 - \sigma_Y^2 \\ \sigma_X^2 - \sigma_Y^2 & \sigma_X^2 + \sigma_Y^2 - 2c \end{pmatrix}.$$

En particular,

$$\text{Cov}(X + Y, X - Y) = \text{Var } X - \text{Var } Y.$$

La covarianza puede anularse sin que las dos combinaciones sean independientes, salvo bajo hipótesis adicionales como gaussianidad conjunta.

3.7. Muestras i.i.d. y media muestral

Una muestra aleatoria $X_1, \dots, X_n$ significa que las variables son independientes y tienen la misma ley. Abreviaremos esta condición diciendo que son *i.i.d.*, por “independientes e idénticamente distribuidas”. No significa que los valores observados sean distintos ni que se conozcan los parámetros de la ley común.

Si $\mathbb{E}X_1 = \mu$ y $\text{Var}(X_1) = \sigma^2 < \infty$, la media

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

satisface

$$\mathbb{E}\bar{X}_n = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

Para la varianza,

$$\begin{aligned} \text{Var}(\bar{X}_n) &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j) \right] \\ &= \frac{\sigma^2}{n}. \end{aligned}$$

La última igualdad usa que independencia y segundo momento finito implican $\text{Cov}(X_i, X_j) = 0$ para $i \neq j$.

Ejemplo 3.14 (Muestra Bernoulli). Si X_i indica éxito con probabilidad p , entonces $X_i^2 = X_i$ y

$$\text{Var}(X_i) = \mathbb{E}X_i^2 - (\mathbb{E}X_i)^2 = p - p^2 = p(1 - p).$$

Así $\bar{X}_n$ es la proporción de éxitos, con media p y varianza $p(1 - p)/n$. Para $\varepsilon > 0$, Chebyshev da

$$\mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{p(1 - p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}.$$

La última cota es uniforme en p porque $p(1 - p) \leq 1/4$.

Proposición 3.15 (Covarianzas con la media). *Para una muestra i.i.d. con segundo momento,*

$$\text{Cov}(X_i, \bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{Cov}(X_i - \bar{X}_n, \bar{X}_n) = 0.$$

Demostración. Por bilinealidad,

$$\text{Cov}(X_i, \bar{X}_n) = \frac{1}{n} \sum_j \text{Cov}(X_i, X_j) = \frac{\sigma^2}{n},$$

porque los términos con $j \neq i$ se anulan. Restar $\text{Var}(\bar{X}_n) = \sigma^2/n$ prueba la segunda identidad. $\square$

La incorrelación entre residuos y media no implica todavía independencia. En una muestra normal sí la implicará, pero esa demostración requiere la estructura gaussiana de las semanas 10–11.

3.8. Varianza muestral y descomposición de cuadrados

Definimos

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad n \geq 2.$$

El denominador $n-1$ se deduce de una identidad, no es una convención arbitraria.

Teorema 3.16 (Descomposición de suma de cuadrados). *Para cualquier constante a ,*

$$\sum_{i=1}^n (X_i - a)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - a)^2.$$

Demostración. Escribimos $X_i - a = (X_i - \bar{X}_n) + (\bar{X}_n - a)$. Al elevar al cuadrado y sumar,

$$\begin{aligned} \sum_{i=1}^n (X_i - a)^2 &= \sum_{i=1}^n (X_i - \bar{X}_n)^2 \\ &\quad + 2(\bar{X}_n - a) \sum_{i=1}^n (X_i - \bar{X}_n) + n(\bar{X}_n - a)^2. \end{aligned}$$

El término cruzado desaparece porque

$$\sum_{i=1}^n (X_i - \bar{X}_n) = \sum_{i=1}^n X_i - n\bar{X}_n = 0.$$

□

Corolario 3.17 (Insensibilidad). *Si la muestra es i.i.d. con varianza $\sigma^2 < \infty$, entonces $\mathbb{E}S_n^2 = \sigma^2$.*

Demostración. Tomamos $a = \mu$ y esperanzas. Como las variables tienen la misma varianza,

$$\mathbb{E} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \mathbb{E}(X_i - \mu)^2 = n\sigma^2.$$

Además, $\mathbb{E}\bar{X}_n = \mu$ y

$$\mathbb{E}[n(\bar{X}_n - \mu)^2] = n \text{Var}(\bar{X}_n) = \sigma^2.$$

Al restar en la identidad anterior,

$$\mathbb{E} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = (n-1)\sigma^2,$$

y dividir por $n-1$ concluye que $\mathbb{E}S_n^2 = \sigma^2$. □

Observación. La prueba solo exige independencia, igualdad de leyes y segundo momento. Si se empleara el divisor n , la esperanza del estimador sería $\frac{n-1}{n}\sigma^2$. La distribución de S_n^2 y su independencia respecto de $\bar{X}_n$ requieren normalidad y se estudiarán en la semana 11.

Cierre. Las transformaciones se resuelven por preimágenes; los jacobianos son una herramienta derivada. En vectores, la covarianza se organiza como una matriz semidefinida positiva. En muestras i.i.d., las identidades de media y varianza preparan las leyes de los grandes números y el TCL.

Lecturas

Saporta, capítulos 2–4; Durrett, §1.3; Sheffield, clases 2–3. Las familias no desarrolladas en teoría quedan como ejercicios de transformación y reconocimiento de mecanismos.