



Notas · Semana 3

Teoría de la Probabilidad · CM4H1

Transformaciones, familias, vectores y muestras

Oswaldo Velásquez Castañón

Profesor Principal · Escuela Profesional de Matemática

Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 3

Transformar variables y organizar información multivariada

Propósito. La sesión 1 obtiene leyes por preimágenes y por cambio de variables, y presenta distribuciones básicas como modelos generadores. La sesión 2 desarrolla vectores aleatorios, matrices de covarianza y las identidades fundamentales de una muestra i.i.d. Las distribuciones complementarias se practican en ejercicios; no se convierten en un catálogo de fórmulas.

Recordatorios de medida. Medida imagen, integración respecto de una ley, función inversa generalizada, cambio de variables en integrales de Lebesgue, Tonelli–Fubini y Cauchy–Schwarz. Se enuncian en el punto exacto donde se emplean.

Sesión 1. Transformaciones y modelos fundamentales

Objetivo de la sesión. Obtener la ley de $Y = g(X)$ desde sus preimágenes y reconocer mecanismos que producen familias probabilísticas.

3.1. La ley transformada se obtiene por preimágenes

Sea $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ una variable y $g : \mathbb{R} \rightarrow \mathbb{R}$ boreliana. Definimos $Y = g(X)$. Para cada boreliano B ,

$$\mu_Y(B) = \mathbb{P}(Y \in B) = \mathbb{P}(X \in g^{-1}(B)) = \mu_X(g^{-1}(B)).$$

Esta identidad es el punto de partida; una fórmula con derivadas solo es una consecuencia cuando g posee regularidad suficiente.

Definición 3.1 (Soporte de una ley real). Sea $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow \mathbb{R}$ una variable aleatoria. Primero se construye su ley, es decir, la medida de probabilidad

$$\mu_X(B) := \mathbb{P}(X \in B) = \mathbb{P}(X^{-1}(B)), \quad B \in \mathcal{B}(\mathbb{R}).$$

Respecto de la topología usual de $\mathbb{R}$, el *soporte de la ley* μ_X se define por

$$\text{supp}(\mu_X) := \{x \in \mathbb{R} : \mu_X(U) > 0 \text{ para todo abierto } U \text{ que contiene a } x\}.$$

Equivalentemente,

$$\mathbb{R} \setminus \text{supp}(\mu_X) = \bigcup \{U \subseteq \mathbb{R} : U \text{ es abierto y } \mu_X(U) = 0\}.$$

Esta unión también tiene medida nula: como $\mathbb{R}$ posee una base numerable, puede reducirse a una unión numerable de elementos de la base que tienen medida cero.

Cuando se dice informalmente “soporte de X ”, se entiende siempre el soporte de su ley. No es el dominio Ω ni la imagen puntual $X(\Omega)$; esta última puede cambiar al modificar X en un conjunto nulo, mientras que μ_X no cambia.

Si μ_X admite una densidad f_X , entonces

$$x \in \text{supp}(\mu_X) \iff \int_U f_X(t) dt > 0 \text{ para todo abierto } U \ni x.$$

Esta caracterización no depende de la versión de la densidad. Solo bajo una hipótesis adicional, por ejemplo si se dispone de una versión continua de f_X , puede escribirse

$$\text{supp}(\mu_X) = \overline{\{x \in \mathbb{R} : f_X(x) > 0\}}.$$

Definición 3.2 (Átomo de una ley real). Un punto $a \in \mathbb{R}$ es un *átomo* de la ley de X si

$$\mu_X(\{a\}) = \mathbb{P}(X = a) > 0.$$

Diremos que X , o su ley, *no tiene átomos* si $\mathbb{P}(X = a) = 0$ para todo $a \in \mathbb{R}$. Como

$$\mathbb{P}(X = a) = F_X(a) - F_X(a-),$$

los átomos son exactamente los puntos de salto de F_X . Aquí $F_X(a-) := \lim_{x \uparrow a} F_X(x)$.

Proposición 3.3 (Transformación monótona). Supongamos que g es estrictamente creciente y continua en un intervalo I que contiene a X c.s. Entonces, para $y \in g(I)$,

$$F_Y(y) = F_X(g^{-1}(y)).$$

Si g es estrictamente decreciente y X no tiene átomos,

$$F_Y(y) = 1 - F_X(g^{-1}(y)).$$

En presencia de átomos debe conservarse el extremo correcto: $\mathbb{P}(X \geq a) = 1 - F_X(a-)$.

Demostración. Si g crece, $\{g(X) \leq y\} = \{X \leq g^{-1}(y)\}$. Si decrece, el evento es $\{X \geq g^{-1}(y)\}$; su probabilidad es $1 - \mathbb{P}(X < g^{-1}(y)) = 1 - F_X(g^{-1}(y)-)$. Cuando no hay átomos, $F_X(a-) = F_X(a)$. $\square$

Definición 3.4 (Distribución uniforme). Sean $a < b$. Se dice que U tiene distribución uniforme en (a, b) , y se escribe $U \sim \text{Unif}(a, b)$, si tiene densidad

$$f_U(u) = \frac{1}{b-a} \mathbf{1}_{(a,b)}(u).$$

Su función de distribución es

$$F_U(u) = \begin{cases} 0, & u \leq a, \\ \frac{u-a}{b-a}, & a < u < b, \\ 1, & u \geq b. \end{cases}$$

La elección de extremos abiertos o cerrados no altera la ley, porque una distribución con densidad no asigna masa a puntos.

Definición 3.5 (Distribución exponencial). Para $\lambda > 0$, se dice que T tiene distribución exponencial de tasa λ , y se escribe $T \sim \text{Exp}(\lambda)$, si

$$f_T(t) = \lambda e^{-\lambda t} \mathbf{1}_{(0,\infty)}(t).$$

Equivalentemente, para $t \geq 0$,

$$F_T(t) = 1 - e^{-\lambda t}, \quad \mathbb{P}(T > t) = e^{-\lambda t}.$$

El parámetro es una tasa; su esperanza, cuando se calcule, será $1/\lambda$.

Ejemplo 3.6 (De uniforme a exponencial). Sea $U \sim \text{Unif}(0, 1)$ y sea $Y = -\log U$. Antes de derivar se observa que $Y > 0$ casi seguramente y se construye su ley. Para $y \geq 0$,

$$\begin{aligned} \{Y \leq y\} &= \{-\log U \leq y\} \\ &= \{\log U \geq -y\} \\ &= \{U \geq e^{-y}\}. \end{aligned}$$

La segunda equivalencia invierte la desigualdad al multiplicar por -1 ; la tercera usa que la exponencial es creciente. Como U no tiene átomos,

$$F_Y(y) = \mathbb{P}(U \geq e^{-y}) = 1 - e^{-y}, \quad y \geq 0,$$

mientras que $F_Y(y) = 0$ para $y < 0$. La función es absolutamente continua y

$$f_Y(y) = e^{-y} \mathbf{1}_{(0,\infty)}(y).$$

Finalmente, $\int_0^\infty e^{-y} dy = 1$; por definición, $Y \sim \text{Exp}(1)$. Aunque $Y > 0$ casi seguramente, el soporte de su ley es $[0, \infty)$: cada entorno abierto de 0 contiene puntos positivos en los que la densidad tiene integral estrictamente positiva.

Observación (Recordatorio: cambio unidimensional). Si g es de clase C^1 (continuamente diferenciable), estrictamente monótona y $g'(x) \neq 0$, y X tiene densidad f_X , entonces

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

en $g(I)$. Es el teorema de cambio de variables aplicado a $\int_{g^{-1}(B)} f_X(x) dx$; no se memoriza sin especificar soporte e inversa. En efecto, para $B \in \mathcal{B}(g(I))$,

$$\mathbb{P}(Y \in B) = \int_{g^{-1}(B)} f_X(x) dx = \int_B f_X(g^{-1}(y)) |(g^{-1})'(y)| dy.$$

La igualdad para todo boreliano B identifica la función integranda como una densidad de Y . El valor absoluto es necesario porque una densidad no puede cambiar de signo cuando g es decreciente.

3.2. Transformaciones no inyectivas y varias ramas

Cuando g no es inyectiva, el evento $\{g(X) \in B\}$ reúne todas las ramas inversas. Si para casi todo y las soluciones de $g(x) = y$ son $x_1(y), \dots, x_r(y)$ y $g'(x_j(y)) \neq 0$, entonces

$$f_Y(y) = \sum_{j=1}^r \frac{f_X(x_j(y))}{|g'(x_j(y))|}.$$

Ejemplo 3.7 (Cuadrado de una normal). Denotamos por $X \sim N(0, 1)$ una variable con ley normal estándar, cuya densidad y función de distribución son, respectivamente,

$$\phi(x) := \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad \Phi(x) := \int_{-\infty}^x \phi(t) dt.$$

Sea $Y = X^2$. El soporte de su ley es $[0, \infty)$. Para $y > 0$, las ramas son $x_1 = \sqrt{y}$ y $x_2 = -\sqrt{y}$, con derivadas inversas de módulo $1/(2\sqrt{y})$. Como ϕ es par,

$$f_Y(y) = \frac{\phi(\sqrt{y}) + \phi(-\sqrt{y})}{2\sqrt{y}} = \frac{e^{-y/2}}{\sqrt{2\pi y}}, \quad y > 0.$$

Por definición, esta distribución se denomina *ji-cuadrado con un grado de libertad* y se denota χ_1^2 . También puede obtenerse primero

$$F_Y(y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) = 2\Phi(\sqrt{y}) - 1$$

y derivar. En efecto,

$$f_Y(y) = 2\phi(\sqrt{y}) \frac{1}{2\sqrt{y}} = \frac{e^{-y/2}}{\sqrt{2\pi y}}, \quad y > 0.$$

La singularidad $y^{-1/2}$ en cero es integrable y

$$\int_0^\infty \frac{e^{-y/2}}{\sqrt{2\pi y}} dy = 2 \int_0^\infty \phi(x) dx = 1,$$

mediante $y = x^2$. Ambas rutas empiezan por el mismo evento y la última igualdad comprueba la normalización.

Ejemplo 3.8 (Valor absoluto y un átomo). Supongamos, con $0 \leq p \leq 1$, que

$$\mu_X = p\delta_0 + f(x)\mathbf{1}_{\mathbb{R} \setminus \{0\}}(x) dx, \quad \int_{\mathbb{R} \setminus \{0\}} f(x) dx = 1 - p.$$

Aquí δ_0 es la medida de Dirac en cero, definida por $\delta_0(B) = \mathbf{1}_B(0)$ para $B \in \mathcal{B}(\mathbb{R})$. Para $Y = |X|$, $\mathbb{P}(Y = 0) = \mathbb{P}(X = 0) = p$. Para $y > 0$ las ramas son y y $-y$, de modo que la parte absolutamente continua tiene densidad $f(y) + f(-y)$. En notación de medidas,

$$\mu_Y = p\delta_0 + [f(y) + f(-y)]\mathbf{1}_{(0, \infty)}(y) dy.$$

La fórmula de ramas no debe borrar el átomo: una densidad respecto de Lebesgue describe solo la parte absolutamente continua.

Observación (Recordatorio: cambio de variables en $\mathbb{R}^d$). Si $T : U \rightarrow V$ es un difeomorfismo de clase C^1 entre abiertos y Z tiene densidad f_Z en U , entonces $W = T(Z)$ tiene

$$f_W(w) = f_Z(T^{-1}(w)) |\det DT^{-1}(w)|, \quad w \in V.$$

En esta fórmula, $DT^{-1}(w)$ es la matriz de derivadas parciales de T^{-1} en w y $\det DT^{-1}(w)$ es su determinante, llamado jacobiano de la transformación inversa. Si hay varias ramas inyectivas, se suman sus contribuciones. Deben identificarse dominio, imagen, ramas y jacobiano antes de integrar.

Por ejemplo, para $T(x, y) = (u, v) = (x + y, x - y)$,

$$x = \frac{u+v}{2}, \quad y = \frac{u-v}{2}, \quad \left| \det \frac{\partial(x, y)}{\partial(u, v)} \right| = \frac{1}{2}.$$

Por tanto, si (X, Y) tiene densidad conjunta $f_{X,Y}$,

$$f_{X+Y, X-Y}(u, v) = \frac{1}{2} f_{X,Y} \left(\frac{u+v}{2}, \frac{u-v}{2} \right)$$

en la imagen del soporte original. La fórmula no determina por sí sola esa imagen; esta debe transformarse junto con las coordenadas.

Error típico. Escribir $f_Y(y) = f_X(g^{-1}(y))|(g^{-1})'(y)|$ para $g(x) = x^2$ conserva solo una rama y pierde la mitad de la masa.

3.3. Modelos básicos y mecanismos que los producen

Las familias se introducen por el experimento que representan. En todas las definiciones, la igualdad de una masa o densidad se entiende en el soporte indicado y vale cero fuera de él.

Definición 3.9 (Distribución de Bernoulli). Para $0 \leq p \leq 1$, se dice que B tiene distribución de Bernoulli de parámetro p , y se escribe $B \sim \text{Bernoulli}(p)$, si

$$\mathbb{P}(B = 1) = p, \quad \mathbb{P}(B = 0) = 1 - p.$$

La variable B es el indicador de un suceso que se denomina éxito.

Definición 3.10 (Distribución binomial). Sean $n \geq 1$ entero, $0 \leq p \leq 1$ y $B_1, \dots, B_n$ variables independientes con ley Bernoulli(p). La suma

$$S_n := \sum_{i=1}^n B_i$$

tiene distribución binomial de parámetros n y p , notación $S_n \sim \text{Bin}(n, p)$, y

$$\mathbb{P}(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

La fórmula cuenta los subconjuntos de k éxitos y usa independencia para calcular la probabilidad de cada patrón.

Definición 3.11 (Distribución de Poisson). Para $\lambda > 0$, se dice que N tiene distribución de Poisson de parámetro λ , y se escribe $N \sim \text{Pois}(\lambda)$, si toma valores $k = 0, 1, 2, \dots$ con

$$\mathbb{P}(N = k) = e^{-\lambda} \frac{\lambda^k}{k!}.$$

Esta ley modela conteos. Más adelante se demostrará que la suma de variables de Poisson independientes vuelve a ser de Poisson y que sus parámetros se suman.

Definición 3.12 (Distribución normal). Para $\mu \in \mathbb{R}$ y $\sigma > 0$, se dice que X tiene distribución normal de media μ y varianza σ^2 , y se escribe $X \sim N(\mu, \sigma^2)$, si tiene densidad

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \quad x \in \mathbb{R}.$$

Equivalentemente, X tiene la misma ley que $\mu + \sigma Z$ para $Z \sim N(0, 1)$. Su tratamiento vectorial se reserva para las semanas 10–11.

La distribución exponencial ya definida modela tiempos de espera. Su propiedad distintiva es la falta de memoria, que ahora caracterizamos.

Proposición 3.13 (Caracterización de la falta de memoria). Si $T \geq 0$, $\mathbb{P}(T > t) > 0$ y su supervivencia $G(t) = \mathbb{P}(T > t)$ es continua, entonces

$$\mathbb{P}(T > s + t \mid T > s) = \mathbb{P}(T > t)$$

para $s, t \geq 0$ si y solo si $G(t) = e^{-\lambda t}$ para algún $\lambda \geq 0$. Si además T es finita c.s., necesariamente $\lambda > 0$.

Demostración. Como $\{T > s + t\} \subseteq \{T > s\}$ y $G(s) > 0$,

$$\mathbb{P}(T > s + t \mid T > s) = \frac{\mathbb{P}(T > s + t)}{\mathbb{P}(T > s)} = \frac{G(s + t)}{G(s)}.$$

Por ello, la propiedad equivale a $G(s + t) = G(s)G(t)$. Como G es continua, positiva, no creciente y $G(0) = 1$, $h(t) = -\log G(t)$ es continua, aditiva y no decreciente en $[0, \infty)$. La ecuación de Cauchy continua da $h(t) = \lambda t$, con $\lambda \geq 0$, y por tanto $G(t) = e^{-\lambda t}$. El recíproco se comprueba sustituyendo esta expresión en el cociente anterior. Si $T < \infty$ c.s., $G(t) \downarrow 0$ cuando $t \rightarrow \infty$; esto excluye $\lambda = 0$, caso que formalmente correspondería a un tiempo infinito. $\square$

Ejemplo 3.14 (Mínimo de tiempos exponenciales). Si $T_1, \dots, T_n$ son exponenciales independientes de tasas λ_i y $M = \min_i T_i$, entonces

$$\{M > t\} = \bigcap_i \{T_i > t\}, \quad \mathbb{P}(M > t) = \prod_i e^{-\lambda_i t} = e^{-t \sum_i \lambda_i}.$$

Así $M \sim \text{Exp}(\sum_i \lambda_i)$. La identidad entre eventos precede al producto. La segunda igualdad usa independencia. No debe confundirse el mínimo con la suma: una suma de exponenciales no es, en general, exponencial.

Observación (Familias para los ejercicios). Las siguientes leyes se emplearán en la lista autónoma, sin desarrollar todavía su teoría.

- Para $0 < p \leq 1$, $G \sim \text{Geom}(p)$ significa, con la convención adoptada en estas notas, que $G \in \{1, 2, \dots\}$ y

$$\mathbb{P}(G = k) = (1 - p)^{k-1} p, \quad k \geq 1.$$

Así G cuenta el número de ensayos hasta el primer éxito.

- Para $\alpha, \lambda > 0$, $X \sim \text{Gamma}(\alpha, \lambda)$ significa que α es la forma, λ la tasa y

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x), \quad \Gamma(\alpha) := \int_0^\infty t^{\alpha-1} e^{-t} dt.$$

- Para $\alpha, \beta > 0$, $X \sim \text{Beta}(\alpha, \beta)$ significa que

$$f_X(x) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)} \mathbf{1}_{(0,1)}(x), \quad B(\alpha, \beta) := \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt.$$

- Sean $m \geq 2$, $p_j \geq 0$ y $\sum_{j=1}^m p_j = 1$. El vector de conteos $K = (K_1, \dots, K_m)$ tiene distribución multinomial de parámetros n y $(p_1, \dots, p_m)$, notación $K \sim \text{Multinomial}(n; p_1, \dots, p_m)$, si, para enteros $k_j \geq 0$ con $\sum_j k_j = n$,

$$\mathbb{P}(K_1 = k_1, \dots, K_m = k_m) = \frac{n!}{k_1! \dots k_m!} \prod_{j=1}^m p_j^{k_j}.$$

Esta ley registra las frecuencias de m categorías en n ensayos independientes.

3.4. Transformación integral de probabilidad y cuantiles

Sea F una función de distribución y

$$Q(u) = \inf\{x : F(x) \geq u\}, \quad 0 < u < 1.$$

La semana 1 probó la equivalencia $Q(u) \leq x \iff u \leq F(x)$.

Recordemos por qué. Si $u \leq F(x)$, entonces x pertenece al conjunto cuyo ínfimo define $Q(u)$, de modo que $Q(u) \leq x$. Recíprocamente, si $Q(u) \leq x$, la monotonía y continuidad por la derecha de F permiten aproximar $Q(u)$ por puntos $x_k \downarrow Q(u)$ con $F(x_k) \geq u$; de aquí $F(x) \geq u$. Esta equivalencia incluye distribuciones con saltos.

Teorema 3.15 (Método de la inversa). *Si $U \sim \text{Unif}(0, 1)$, entonces $Q(U)$ tiene función de distribución F .*

Demostración. Para cada x ,

$$\mathbb{P}(Q(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

La inversa generalizada funciona aunque F tenga saltos o intervalos planos. $\square$

Proposición 3.16 (Transformación integral). *Si X tiene función de distribución continua F_X , entonces $F_X(X)$ es uniforme en $(0, 1)$ cuando F_X es estrictamente creciente en el soporte. En general, la afirmación requiere una aleatorización dentro de los saltos.*

Demostración. En el caso estrictamente creciente, para $0 < u < 1$,

$$\{F_X(X) \leq u\} = \{X \leq F_X^{-1}(u)\},$$

y su probabilidad es u . Si hay saltos, $F_X(X)$ concentra masa y no puede ser uniforme; esta observación explica la hipótesis. $\square$

Ejemplo 3.17 (Simulación conceptual). Para generar una exponencial de tasa λ a partir de U uniforme, resolvemos

$$u = 1 - e^{-\lambda x} \implies x = -\frac{1}{\lambda} \log(1 - u).$$

Como $1 - U$ también es uniforme, suele usarse $X = -\lambda^{-1} \log U$. Esto es una construcción probabilística, no solo una receta computacional.

Cierre de la sesión. Para transformar una variable: definir Y , construir su ley, hallar el soporte de esa ley, traducir $\{Y \leq y\}$ o $\{Y \in B\}$ a un evento de X , y solo después derivar o usar jacobianos.

Sesión 2. Vectores, covarianza y muestras independientes

Objetivo de la sesión. Organizar momentos multivariados y demostrar las identidades de media y varianza muestral.

3.5. Vectores aleatorios y leyes conjuntas

Un vector columna $X = (X_1, \dots, X_d)^T$ es medible de $(\Omega, \mathcal{F})$ a $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ si y solo si cada coordenada es medible. El superíndice T indica transposición. Su ley conjunta determina las marginales, pero no a la inversa.

La función de distribución conjunta es

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d).$$

En dimensión dos, para un par (X, Y) abreviamos $F_{X,Y}$ por F . Las probabilidades de rectángulos se obtienen por incrementos:

$$\begin{aligned} \mathbb{P}(a < X \leq b, c < Y \leq d) &= F(b, d) - F(a, d) \\ &\quad - F(b, c) + F(a, c). \end{aligned}$$

La cuenta procede de la identidad de indicadores

$$\mathbf{1}_{(a,b] \times (c,d]}(X, Y) = [\mathbf{1}_{\{X \leq b\}} - \mathbf{1}_{\{X \leq a\}}][\mathbf{1}_{\{Y \leq d\}} - \mathbf{1}_{\{Y \leq c\}}].$$

Al expandir y tomar esperanzas aparecen exactamente los cuatro términos anteriores. La fórmula ya incorpora posibles átomos en a y c , porque esos extremos están excluidos. Para rectángulos con extremos incluidos deben emplearse los límites izquierdos correspondientes, por ejemplo $F(a-, y) = \lim_{x \uparrow a} F(x, y)$.

Observación (Recordatorio: Tonelli para marginalizar). Si (X, Y) tiene densidad conjunta $f_{X,Y} \geq 0$, entonces

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx.$$

Tonelli justifica las integrales iteradas por no negatividad. Antes de calcular se determina el soporte de la conjunta; integrar sobre un rectángulo incorrecto cambia la marginal.

Ejemplo 3.18 (Densidad en un triángulo). Sea (X, Y) un vector cuya densidad conjunta está dada por

$$f_{X,Y}(x, y) := 2\mathbf{1}_{\{0 < x < y < 1\}}.$$

Antes de marginalizar se comprueba, por Tonelli, que

$$\int_0^1 \int_0^y 2 dx dy = \int_0^1 2y dy = 1.$$

Así la función es efectivamente una densidad. Para $0 < x < 1$, el soporte exige $x < y < 1$, luego

$$f_X(x) = \int_x^1 2 dy = 2(1 - x).$$

Para $0 < y < 1$, x recorre $(0, y)$ y $f_Y(y) = 2y$. Las marginales son distintas aunque la densidad conjunta sea constante sobre su soporte. Además, X e Y no son independientes: $f_X(x)f_Y(y)$ es positivo en puntos del cuadrado $(0, 1)^2$ donde $f_{X,Y}(x, y) = 0$, por ejemplo cuando $y < x$.

3.6. Media vectorial y matriz de covarianza

Si cada coordenada es integrable, $m = \mathbb{E}X = (\mathbb{E}X_1, \dots, \mathbb{E}X_d)^T$. Si están en L^2 , se define

$$\Sigma = \text{Cov}(X) = \mathbb{E}[(X - m)(X - m)^T], \quad \Sigma_{ij} = \text{Cov}(X_i, X_j).$$

Proposición 3.19. Σ es simétrica y semidefinida positiva. Para toda matriz A y vector b ,

$$\mathbb{E}(AX + b) = Am + b, \quad \text{Cov}(AX + b) = A\Sigma A^T.$$

Demostración. La simetría es inmediata. Para $a \in \mathbb{R}^d$,

$$a^T \Sigma a = \mathbb{E}[a^T (X - m)(X - m)^T a] = \mathbb{E}[(a^T (X - m))^2] = \text{Var}(a^T X) \geq 0.$$

La transformación de la media usa linealidad; para la covarianza se sustituye $AX + b - (Am + b) = A(X - m)$ y se extraen las matrices constantes. $\square$

Corolario 3.20. Σ es singular si y solo si existe $a \neq 0$ tal que $a^T X$ es constante c.s.

Demostración. Si Σ es singular y semidefinida positiva, existe $a \neq 0$ con $a^T \Sigma a = 0$. La identidad anterior da $\text{Var}(a^T X) = 0$, equivalente a $a^T X = \mathbb{E}(a^T X)$ c.s. El recíproco sigue en reversa. $\square$

Ejemplo 3.21. Escribamos

$$\Sigma = \begin{pmatrix} \sigma_X^2 & c \\ c & \sigma_Y^2 \end{pmatrix}, \quad c = \text{Cov}(X, Y).$$

Aquí $\sigma_X^2 := \text{Var}(X)$ y $\sigma_Y^2 := \text{Var}(Y)$. Para $Z = (X + Y, X - Y)^T = AX$, con $A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$, la multiplicación $A\Sigma A^T$ da

$$\text{Cov}(Z) = \begin{pmatrix} \sigma_X^2 + \sigma_Y^2 + 2c & \sigma_X^2 - \sigma_Y^2 \\ \sigma_X^2 - \sigma_Y^2 & \sigma_X^2 + \sigma_Y^2 - 2c \end{pmatrix}.$$

En particular,

$$\text{Cov}(X + Y, X - Y) = \text{Var } X - \text{Var } Y.$$

La covarianza puede anularse sin que las dos combinaciones sean independientes, salvo bajo hipótesis adicionales como gaussianidad conjunta.

3.7. Muestras i.i.d. y media muestral

Una muestra aleatoria $X_1, \dots, X_n$ significa que las variables son independientes y tienen la misma ley. Abreviaremos esta condición diciendo que son *i.i.d.*, por “independientes e idénticamente distribuidas”. No significa que los valores observados sean distintos ni que se conozcan los parámetros de la ley común.

Si $\mathbb{E}X_1 = \mu$ y $\text{Var}(X_1) = \sigma^2 < \infty$, la media

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

satisface

$$\mathbb{E}\bar{X}_n = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

Para la varianza,

$$\begin{aligned} \text{Var}(\bar{X}_n) &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j) \right] \\ &= \frac{\sigma^2}{n}. \end{aligned}$$

La última igualdad usa que independencia y segundo momento finito implican $\text{Cov}(X_i, X_j) = 0$ para $i \neq j$.

Ejemplo 3.22 (Muestra Bernoulli). Si X_i indica éxito con probabilidad p , entonces $X_i^2 = X_i$ y

$$\text{Var}(X_i) = \mathbb{E}X_i^2 - (\mathbb{E}X_i)^2 = p - p^2 = p(1 - p).$$

Así $\bar{X}_n$ es la proporción de éxitos, con media p y varianza $p(1 - p)/n$. Para $\varepsilon > 0$, Chebyshev da

$$\mathbb{P}(|\bar{X}_n - p| \geq \varepsilon) \leq \frac{p(1 - p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}.$$

La última cota es uniforme en p porque $p(1 - p) \leq 1/4$.

Proposición 3.23 (Covarianzas con la media). *Para una muestra i.i.d. con segundo momento,*

$$\text{Cov}(X_i, \bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{Cov}(X_i - \bar{X}_n, \bar{X}_n) = 0.$$

Demostración. Por bilinealidad,

$$\text{Cov}(X_i, \bar{X}_n) = \frac{1}{n} \sum_j \text{Cov}(X_i, X_j) = \frac{\sigma^2}{n},$$

porque los términos con $j \neq i$ se anulan. Restar $\text{Var}(\bar{X}_n) = \sigma^2/n$ prueba la segunda identidad. $\square$

La incorrelación entre residuos y media no implica todavía independencia. En una muestra normal sí la implicará, pero esa demostración requiere la estructura gaussiana de las semanas 10–11.

3.8. Varianza muestral y descomposición de cuadrados

Definimos

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad n \geq 2.$$

El denominador $n-1$ se deduce de una identidad, no es una convención arbitraria.

Teorema 3.24 (Descomposición de suma de cuadrados). *Para cualquier constante a ,*

$$\sum_{i=1}^n (X_i - a)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - a)^2.$$

Demostración. Escribimos $X_i - a = (X_i - \bar{X}_n) + (\bar{X}_n - a)$. Al elevar al cuadrado y sumar,

$$\begin{aligned} \sum_{i=1}^n (X_i - a)^2 &= \sum_{i=1}^n (X_i - \bar{X}_n)^2 \\ &\quad + 2(\bar{X}_n - a) \sum_{i=1}^n (X_i - \bar{X}_n) + n(\bar{X}_n - a)^2. \end{aligned}$$

El término cruzado desaparece porque

$$\sum_{i=1}^n (X_i - \bar{X}_n) = \sum_{i=1}^n X_i - n\bar{X}_n = 0.$$

□

Corolario 3.25 (Insensibilidad). *Si la muestra es i.i.d. con varianza $\sigma^2 < \infty$, entonces $\mathbb{E}S_n^2 = \sigma^2$.*

Demostración. Tomamos $a = \mu$ y esperanzas. Como las variables tienen la misma varianza,

$$\mathbb{E} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \mathbb{E}(X_i - \mu)^2 = n\sigma^2.$$

Además, $\mathbb{E}\bar{X}_n = \mu$ y

$$\mathbb{E}[n(\bar{X}_n - \mu)^2] = n \text{Var}(\bar{X}_n) = \sigma^2.$$

Al restar en la identidad anterior,

$$\mathbb{E} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = (n-1)\sigma^2,$$

y dividir por $n-1$ concluye que $\mathbb{E}S_n^2 = \sigma^2$. □

Observación. La prueba solo exige independencia, igualdad de leyes y segundo momento. Si se empleara el divisor n , la esperanza del estimador sería $\frac{n-1}{n}\sigma^2$. La distribución de S_n^2 y su independencia respecto de $\bar{X}_n$ requieren normalidad y se estudiarán en la semana 11.

Cierre. Las transformaciones se resuelven por preimágenes; los jacobianos son una herramienta derivada. En vectores, la covarianza se organiza como una matriz semidefinida positiva. En muestras i.i.d., las identidades de media y varianza preparan las leyes de los grandes números y el TCL.

Lecturas

Saporta, capítulos 2–4; Durrett, §1.3; Sheffield, clases 2–3. Las familias no desarrolladas en teoría quedan como ejercicios de transformación y reconocimiento de mecanismos.