



Notas · Semana 8

Teoría de la Probabilidad · CM4H1

Esperanza condicional

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 8: información y esperanza condicional

Propósito. Construir la esperanza condicional como variable aleatoria, no como cociente informal, y dominar sus propiedades de cálculo.

Sesión 1. Información como sub- σ -álgebra; definición; existencia por Radon–Nikodym; unicidad; casos discretos.

Sesión 2. Linealidad, monotonía, extracción de factores, torre, independencia, Jensen y fórmulas con densidades.

Recordatorios de medida. Restricción de una medida, continuidad monótona, Radon–Nikodym, aproximación simple, convergencia dominada y teorema π - λ . Se usan sin redemostrar todos sus detalles.

Idea guía. $\mathbb{E}(X \mid \mathcal{G})$ es el promedio de X compatible con la información $\mathcal{G}$: es observable con $\mathcal{G}$ y conserva las integrales sobre todos los sucesos observables.

1.1. Información y definición

Objetivo de la sesión. Interpretar una sub- σ -álgebra y formular la propiedad que caracteriza la esperanza condicional.

Una sub- σ -álgebra $\mathcal{G} \subset \mathcal{F}$ representa las preguntas cuya respuesta está disponible. Si Z es $\mathcal{G}$ -medible, conocer $\mathcal{G}$ basta para conocer Z .

Definición 1.1. Para $X \in L^1$, una *versión* de $\mathbb{E}(X | \mathcal{G})$ es una variable Z tal que: (i) es $\mathcal{G}$ -medible; (ii) es integrable; y (iii)

$$\int_G Z d\mathbb{P} = \int_G X d\mathbb{P} \quad (G \in \mathcal{G}).$$

La tercera condición conserva el promedio en cada región distinguible por la información. Con $G = \Omega$ resulta $\mathbb{E}Z = \mathbb{E}X$. Se habla de versiones porque la definición determina Z solo casi seguramente.

Ejemplo: una partición. Una empresa clasifica una pieza únicamente por la línea G_j de la que procede. La pregunta natural es: *¿cuál es el costo medio de reparación cuando solo se conoce la línea?* Si (G_j) es una partición numerable y $\mathbb{P}(G_j) > 0$,

$$Z = \sum_j \frac{\mathbb{E}[X \mathbf{1}_{G_j}]}{\mathbb{P}(G_j)} \mathbf{1}_{G_j}.$$

La respuesta es constante dentro de cada celda, pues la información no distingue resultados dentro de ella. Para verificar la definición se suman las identidades sobre las celdas contenidas en $G \in \sigma(G_j : j \geq 1)$.

Dos extremos. Si X es $\mathcal{G}$ -medible, entonces $\mathbb{E}(X | \mathcal{G}) = X$. Si $\mathcal{G} = \{\emptyset, \Omega\}$, entonces $\mathbb{E}(X | \mathcal{G}) = \mathbb{E}X$.

1.2. Existencia por Radon–Nikodym

Recordatorio. Si $\nu \ll \mu$ son medidas σ -finitas, existe $h \geq 0$, única μ -c.s., tal que $\nu(A) = \int_A h d\mu$.

Teorema 1.2 (Existencia). Si $X \in L^1$ y $\mathcal{G} \subset \mathcal{F}$, existe $\mathbb{E}(X \mid \mathcal{G})$.

Demostración. Primero sea $X \geq 0$. Sobre $(\Omega, \mathcal{G})$ definimos

$$\nu(G) = \int_G X d\mathbb{P}.$$

La convergencia monótona prueba la aditividad numerable. Si $\mathbb{P}(G) = 0$, entonces $\nu(G) = 0$; por ello $\nu \ll \mathbb{P}|_{\mathcal{G}}$. Radon–Nikodym produce una función $Z \geq 0$, $\mathcal{G}$ -medible, tal que $\nu(G) = \int_G Z d\mathbb{P}$. Como $\nu(\Omega) = \mathbb{E}X < \infty$, también $Z \in L^1$.

Para $X \in L^1$, escribimos $X = X^+ - X^-$. Construimos $Z^+ = \mathbb{E}(X^+ \mid \mathcal{G})$ y $Z^- = \mathbb{E}(X^- \mid \mathcal{G})$; entonces $Z = Z^+ - Z^-$ cumple las tres condiciones. $\square$

El teorema entrega un objeto caracterizado por integrales, no siempre una fórmula puntual. Las fórmulas discretas y con densidades son representaciones particulares.

Caso de un suceso. Si $\mathcal{G} = \sigma(A)$ y $0 < \mathbb{P}(A) < 1$,

$$\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}(X \mid A)\mathbf{1}_A + \mathbb{E}(X \mid A^c)\mathbf{1}_{A^c}.$$

Aquí $\mathbb{E}(X \mid A)$ es un número, mientras que $\mathbb{E}(X \mid \mathcal{G})$ es una variable. Confundirlos elimina la dependencia respecto de la información observada.

1.3. Unicidad y clase de prueba

Teorema 1.3 (Unicidad). *Si Z_1 y Z_2 satisfacen la definición, entonces $Z_1 = Z_2$ c.s.*

Demostración. Para $G = \{Z_1 > Z_2\} \in \mathcal{G}$,

$$\int_G (Z_1 - Z_2) d\mathbb{P} = 0.$$

El integrando es no negativo, así que es cero c.s. en G y $\mathbb{P}(Z_1 > Z_2) = 0$. Intercambiar índices termina la prueba. $\square$

Para comprobar una candidata Z basta verificar medibilidad, integrabilidad e identidad de integrales. Puede reducirse la clase de conjuntos.

Lema de prueba. Suponga que $\mathcal{C}$ es un π -sistema que genera $\mathcal{G}$ y contiene Ω . Si Z es $\mathcal{G}$ -medible e integrable y

$$\mathbb{E}[Z\mathbf{1}_C] = \mathbb{E}[X\mathbf{1}_C] \quad (C \in \mathcal{C}),$$

entonces Z es una versión de $\mathbb{E}(X \mid \mathcal{G})$.

Demostración. Las aplicaciones $G \mapsto \int_G Z, d\mathbb{P}$ y $G \mapsto \int_G X, d\mathbb{P}$ son medidas con signo finitas. Aplicando el argumento de unicidad de medidas a partes positivas y negativas, o separando signos mediante una constante, la clase donde coinciden es un sistema de Dynkin. El teorema π - λ extiende la igualdad desde $\mathcal{C}$ hasta $\sigma(\mathcal{C}) = \mathcal{G}$. $\square$

Este criterio será útil para condicionar respecto de una variable y, más adelante, para demostrar propiedades de vectores gaussianos y martingalas.

1.4. Cálculo discreto

Si Y toma valores y_j con masas positivas,

$$\mathbb{E}(X | Y) = g(Y), \quad g(y_j) = \frac{\mathbb{E}[X \mathbf{1}_{\{Y=y_j\}}]}{\mathbb{P}(Y = y_j)}.$$

La expresión $\mathbb{E}(X | Y)$ abrevia $\mathbb{E}(X | \sigma(Y))$.

Pregunta. Se lanzan dos dados justos. Sabiendo únicamente la suma, ¿cuál es el valor medio del primer dado?

Modelo. $\Omega = \{1, \dots, 6\}^2$ con masa $1/36$; $X_1(i, j) = i$, $X_2(i, j) = j$ y $S = X_1 + X_2$. Dentro de $\{S = s\}$, el intercambio $(i, j) \leftrightarrow (j, i)$ conserva probabilidades. Luego

$$\mathbb{E}(X_1 | S = s) = \mathbb{E}(X_2 | S = s).$$

Como $X_1 + X_2 = s$ en esa celda, ambas esperanzas suman s , de modo que

$$\mathbb{E}(X_1 | S) = S/2.$$

Ley total de la esperanza.

$$\mathbb{E}X = \sum_j \mathbb{E}(X | Y = y_j) \mathbb{P}(Y = y_j),$$

que es simplemente $\mathbb{E}\mathbb{E}(X | Y) = \mathbb{E}X$.

Advertencia. Si Y es continua, normalmente $\mathbb{P}(Y = y) = 0$ y el cociente elemental no define el condicionamiento. Se necesita una distribución condicional regular o una fórmula con densidades, válida para casi todo y .

1.5. Propiedades estructurales

Objetivo de la sesión. Obtener reglas de cálculo desde la definición y la unicidad.

Linealidad. Para $X, Y \in L^1$,

$$\mathbb{E}(aX + bY \mid \mathcal{G}) = a\mathbb{E}(X \mid \mathcal{G}) + b\mathbb{E}(Y \mid \mathcal{G}).$$

Se verifica medibilidad e identidad de integrales y se usa unicidad.

Positividad. Si $X \geq 0$, entonces $\mathbb{E}(X \mid \mathcal{G}) \geq 0$ c.s. Si una versión Z fuese negativa en $G = \{Z < 0\} \in \mathcal{G}$, se tendría $\int_G Z < 0$ pero $\int_G X \geq 0$. Por tanto, $X \leq Y$ implica $\mathbb{E}(X \mid \mathcal{G}) \leq \mathbb{E}(Y \mid \mathcal{G})$.

Contracción. Jensen con $|x|$ produce

$$|\mathbb{E}(X \mid \mathcal{G})| \leq \mathbb{E}(|X| \mid \mathcal{G}), \quad \|\mathbb{E}(X \mid \mathcal{G})\|_1 \leq \|X\|_1.$$

Dominada condicional. Si $X_n \rightarrow X$ c.s. y $|X_n| \leq Y \in L^1$, entonces

$$\|\mathbb{E}(X_n \mid \mathcal{G}) - \mathbb{E}(X \mid \mathcal{G})\|_1 \leq \mathbb{E}|X_n - X| \rightarrow 0.$$

Esto da convergencia en L^1 , no necesariamente convergencia casi segura de toda la sucesión.

Fatou condicional. Para $X_n \geq 0$,

$$\mathbb{E}(\liminf X_n \mid \mathcal{G}) \leq \liminf \mathbb{E}(X_n \mid \mathcal{G}) \quad \text{c.s.}$$

Se integra sobre cada $G \in \mathcal{G}$, se aplica Fatou ordinario y se usa la caracterización por integrales.

1.6. Extracción de factores e independencia

Teorema 1.4. Si Y es $\mathcal{G}$ -medible y acotada, y $X \in L^1$, entonces

$$\mathbb{E}(YX \mid \mathcal{G}) = Y\mathbb{E}(X \mid \mathcal{G}).$$

Demostración. Para $Y = \mathbf{1}_H$, $H \in \mathcal{G}$, y $G \in \mathcal{G}$,

$$\int_G \mathbf{1}_H \mathbb{E}(X \mid \mathcal{G}) d\mathbb{P} = \int_{G \cap H} \mathbb{E}(X \mid \mathcal{G}) d\mathbb{P} = \int_{G \cap H} X d\mathbb{P}.$$

Linealidad extiende a funciones simples. Si Y es acotada, tomar simples $Y_n \rightarrow Y$ uniformemente acotadas y aplicar convergencia dominada a $Y_n X$ y a $Y_n \mathbb{E}(X \mid \mathcal{G})$. $\square$

En particular, para toda decisión acotada Y basada en $\mathcal{G}$,

$$\mathbb{E}(YX) = \mathbb{E}[Y\mathbb{E}(X \mid \mathcal{G})].$$

Teorema 1.5. Si X es independiente de $\mathcal{G}$, entonces $\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}X$.

Demostración. Para $X = \mathbf{1}_A$, independencia da $\mathbb{P}(A \cap G) = \mathbb{P}(A)\mathbb{P}(G)$. Se extiende a simples no negativas, después por convergencia monótona a variables no negativas y por descomposición a L^1 . $\square$

La recíproca para una sola variable X es falsa: tener media condicional constante no implica independencia. Sí es suficiente exigir $\mathbb{E}[h(X) \mid \mathcal{G}] = \mathbb{E}h(X)$ para toda h boreliana acotada.

1.7. Propiedad de la torre

Teorema 1.6. Si $\mathcal{H} \subset \mathcal{G}$ y $X \in L^1$, entonces

$$\mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) = \mathbb{E}(X | \mathcal{H}).$$

Demostración. El lado izquierdo es $\mathcal{H}$ -medible. Para $H \in \mathcal{H} \subset \mathcal{G}$,

$$\int_H \mathbb{E}(\mathbb{E}(X | \mathcal{G}) | \mathcal{H}) d\mathbb{P} = \int_H \mathbb{E}(X | \mathcal{G}) d\mathbb{P} = \int_H X, d\mathbb{P}.$$

La unicidad concluye. □

Consecuencias:

$$\mathbb{E}\mathbb{E}(X | \mathcal{G}) = \mathbb{E}X, \quad \mathbb{E}(\mathbb{E}(X | \mathcal{H}) | \mathcal{G}) = \mathbb{E}(X | \mathcal{H})$$

si $\mathcal{H} \subset \mathcal{G}$, pues la variable interna ya es $\mathcal{G}$ -medible.

Pregunta. Una aseguradora observa primero la región y luego la región junto con el tipo de vehículo. ¿Qué sucede si el pronóstico fino se vuelve a promediar reteniendo solo la región?

Modelo. Sea X el siniestro, R la región y T el tipo. Con $\mathcal{H} = \sigma(R)$ y $\mathcal{G} = \sigma(R, T)$,

$$\mathbb{E}(\mathbb{E}(X | R, T) | R) = \mathbb{E}(X | R).$$

La torre expresa coherencia entre niveles de información. Para σ -álgebras no comparables no existe una simplificación universal.

1.8. Jensen condicional

Teorema 1.7. Si φ es convexa y $X, \varphi(X) \in L^1$, entonces

$$\varphi(\mathbb{E}(X \mid \mathcal{G})) \leq \mathbb{E}(\varphi(X) \mid \mathcal{G}) \quad c.s.$$

Demostración. Una convexa finita es el supremo de una familia numerable de rectas soporte: $\varphi(x) = \sup_k (a_k x + b_k)$. Para cada k ,

$$a_k \mathbb{E}(X \mid \mathcal{G}) + b_k = \mathbb{E}(a_k X + b_k \mid \mathcal{G}) \leq \mathbb{E}(\varphi(X) \mid \mathcal{G}).$$

Tomar el supremo en el lado izquierdo prueba la afirmación. □

Para $p \geq 1$,

$$|\mathbb{E}(X \mid \mathcal{G})|^p \leq \mathbb{E}(|X|^p \mid \mathcal{G}), \quad \|\mathbb{E}(X \mid \mathcal{G})\|_p \leq \|X\|_p.$$

Con $\varphi(x) = x^2$ y $X \in L^2$,

$$\mathbb{E}[(X - \mathbb{E}(X \mid \mathcal{G}))^2] = \mathbb{E}(X^2) - \mathbb{E}[\mathbb{E}(X \mid \mathcal{G})^2].$$

Para probarla, expandir el cuadrado y usar extracción de factores:

$$\mathbb{E}[X\mathbb{E}(X \mid \mathcal{G})] = \mathbb{E}[\mathbb{E}(X \mid \mathcal{G})^2].$$

La semana siguiente interpretará esta identidad como proyección ortogonal y mejor predictor cuadrático.

1.9. Densidades y cálculo explícito

Si (X, Y) tiene densidad conjunta, para $f_Y(y) > 0$ definimos

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad g(y) = \int x f_{X|Y}(x | y), dx.$$

Entonces $g(Y)$ es una versión de $\mathbb{E}(X | Y)$.

Demostración. Para todo boreliano B , Tonelli–Fubini da

$$\int_{\{Y \in B\}} g(Y) d\mathbb{P} = \int_B g(y) f_Y(y) dy = \int_B \int x f_{X,Y}(x, y) dx dy = \mathbb{E}[X \mathbf{1}_{\{Y \in B\}}].$$

La clase $\{Y \in B\}$ genera $\sigma(Y)$; el lema de prueba concluye. Los valores de g donde $f_Y = 0$ se eligen arbitrariamente. $\square$

Ejemplo: dos fuentes Poisson. Sean $X \sim \text{Poi}(\lambda)$ y $Y \sim \text{Poi}(\mu)$ independientes. Observado $S = X + Y$, ¿cuántos eventos se atribuyen en promedio a la primera fuente? Para $0 \leq k \leq n$,

$$\mathbb{P}(X = k | S = n) = \binom{n}{k} p^k (1-p)^{n-k}, \quad p = \frac{\lambda}{\lambda + \mu}.$$

Así, $\mathbb{E}(X | S = n) = np$ y

$$\mathbb{E}(X | S) = \frac{\lambda}{\lambda + \mu} S.$$

Lecturas. Durrett: esperanza condicional. Saporta: condicionamiento y momentos. Notas MIT: formulación abstracta y convenciones.