



Notas · Semana 9

Teoría de la Probabilidad · CM4H1

Predicción y descomposición de varianza

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Semana 9

Esperanza condicional como predictor

Propósito. Pasar de la definición por integrales a su significado geométrico y estadístico: proyección, mejor predictor, varianza explicada y modelos con información latente.

Sesión 1. Geometría de L^2 , ortogonalidad, teorema del mejor predictor y ley de varianza total.

Sesión 2. Predicción lineal, comparación con el predictor óptimo, mezclas y sumas aleatorias.

Recordatorios. Completitud de L^2 , subsucesión casi segura desde convergencia L^2 , Cauchy–Schwarz, truncamiento, Tonelli para series aleatorias y funciones generatrices.

Sesión 1. El subespacio de información

Objetivo de la sesión. Probar que las variables observables forman un subespacio cerrado de L^2 .

En $L^2(\Omega, \mathcal{F}, \mathbb{P})$ usamos

$$\langle X, Y \rangle = \mathbb{E}(XY), \quad \|X\|_2 = (\mathbb{E}X^2)^{1/2}.$$

Para $\mathcal{G} \subset \mathcal{F}$, sea $L^2(\mathcal{G})$ el conjunto de clases de variables $\mathcal{G}$ -medibles con segundo momento finito.

Proposición 9.1. $L^2(\mathcal{G})$ es un subespacio cerrado de $L^2(\mathcal{F})$.

Demostración. La estabilidad por combinaciones lineales es inmediata. Sea $Y_n \in L^2(\mathcal{G})$ y $Y_n \rightarrow Y$ en L^2 . Seleccionamos una subsucesión Y_{n_k} con

$$\|Y_{n_k} - Y\|_2^2 \leq 2^{-k}.$$

Por Markov, $\mathbb{P}(|Y_{n_k} - Y| > \varepsilon) \leq 2^{-k}/\varepsilon^2$; Borel–Cantelli implica $Y_{n_k} \rightarrow Y$ c.s. El límite puntual de funciones $\mathcal{G}$ -medibles es $\mathcal{G}$ -medible fuera de un nulo. Como trabajamos con clases c.s. y el espacio es completo, elegimos una versión $\mathcal{G}$ -medible de Y . Luego $Y \in L^2(\mathcal{G})$. $\square$

Recordatorio de Hilbert. Todo subespacio cerrado M de un espacio de Hilbert admite una proyección ortogonal: para cada x existe un único $z \in M$ tal que $x - z \perp M$. Aquí identificaremos esa proyección sin invocar el teorema como caja negra.

9.1. Ortogonalidad de la esperanza condicional

Sea $X \in L^2$ y $Z = \mathbb{E}(X \mid \mathcal{G})$. Jensen asegura $Z \in L^2(\mathcal{G})$.

Teorema 9.2. Para todo $Y \in L^2(\mathcal{G})$,

$$\mathbb{E}[(X - Z)Y] = 0.$$

Demostración. Si Y es $\mathcal{G}$ -medible y acotada, la extracción de factores y la torre dan

$$\mathbb{E}[(X - Z)Y] = \mathbb{E}\{\mathbb{E}[(X - Z)Y \mid \mathcal{G}]\} = \mathbb{E}\{Y\mathbb{E}[X - Z \mid \mathcal{G}]\} = 0.$$

Para $Y \in L^2(\mathcal{G})$, trunque $Y_m = (-m) \vee (Y \wedge m)$. Entonces $Y_m \rightarrow Y$ en L^2 . Por Cauchy-Schwarz,

$$|\mathbb{E}[(X - Z)(Y - Y_m)]| \leq \|X - Z\|_2 \|Y - Y_m\|_2 \rightarrow 0.$$

Pasar al límite completa la prueba. □

Esta igualdad contiene la definición integral: al tomar $Y = \mathbf{1}_G$, $G \in \mathcal{G}$, recuperamos $\int_G (X - Z)d\mathbb{P} = 0$. En L^2 , por tanto, la esperanza condicional puede definirse equivalentemente mediante ortogonalidad.

Interpretación. El error $X - Z$ no tiene correlación con ninguna variable cuadrado-integrable construida a partir de la información disponible. No queda una corrección lineal basada en $\mathcal{G}$ que reduzca el error.

9.2. Mejor predictor cuadrático

Teorema 9.3. Para todo $Y \in L^2(\mathcal{G})$,

$$\mathbb{E}(X - Y)^2 = \mathbb{E}(X - Z)^2 + \mathbb{E}(Z - Y)^2, \text{ donde } Z = \mathbb{E}(X \mid \mathcal{G}).$$

En consecuencia, Z es el único minimizador c.s. del error cuadrático entre los predictores $\mathcal{G}$ -medibles.

Demostración. Escribimos $X - Y = (X - Z) + (Z - Y)$ y expandimos. El término cruzado es

$$2\mathbb{E}[(X - Z)(Z - Y)] = 0$$

porque $Z - Y \in L^2(\mathcal{G})$. La identidad de Pitágoras resulta. El segundo término es no negativo y se anula únicamente si $Y = Z$ c.s. $\square$

Pregunta. Si solo se conoce una medición ruidosa Y , ¿qué función $g(Y)$ predice mejor a X en error cuadrático medio?

Modelo. La clase admisible es $L^2(\sigma(Y))$, es decir, variables de la forma $g(Y)$ bajo condiciones usuales. La respuesta es

$$g(Y) = \mathbb{E}(X \mid Y).$$

No se restringe g a ser lineal. Por ello la esperanza condicional nunca tiene error mayor que el mejor predictor afín.

Caso trivial. Si no se observa información, $\mathcal{G} = \{\emptyset, \Omega\}$ y el mejor predictor constante es $\mathbb{E}X$; el error mínimo es $\text{Var } X$.

9.3. Varianza condicional y varianza total

Definimos

$$\text{Var}(X \mid \mathcal{G}) = \mathbb{E}[(X - \mathbb{E}(X \mid \mathcal{G}))^2 \mid \mathcal{G}] = \mathbb{E}(X^2 \mid \mathcal{G}) - \mathbb{E}(X \mid \mathcal{G})^2.$$

La segunda identidad se obtiene expandiendo y extrayendo los factores $\mathcal{G}$ -medibles.

Teorema 9.4 (Varianza total). Si $X \in L^2$, entonces

$$\text{Var } X = \mathbb{E}[\text{Var}(X \mid \mathcal{G})] + \text{Var}(\mathbb{E}(X \mid \mathcal{G})).$$

Demostración. Sea $Z = \mathbb{E}(X \mid \mathcal{G})$. Descomponemos

$$X - \mathbb{E}X = (X - Z) + (Z - \mathbb{E}X).$$

Los sumandos son ortogonales, porque $Z - \mathbb{E}X \in L^2(\mathcal{G})$. Tomar normas al cuadrado da

$$\text{Var } X = \mathbb{E}(X - Z)^2 + \mathbb{E}(Z - \mathbb{E}X)^2.$$

La torre identifica el primer término con $\mathbb{E} \text{Var}(X \mid \mathcal{G})$ y $\mathbb{E}Z = \mathbb{E}X$ identifica el segundo. $\square$

La primera parte es variación residual dentro de los grupos de información; la segunda es variación entre sus medias. Ninguna es negativa, por lo cual

$$\text{Var}(\mathbb{E}(X \mid \mathcal{G})) \leq \text{Var } X.$$

Más información reduce el error cuadrático promedio, aunque la varianza condicional puntual no tiene que disminuir para cada ω .

Sesión 2. Predicción lineal

Objetivo de la sesión. Derivar las ecuaciones normales y compararlas con la esperanza condicional. Buscamos a, b que minimicen $Q(a, b) = \mathbb{E}[(X - a - bY)^2]$, suponiendo segundos momentos y $\text{Var } Y > 0$.

Centrar variables separa la constante. Para cada b , el mejor a satisface $a = \mathbb{E}X - b\mathbb{E}Y$. Entonces

$$Q(b) = \mathbb{E}[(X - \mathbb{E}X) - b(Y - \mathbb{E}Y)]^2 = \text{Var } X - 2b \text{Cov}(X, Y) + b^2 \text{Var } Y.$$

Completar cuadrados o derivar da

$$b^* = \frac{\text{Cov}(X, Y)}{\text{Var } Y}, \quad a^* = \mathbb{E}X - b^*\mathbb{E}Y.$$

El error mínimo lineal es

$$\text{Var } X - \frac{\text{Cov}(X, Y)^2}{\text{Var } Y}.$$

Cauchy–Schwarz garantiza que es no negativo.

Ecuaciones normales. El residuo $R = X - a^* - b^*Y$ satisface $\mathbb{E}R = 0$ y $\mathbb{E}(RY) = 0$: es ortogonal al espacio generado por 1 y Y .

Comparación. El predictor $\mathbb{E}(X | Y)$ minimiza sobre todas las funciones cuadrado-integrables de Y , mientras que $a^* + b^*Y$ minimiza solo sobre funciones afines. Coinciden si $\mathbb{E}(X | Y)$ es afín; esto ocurrirá para vectores conjuntamente gaussianos.

9.4. Mezclas y variable latente

Pregunta. Una población combina dos subpoblaciones con distintas medias y varianzas. ¿Qué parte de la variabilidad total proviene de diferencias internas y qué parte de las diferencias entre grupos?

Modelo. Sea $C \in \{1, 2\}$ el grupo, $\mathbb{P}(C = 1) = p$, y

$$\mathbb{E}(X \mid C = i) = \mu_i, \text{ y } \text{Var}(X \mid C = i) = \sigma_i^2.$$

Por la torre,

$$\mathbb{E}X = p\mu_1 + (1 - p)\mu_2.$$

Por varianza total,

$$\text{Var } X = p\sigma_1^2 + (1 - p)\sigma_2^2 + p(1 - p)(\mu_1 - \mu_2)^2.$$

El último término es la varianza entre grupos. Puede ser grande aunque ambas varianzas internas sean pequeñas.

Demostración. La esperanza de la varianza condicional es $p\sigma_1^2 + (1 - p)\sigma_2^2$. Además, $\mathbb{E}(X \mid C)$ toma valores μ_1, μ_2 con probabilidades $p, 1 - p$, cuya varianza es $p(1 - p)(\mu_1 - \mu_2)^2$. $\square$

Advertencia estadística. Una mezcla de normales no suele ser normal. Condicionar en el grupo simplifica la ley, pero al eliminar la etiqueta aparece heterogeneidad y, a veces, multimodalidad.

9.5. Sumas aleatorias

Sea N entero no negativo, independiente de una sucesión i.i.d. (X_k) , con $\mathbb{E}X_1 = \mu$, $\text{Var } X_1 = \sigma^2$. Defina $S_N = \sum_{k=1}^N X_k$ y $S_0 = 0$.

Condicionado en $N = n$,

$$\mathbb{E}(S_N \mid N = n) = n\mu, \text{ y } \text{Var}(S_N \mid N = n) = n\sigma^2.$$

Por torre y varianza total,

$$\mathbb{E}S_N = \mu\mathbb{E}N, \text{ y } \text{Var}(S_N) = \sigma^2\mathbb{E}N + \mu^2 \text{Var } N.$$

Demostración. La independencia asegura que, bajo $N = n$, los primeros n sumandos conservan su ley conjunta. Así $\mathbb{E}(S_N \mid N) = N\mu$ y $\text{Var}(S_N \mid N) = N\sigma^2$. Aplicar las dos identidades totales produce las fórmulas. $\square$

Pregunta. En un día llegan N reclamos y cada costo es X_k . ¿Cómo se separan la incertidumbre por cantidad de reclamos y la incertidumbre por severidad? La primera contribuye $\mu^2 \text{Var } N$ y la segunda $\sigma^2\mathbb{E}N$.

La independencia es una hipótesis, no una consecuencia de la notación S_N . Si el número de reclamos depende de severidades anticipadas, las fórmulas pueden fallar.

9.6. Transformadas de sumas compuestas

Si $G_N(s) = \mathbb{E}(s^N)$ es la función generatriz de N y $M_X(t) = \mathbb{E}(e^{tX_1})$ existe, entonces

$$M_{S_N}(t) = \mathbb{E}[M_X(t)^N] = G_N(M_X(t)).$$

Demostración. Condicionando en N y usando independencia,

$$\mathbb{E}(e^{tS_N} \mid N = n) = M_X(t)^n.$$

La torre completa la identidad. Para funciones características no se exige existencia de la MGF:

$$\varphi_{S_N}(t) = G_N(\varphi_X(t)).$$

□

Si $N \sim \text{Poi}(\lambda)$,

$$\varphi_{S_N}(t) = \exp\{\lambda(\varphi_X(t) - 1)\},$$

la función característica de una distribución Poisson compuesta.

Ejemplo. Si además $X_k \equiv 1$, entonces $S_N = N$. Si X_k es Bernoulli(q), el adelgazamiento Poisson produce $S_N \sim \text{Poi}(\lambda q)$, pues

$$\exp\{\lambda[(1 - q + qe^{it}) - 1]\} = \exp\{\lambda q(e^{it} - 1)\}.$$

Recordatorio de Tonelli. Para $X_k \geq 0$, también puede escribirse $S_N = \sum_{k \geq 1} X_k \mathbf{1}_{\{N \geq k\}}$ e intercambiar suma y esperanza por Tonelli. Esta vía hace visibles las hipótesis cuando no hay segundos momentos.