



Notas · Semana 10

Teoría de la Probabilidad · CM4H1

Vectores gaussianos

Oswaldo Velásquez Castañón
Profesor Principal · Escuela Profesional de Matemática
Universidad Nacional de Ingeniería

Periodo 2026-2

Capítulo 1

Semana 10: estructura gaussiana multivariada

Propósito. Definir vectores gaussianos sin depender de densidades, caracterizar su ley, estudiar transformaciones lineales y calcular distribuciones condicionales.

Sesión 1. Definiciones equivalentes, función característica, existencia, transformaciones, independencia y degeneración.

Sesión 2. Regresión gaussiana, complemento de Schur, condicionamiento y construcción mediante residuos independientes.

Recordatorios. Matrices semidefinidas positivas, raíces cuadradas espectrales, funciones características y proyección ortogonal.

1.1. Definición y caracterización

Objetivo de la sesión. Reconocer la gaussianidad mediante todas las combinaciones lineales.

Definición 1.1. Un vector $X \in \mathbb{R}^d$ es gaussiano si $t^T X$ es normal unidimensional para todo $t \in \mathbb{R}^d$. Se permiten normales degeneradas.

Si $m = \mathbb{E}X$ y $\Sigma = \mathbb{E}[(X - m)(X - m)^T]$, entonces Σ es simétrica semidefinida positiva porque

$$t^T \Sigma t = \text{Var}(t^T X) \geq 0.$$

Como $t^T X \sim N(t^T m, t^T \Sigma t)$,

$$\varphi_X(t) = \mathbb{E}e^{it^T X} = \exp\{it^T m - \frac{1}{2}t^T \Sigma t\}.$$

La unicidad de funciones características muestra que m y Σ determinan completamente la ley.

Degeneración. Si $t^T \Sigma t = 0$, entonces $t^T(X - m) = 0$ c.s.; la ley vive en un subespacio afín. Por eso no todo vector gaussiano posee densidad respecto de Lebesgue en $\mathbb{R}^d$.

Convención. Escribimos $X \sim N_d(m, \Sigma)$ aun cuando Σ sea singular.

1.2. Existencia y representación lineal

Teorema 1.2. Para todo $m \in \mathbb{R}^d$ y toda matriz simétrica semidefinida positiva Σ , existe $X \sim N_d(m, \Sigma)$.

Demostración. Por el teorema espectral, $\Sigma = Q\Lambda Q^T$ con Λ diagonal no negativa. Sea $A = Q\Lambda^{1/2}$ y Z un vector de normales estándar independientes. Defina $X = m + AZ$. Entonces

$$\mathbb{E}X = m, \text{ y } \text{Cov}(X) = AA^T = \Sigma.$$

Para cada t , $t^T X = t^T m + (A^T t)^T Z$ es combinación lineal de normales independientes y, por funciones características, es normal con varianza $\|A^T t\|^2 = t^T \Sigma t$. $\square$

La representación no es única: si U es ortogonal, $AU(U^T Z)$ da la misma ley. El rango de Σ es la dimensión efectiva del soporte.

Si Σ es definida positiva, el cambio $x = m + Az$ produce la densidad

$$f_X(x) = \frac{1}{(2\pi)^{d/2}(\det \Sigma)^{1/2}} \exp\left\{-\frac{1}{2}(x - m)^T \Sigma^{-1}(x - m)\right\}.$$

La deducción requiere el jacobiano $|\det A| = (\det \Sigma)^{1/2}$.

1.3. Transformaciones y marginales

Proposición 1.3. Si $X \sim N_d(m, \Sigma)$, B es una matriz $k \times d$ y $b \in \mathbb{R}^k$, entonces

$$BX + b \sim N_k(Bm + b, B\Sigma B^T).$$

Demostración. Para cada $s \in \mathbb{R}^k$, $s^T(BX + b) = (B^T s)^T X + s^T b$ es normal. La media y covarianza se calculan por linealidad. $\square$

Toda subcolección de coordenadas es gaussiana. Más aún, si

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}, \quad m = \begin{pmatrix} m_1 \\ m_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

entonces $X_1 \sim N(m_1, \Sigma_{11})$ y $X_2 \sim N(m_2, \Sigma_{22})$.

Suma. Si X, Y son vectores gaussianos independientes, $X + Y$ es gaussiano y sus parámetros se suman. Sin independencia, la suma sigue siendo gaussiana si el vector conjunto (X, Y) es gaussiano; su covarianza incluye los términos cruzados.

1.4. No correlación e independencia

Para variables generales, covarianza cero no implica independencia. Dentro de un vector conjuntamente gaussiano sí.

Teorema 1.4. *Si (X_1, X_2) es conjuntamente gaussiano y $\Sigma_{12} = 0$, entonces X_1 y X_2 son independientes.*

Demostración. La función característica conjunta es

$$\exp\{i(t_1^T m_1 + t_2^T m_2) - \frac{1}{2}[t_1^T \Sigma_{11} t_1 + 2t_1^T \Sigma_{12} t_2 + t_2^T \Sigma_{22} t_2]\}.$$

Si $\Sigma_{12} = 0$, factoriza como $\varphi_{X_1}(t_1)\varphi_{X_2}(t_2)$. La caracterización por funciones características da independencia. $\square$

Advertencia. Que X y Y sean marginalmente normales y no correlacionados no basta: se necesita gaussianidad conjunta. Por ejemplo, si $Z \sim N(0, 1)$ y $Y = SZ$ con un signo independiente S , entonces Y es normal y $\text{Cov}(Z, Y) = 0$, pero $|Y| = |Z|$.

La estructura gaussiana convierte una condición de segundo orden en una afirmación completa sobre la ley.

1.5. Regresión gaussiana

Objetivo de la sesión. Separar una parte lineal observable y un residuo independiente.

Considere primero (X, Y) bivariado normal, con varianzas positivas. Defina

$$\beta = \frac{\text{Cov}(X, Y)}{\text{Var } Y}, \quad R = X - \mathbb{E}X - \beta(Y - \mathbb{E}Y).$$

El par (R, Y) es conjuntamente gaussiano por transformación lineal y

$$\text{Cov}(R, Y) = \text{Cov}(X, Y) - \beta \text{Var } Y = 0.$$

Por el teorema anterior, R es independiente de Y . Además $\mathbb{E}R = 0$ y

$$\text{Var } R = \text{Var } X - \frac{\text{Cov}(X, Y)^2}{\text{Var } Y}.$$

Por tanto

$$X = \mathbb{E}X + \beta(Y - \mathbb{E}Y) + R, \text{ y } R \perp Y.$$

Condicionando en Y ,

$$\mathbb{E}(X | Y) = \mathbb{E}X + \beta(Y - \mathbb{E}Y).$$

Así el mejor predictor general coincide con el predictor afín. Esta coincidencia es una propiedad gaussiana, no una regla universal.

1.6. Condicionamiento vectorial

Sea (X_1, X_2) conjuntamente gaussiano y suponga Σ_{22} invertible. Defina

$$B = \Sigma_{12}\Sigma_{22}^{-1}, \quad R = X_1 - m_1 - B(X_2 - m_2).$$

Entonces

$$\text{Cov}(R, X_2) = \Sigma_{12} - B\Sigma_{22} = 0.$$

Como (R, X_2) es gaussiano, R y X_2 son independientes. Su covarianza es

$$\Sigma_R = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

Se deduce que una versión de la ley condicional es

$$X_1 \mid X_2 = x_2 \sim N(m_1 + B(x_2 - m_2), \Sigma_R).$$

En particular,

$$\mathbb{E}(X_1 \mid X_2) = m_1 + B(X_2 - m_2).$$

La covarianza condicional no depende del valor observado. El valor cambia la media, pero no la incertidumbre residual dentro del modelo gaussiano.

1.7. Complemento de Schur

La matriz

$$\Sigma_{11 \cdot 2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

se llama complemento de Schur de Σ_{22} . Es semidefinida positiva porque es la covarianza del residuo R . También puede demostrarse algebraicamente: para cualquier u , elegir $v = -\Sigma_{22}^{-1} \Sigma_{21} u$ y usar

$$0 \leq (u^T, v^T) \Sigma (u^T, v^T)^T = u^T \Sigma_{11 \cdot 2} u.$$

Pregunta. Dos instrumentos miden magnitudes correlacionadas. Observado el segundo, ¿cuánto se reduce la incertidumbre sobre el primero?

En el caso bivariado con correlación ρ ,

$$\text{Var}(X | Y) = \sigma_X^2 (1 - \rho^2).$$

La reducción es $\rho^2 \sigma_X^2$, que coincide con la varianza explicada por la regresión lineal.

Si Σ_{22} es singular, se puede restringir al subespacio efectivo o usar una inversa generalizada; para este curso trabajaremos principalmente con el caso invertible.

1.8. Deducción alternativa por densidades

Cuando Σ es definida positiva, la densidad conjunta puede factorizarse completando cuadrados:

$$(x - m)^T \Sigma^{-1} (x - m) = (x_1 - m_1 - B(x_2 - m_2))^T \Sigma_{11.2}^{-1} (\cdots) + (x_2 - m_2)^T \Sigma_{22}^{-1} (x_2 - m_2).$$

Al dividir la densidad conjunta por la marginal de X_2 , el segundo término y las constantes correspondientes se cancelan; queda la densidad normal con media y covarianza ya obtenidas.

La prueba por residuos es más corta y revela independencia. La prueba por densidades confirma la normalización y conecta con el cálculo estadístico.

Ejemplo. Si (X, Y) es normal estándar con correlación ρ ,

$$X \mid Y = y \sim N(\rho y, 1 - \rho^2).$$

Para $|\rho| = 1$ la covarianza conjunta es singular y el condicionamiento se degenera en $X = \rho Y$ c.s.

1.9. Aplicaciones y cierre

Actualización lineal. Sea $X \sim N(m, \tau^2)$ y observe $Y = X + \varepsilon$, con $\varepsilon \sim N(0, \sigma^2)$ independiente. Entonces

$$\mathbb{E}(X | Y) = m + \frac{\tau^2}{\tau^2 + \sigma^2}(Y - m), \quad \text{Var}(X | Y) = \frac{\tau^2 \sigma^2}{\tau^2 + \sigma^2}.$$

El peso de la observación aumenta cuando el ruido σ^2 disminuye.

Simulación. Para generar $N_d(m, \Sigma)$, calcular una factorización $AA^T = \Sigma$, generar Z con componentes $N(0, 1)$ independientes y usar $m + AZ$. Cholesky sirve si Σ es definida positiva; la descomposición espectral también cubre matrices singulares.

Mapa de demostraciones. La función característica prueba unicidad y independencia; el teorema espectral prueba existencia; el residuo ortogonal prueba la ley condicional; el complemento de Schur cuantifica la incertidumbre remanente.

Lecturas. Saporta, capítulos sobre ley normal multivariada; Durrett, vectores gaussianos; notas MIT, funciones características y gaussianidad.